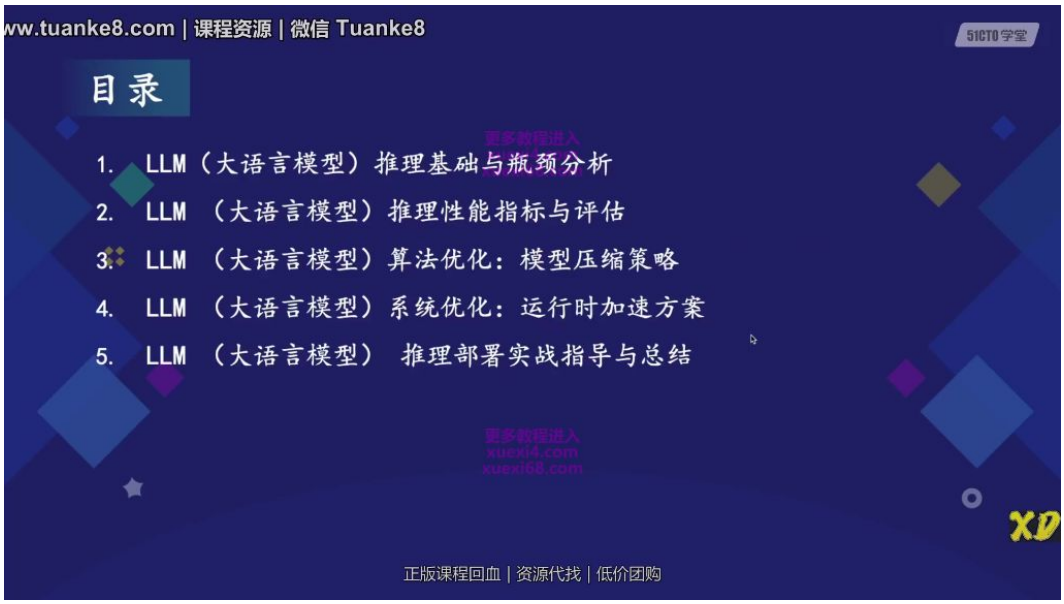
以下为AI生成的图文笔记的内容

一、课程内容介绍 00:12



- **课程目标**：系统掌握大语言模型推理优化与部署全流程技术方案
- **讲师信息**：崔浩（大模型推理优化领域专家）

1. 大语言模型推理基础与瓶颈分析 00:21

- **学习前提**：必须理解推理全流程阶段划分及各阶段瓶颈特征
- **方法论**：采用"问题定位→解决方案"的优化思路
- **关键阶段**：
  - **计算密集型阶段**：矩阵乘法、注意力机制等核心运算
  - **内存受限阶段**：参数量与显存占用的矛盾
  - **通信瓶颈阶段**：多卡/分布式推理时的数据交换

2. 大语言模型推理性能指标与评估 00:48

- **指标体系作用**：作为量化优化的"标尺"，避免主观评估
- **核心指标**：
  - **吞吐量(Throughput)**：单位时间处理的token数量
  - **延迟(Latency)**：单个请求端到端响应时间
  - **内存效率**：显存占用与模型参数的比值
- **评估原则**：需建立baseline进行对比实验，控制变量分析

3. 大语言模型算法优化 01:31

- **核心策略**：模型压缩技术（重点讲解量化方法）
- **技术矛盾**：
  - **压缩率-精度权衡**：量化比特数减少会导致精度损失
  - **解决方案**：采用混合精度量化（不同层使用不同比特数）
- **优化目标**：寻找帕累托最优解（Pareto Optimality）

4. 大语言模型系统优化 02:09

- **优化维度**：运行时加速（区别于算法层面的优化）
- **关键技术**：
  - **注意力机制优化**：稀疏注意力、窗口注意力等变体
  - **算子融合**：减少kernel启动开销
  - **内存调度**：优化显存访问模式
- **实现路径**：从数学原理出发改造计算图（如$softmax(QK^T / \sqrt{d})V$分解）

5. 大语言模型推理部署实战指导 02:33

- **实践要点**：
  - **硬件适配**：根据GPU型号选择最优部署方案
  - **服务化封装**：实现高并发推理API
  - **监控体系**：建立性能指标实时监控看板
- **典型方案**：
  - 小规模部署：单卡FP16量化
  - 中规模部署：TensorRT优化
  - 大规模部署：vLLM框架集群

二、知识小结

章节	核心内容	关键技术	重点难点
第一部分：基础分析	大语言模型推理阶段与瓶颈解析	推理流程拆解	瓶颈定位与归因
第二部分：性能评估	推理性能指标体系建设	量化评估方法	**精度与效率的平衡**
第三部分：算法优化	模型压缩与量化技术	参数量化/剪枝	**精度损失控制**
第四部分：系统加速	运行时加速方案	注意力机制优化	计算资源分配
第五部分：部署实战	生产环境部署指南	推理方案选型	**工程化落地挑战**