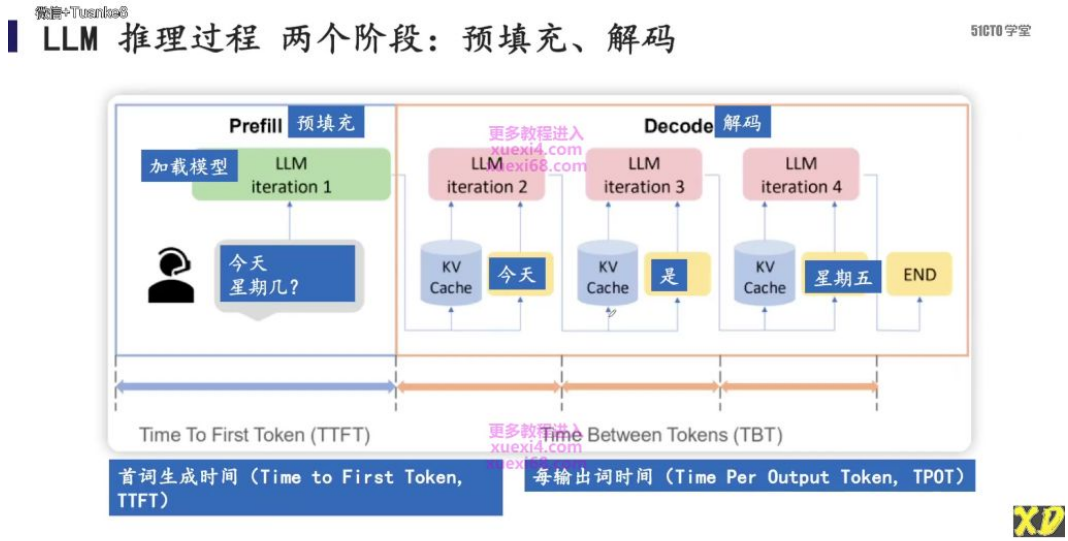
以下为AI生成的图文笔记的内容

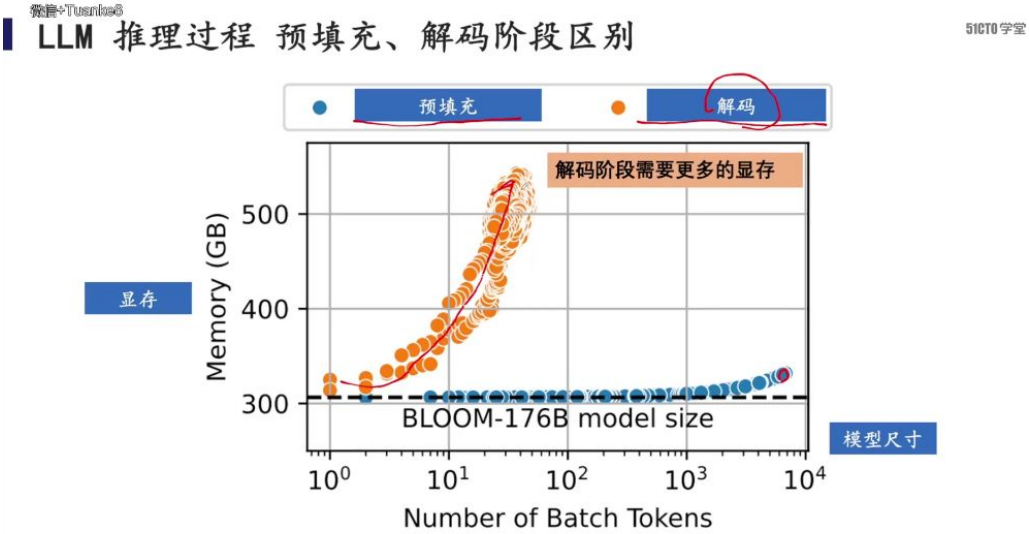
一、推理基础与瓶颈分析 00:15

1. LLM推理过程 01:30



- **阶段划分**：大语言模型推理分为预填充（蓝色框）和解码（红色框）两个阶段
- **预填充机制**：类似"汽车上货"，将用户提示词（如"今天星期几？"）加载到模型内部进行记忆思考
- **关键指标**：
  - **TTFT（首词生成时间）**：从提问到生成第一个词的时间（如3秒），直接影响用户体验
  - **TPOT（每输出词时间）**：解码阶段每个token的生成耗时
- **自回归特性**：每个新token生成都需与之前所有token进行自注意力运算（如"今天"→"是"→"星期五"的迭代过程）
- **KV Cache作用**：存储历史token的键值对，用于加速后续注意力计算

1）预填充、解码阶段显存消耗对比 07:32

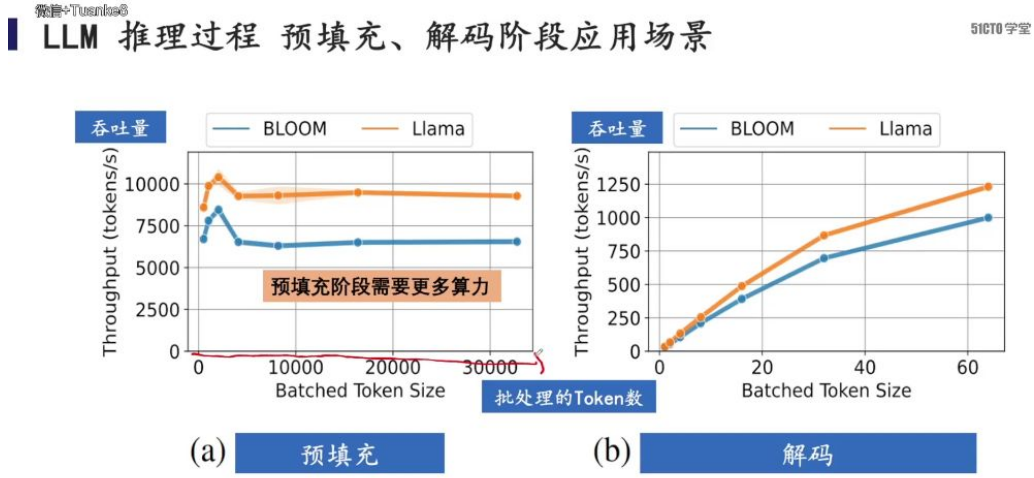


- **显存需求规律**：

- 预填充阶段：模型尺寸增大时显存需求增长平缓（BLOOM-176B模型约100单位）
- 解码阶段：显存需求随模型尺寸指数级增长（相同模型约500单位）

- **部署启示**：解码阶段需要更多显存支持，实际部署需根据模型规模选择显存足够的显卡（如16G/20G/100G）

2）预填充、解码阶段算力要求对比 09:20



-
- **算力特征对比**：
  - 预填充阶段：
    - 吞吐量稳定在7000-10000 token/秒（BLOOM/Llama）
    - 算力需求与批次大小无关，始终维持高位
  - 解码阶段：
    - 吞吐量随批次增大从0增至1250 token/秒
    - 小批次（<20）时算力需求较低，60批次时仍仅为预填充阶段的1/6
- **优化方向**：预填充阶段需要更多计算单元支持高吞吐，解码阶段可通过批处理提升资源利用率

二、知识小结

知识点	核心内容	关键指标/参数	对比维度
推理基础与瓶颈分析	大语言模型推理过程分为预填充阶段和解码阶段	**预填充阶段**：首次生成时间（TTFT） **解码阶段**：每输出词时间（TPOT）	**显存需求**：解码阶段显存需求随模型尺寸增大而显著增加 **算力需求**：预填充阶段算力要求更高
预填充阶段	将用户提示词加载到模型内部，进行记忆和思考	**首次生成时间（TTFT）**：影响用户体验（如3秒返回第一个词）	**显存占用**：模型较小时需求低，随模型增大缓慢上升
解码阶段	自回归生成过程，每生成一个词需与之前所有	**每输出词时间（TPOT）**：生成每个词所需时间 **KV Cache**：存储历史词信息以加速运算	**显存占用**：随模型尺寸增大显著上升 **算力需求**：依赖请求批次，峰值算力需求较低（如1250 tokens/秒）

	词进行注意力运算		
性能优化方向	基于两阶段瓶颈分析提出优化思路（压缩、算法优化、工程部署）	**吞吐量对比**：预填充阶段吞吐量稳定（7000-10000 tokens/秒） 解码阶段吞吐量随批次增加而提升	**硬件瓶颈**：解码阶段显存限制更明显 **算力分配**：预填充阶段需更高算力支持
模型规模影响	横轴为模型参数规模，纵轴为显存需求	**显存曲线**：解码阶段需求增长更快 **吞吐量曲线**：预填充阶段算力需求与模型规模无关	**规模与效率**：大模型需更高显存，但吞吐量不一定线性增长