以下为AI生成的图文笔记的内容

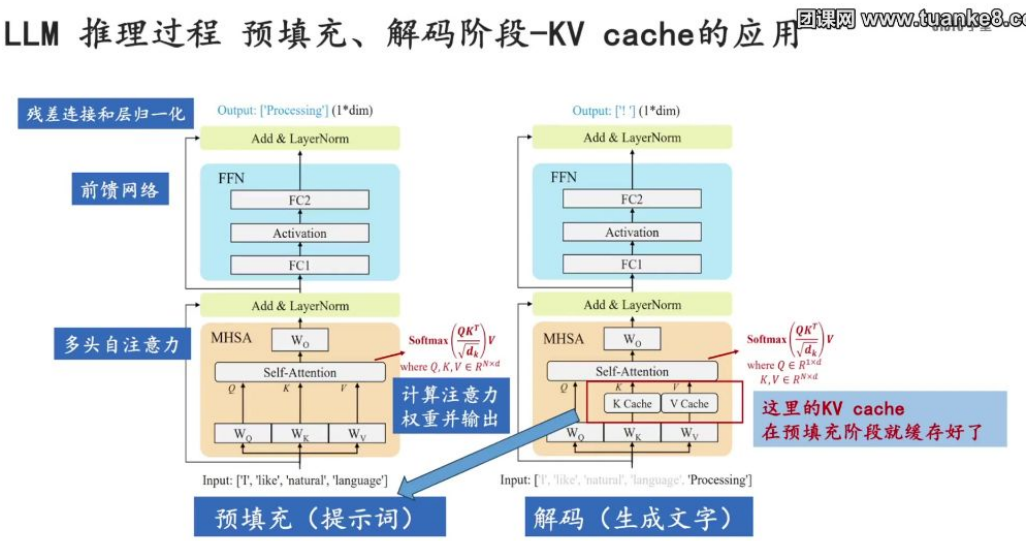
一、预填充阶段和解码阶段 00:34

- **核心区别**：预填充阶段处理提示词输入，解码阶段逐步生成输出文本，两者对算力和显存需求不同
- **工作流程**：预填充→首次输出→解码（自回归）→循环生成，形成完整文本生成链条

1. 预填充阶段示意图 00:41

- **输入处理**：以"I like natural language"为例，每个词生成Q,K,V三个向量
- **计算过程**：
  - **注意力机制**：使用公式$softmax(\frac{QK^T}{\sqrt{d_k}})V$计算权重
  - **层级处理**：依次经过多头自注意力(MHSA)→前馈网络(FFN)→残差连接&层归一化
- **输出特征**：最终得到首个输出标记"Processing"，此时完成提示词的特征提取
- **关键设计**：
  - **向量运算**：每个词的Q需与所有词的K,V进行运算（如"I"的Q与"like/natural/language"的K,V）
  - **缓存机制**：此阶段计算的K,V向量会被暂存，为解码阶段提供基础数据

2. 解码阶段示意图 01:58



-
- **输入构成**：组合预填充内容与已生成输出（如"I like natural language Processing"）
- **核心优化**：
  - **KV缓存**：复用预填充阶段计算的K,V向量，避免重复计算
  - **增量计算**：仅需计算新生成词（如"Processing"）的Q向量
- **生成流程**：
  - 通过相同注意力公式计算新词权重
  - 经FFN网络处理得到输出（如"!"）
  - 将新输出追加至输入序列，循环生成后续内容
- **技术要点**：
  - **自回归特性**：每个生成步骤依赖前序所有输出，形成序列依赖
  - **效率对比**：解码阶段计算量显著低于预填充阶段，因利用KV缓存避免全量计算

二、知识小结

知识点	核心内容	考试重点/易混淆点	难度系数

预填充阶段与解码阶段	大语言模型推理的两个关键阶段，对算力和显存需求不同	**阶段差异**：预填充处理提示词，解码生成答案	★★
Transformer架构拆解	通过注意力机制（QKV向量）、多头自注意力、前馈神经网络逐步计算输出	**注意力权重公式**：softmax(QK^T/√d_k)V	★★★
预填充阶段流程	输入提示词（如"I like natural language"）→ 生成首个词（如"processing"）	**输入输出关系**：仅依赖初始提示词	★★
解码阶段流程	输入=预填充输入+已生成词（自回归）→ 通过KV缓存加速生成后续词	**KV缓存机制**：空间换时间，避免重复计算	★★★★
QKV向量作用	Q（查询）、K（键）、V（值）共同计算注意力权重，**预填充和解码均需**	**易混淆点**：解码阶段仅缓存KV，Q仍需实时计算	★★★
KV缓存优化	缓存历史词的K/V向量，减少重复运算（如"I like..."的K/V被复用）	**技术难点**：显存管理与缓存更新策略	★★★★