以下为AI生成的图文笔记的内容

一、大语言模型的内存占用 00:16

1. GPU存储 00:21

- **组成结构**: GPU存储主要由三部分组成：大模型自身参数占用的内存、KV Cache占用的内存以及其他运算过程中产生的临时内存（包括数据搬移、迁移、转化等）。
- **优化方向**: 降低模型参数大小可提高推理效率，但需权衡模型精度，需要在模型大小和输出质量之间取得平衡。

2. 变量 02:57

- **当前序列长度(n)**: 即输入提示词的token数量，例如100个token的请求长度为100。序列越长，消耗的token数越多。
- **模型层数(l)**: 神经网络中隐层的数量，例如32层。层数越多模型体积越大。
- **批处理大小(b)**: 单批次处理的请求数量，例如批次为1时处理1000token，批次为10时可处理10000token。
- **注意力头数量(h)**: Transformer架构中多头注意力机制的头数，例如32头。每增加一个头就会多一份参数。
- **头维度(dk)**: 每个注意力头的向量维度，例如128维。维度越高表示向量表达能力越强（GPT-3达12888维）。
- **元素精度(p)**: 参数的数据类型和位宽，例如float16表示16位浮点数（占2字节）。精度越高模型越"聪明"。
- **KV因子(2)**: 表示每个token需要存储Key和Value两组向量。

3. 公式 06:51



- **计算公式**: 内存占用(字节)=$2 \times l \times b \times n \times dk \times p$
- **示例计算**: 当$l = 32, b = 1, n = 1000, dk = 128, p = 2$时，计算结果为524,288,000字节（约500MB）
- **规模影响**: 长上下文场景（如n=128,000）或大批次（如b=32）时，内存需求会线性爆炸式增长
- **实际对比**: 主流大模型（如GPT-3）实际占用可达数百GB，需要多张高端显卡（如A100/H100）支撑

二、结束 **08:30**

三、知识小结

知识点	核心内容	考试重点/易混淆点	难度系数
KV Cache 的作用	KV Cache 是 Transformer 模型架构中的核心优化技术，用于缓存键值对，减少重复计算，提升推理效率。	KV Cache 的内存占用与序列长度、批次大小相关，需注意其与模型参数的存储关系。	★★★
大模型内存占用组成	GPU 内存占用 = **模型参数内存 + KV Cache 内存 + 其他推理过程内存**（如数据搬移、转换等）。	模型参数内存是固定占用，KV Cache 内存随输入动态变化。	★★★★
模型参数内存计算	由 **序列长度、模型层数、批处理大小、注意力头数量、头维度、参数精度（如 FP16/INT8）、KV Cache 因子（2）** 共同决定。	公式示例：2 × 32（头数） × 1（批次） × 32（层数） × 1000（序列长度） × 128（维度） × 2（精度） ≈ 500MB。	★★★★★
模型优化方向	**降精度（如 FP16→INT8/INT4）、减少层数/头数、压缩序列长度**，需权衡精度损失与推理效率。	降精度可能影响模型输出质量，需实验验证。	★★★★
硬件资源需求	大模型（如 GPT-3）需 **高端 GPU（如 A100/H100）** 支持，因参数规模达数百 GB，KV Cache 进一步增加内存压力。	实际部署需计算显存容量与模型参数的匹配性。	★★★★★
推理效率关键指标	**吞吐量**（批次处理能力）、**首次生成延迟**（受序列长度影响）、**显存利用率**（优化 KV Cache 可提升）。	需平衡吞吐量与延迟，避免显存溢出。	★★★★