以下为AI生成的图文笔记的内容

一、大模型推理优化 00:02

- **参数量化**：将KV向量以INT4/INT8等低精度格式存储，显著减少显存占用。例如FP32转INT8可降低75%存储空间。
- **运行时加速**：通过优化KV缓存体积和访问效率提升推理速度，需额外计算资源支持。
- **IO优化**：减少GPU高速缓存(SRAM)与高带宽内存(HBM)间的数据读写次数。

1. KV缓存优化 00:31

- **核心作用**：在decoder生成新token时，缓存历史KV向量用于注意力计算。
- **优化方向**：
  - **体积压缩**：采用低精度存储（如INT4量化）
  - **访问效率**：优化缓存命中率，减少显存带宽压力
- **典型收益**：可降低30-50%的内存占用。

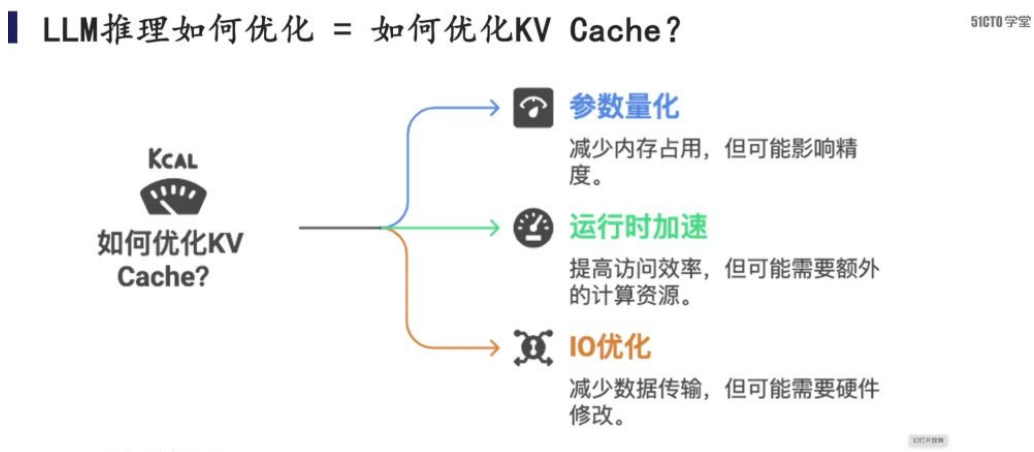
2. 参数量化 01:31

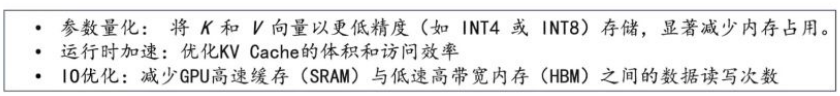
- **精度等级**：
  - 高精度：FP64/FP32（计算精度高但占用大）
  - 低精度：INT8/INT4（节省显存但可能损失精度）
- **实现方法**：
  - 线性量化：$x_{quant} = round(x / \Delta)$
  - 非线性量化：适应参数分布
- **权衡因素**：需平衡内存节省与模型精度损失。

3. 运行时加速 01:57

- **关键技术**：
  - **预取机制**：提前加载后续计算所需数据
  - **并行计算**：利用GPU多流处理器并发执行
- **效果指标**：可提升20-40%的token生成速度。

4. IO优化 02:58





- **优化策略**：
  - **数据局部性**：尽量在SM流式处理器内完成计算
  - **批处理**：合并小IO操作减少传输次数
- **瓶颈分析**：避免显存与计算单元间的数据拥堵。

二、知识小结

知识点	核心内容	技术要点	优化方向
大模型推理阶段划分	通过大圆模型推理分阶段进行	阶段间KV缓存的重要性	参数优化/运行时加速/IO优化
显存占用因素	包含模型参数和KV缓存空间	参数精度影响（int4/int8/fp16/fp32/fp64）	**参数量化**降低内存占用
参数量化技术	高精度参数转低精度（如fp32→int8）	减少显存占用和传输耗时	精度与性能的平衡
运行时加速	优化KV缓存体积和访问效率	Transformer解码过程的KV向量运算	减少重复计算提升生成速度
IO传输优化	CPU指令与GPU运算单元数据交互	显存→流式多处理器数据传输	**降低IO消耗**避免缓存频繁占用
三维优化体系	参数/运行时/IO协同优化	模型压缩算法与硬件资源调配	端到端推理加速方案