以下为AI生成的图文笔记的内容

一、大模型的性能指标 00:16

- **评估维度**：从用户感知和系统能力两个层面建立完整评估体系
- **优化验证**：性能指标是验证模型优化效果的"尺子"，需在量化/压缩后重点监测

1. 首词生成时间 00:42

- **阶段定位**：发生在预填充阶段(pre-fill phase)的核心指标
- **用户感知**：反映用户提问后收到首个响应token的等待时长
- **技术影响**：受模型初始化、上下文处理等预处理环节效率影响

2. 每次生成时间

- **阶段定位**：解码阶段(decoding phase)的关键指标
- **计算方式**：每个输出token的平均生成耗时
- **特殊说明**：与首词生成时间共同构成完整的用户端延迟体验

3. 端到端请求时间 01:01

- **完整定义**：从用户提问开始到获得满意答案的全流程耗时
- **组成要素**：
  - 首词生成时间
  - 后续token持续生成时间
  - 网络传输等系统开销
- **业务价值**：直接决定最终用户体验质量

4. 系统推理评测 01:14

- **评估视角**：从单用户扩展到高并发场景的系统能力评估
- **核心指标**：
  - **吞吐量**：每秒处理的token数量(TPS)
  - **并发能力**：同时服务的有效用户请求数

1）业务水平目标 01:49

- **必要性**：系统需满足特定业务场景的SLA要求
- **案例说明**：客服系统需保证5秒内响应率>95%
- **评估维度**：
  - 响应延迟分布
  - 错误率阈值
  - 高峰时段降级策略

5. LLM推理基准测试 02:08

- **工具类型**：
  - 延迟测量工具(如Latency Profiler)
  - 压力测试工具(如Locust)
  - 行业标准测试集(如HELM)
- **实施建议**：需组合使用多种工具进行多维评估

6. 平台参数 02:20

- **参考价值**：主流硬件平台(GPU/TPU)的性能基准数据
- **典型参数**：
  - 单卡推理吞吐量
  - 显存利用率
  - 批处理效率
- **应用场景**：用于基础设施选型和容量规划

二、知识小结

知识点	核心内容	考试重点/易混淆点	难度系数
大语言模型推理的基本概念	介绍如何评判或判断大模型优化的痛点与重要方面	优化痛点的具体表现	★★
大模型性能指标	性能指标的作用（如衡量模型优化效果）	**手持生成时间**（预填充阶段） vs **每次生成时间**（解码阶段）	★★★
端到端请求时间	用户提问到接收满意答案的总时间	与单阶段时间的区别	★★
系统级推理评测	多并发场景下的吞吐量（如每秒token数）与业务水平达标评估	客服系统等业务属性的适配性	★★★★
基准评测方法与工具	推荐市面流行的评测方法和工具	工具选择与实际需求的匹配	★★★
平台参数参考	搭建平台或实现能力的参数范围（如并发量、延迟等）	参数对性能的影响	★★★★