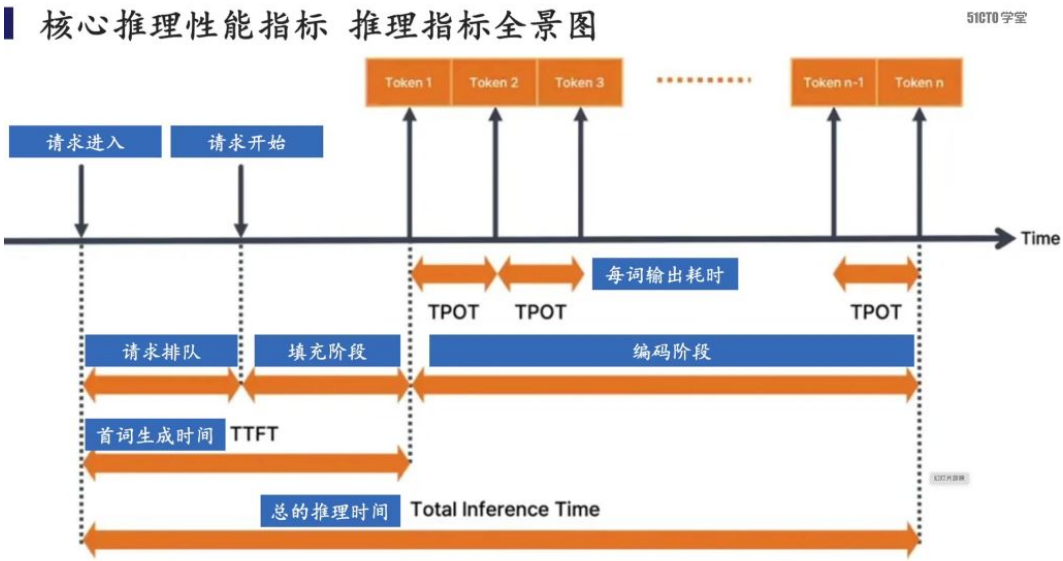
以下为AI生成的图文笔记的内容

一、推理评估指标全景图 00:06



- **端到端指标**：从用户提出问题到获得最终答案的全过程中，需要关注多个性能指标，这些指标共同构成大模型推理性能的评估体系。

1. 推理过程阶段 00:26

- **阶段划分**：大模型推理过程可分为请求进入、请求排队、填充阶段、编码阶段四个主要阶段，最终形成总推理时间。

2. 推理阶段细分 00:53

1）请求进入 00:56

- **触发机制**：当用户向大模型提出问题或发出指令时，系统开始处理该请求，标志着推理过程的开始。

2）请求排队 01:06

- **并发控制**：系统会根据预设的并发量（如20或10个并发）评估当前负载，超出并发限制的请求将进入排队状态。
- **实际场景**：类似DeepSeek或GPT等热门模型在访问量大时会启动保护机制，通过队列管理超量请求。

3）填充阶段 01:23

- **预处理工作**：在正式生成内容前，系统需要完成必要的准备工作，为后续的token生成奠定基础。

4）等待时间 01:47

- **TTFT扩展**：首次生成时间(TTFT)在实际评估中需要包含请求排队阶段的等待时间，这是真实场景中不可避免的延迟。
- **评测方法**：专业评测会通过设置超出系统并发的请求量来测试这一指标。

5）编码阶段 03:03

- **自回归特性**：主流模型（如GPT、DeepSeek）采用Transformer架构，每个token的生成都依赖前面已生成的token内容。
- **TPOT指标**：
  - 定义：每个token的生成耗时(Time Per Output Token)
  - 趋势：随着生成位置的后移，耗时通常会增加
  - 统计方法：评估时采用平均值，也会考察25%、90%、99%等百分位数值

6）总的推理时间 04:22

- **用户体验指标**：从请求开始到获得全部token输出的总耗时，包含：
  - 排队等待时间
  - 首token生成时间
  - 所有后续token生成时间
- **关键组成**：该指标直接决定用户感知的响应速度，是系统性能的综合体现。

二、知识小结

阶段名称	核心指标	技术要点	典型场景案例
请求进入	用户请求响应率	问题输入接口设计	GPT模型高峰时段请求
请求排队	系统并发量	并发控制算法	DeepSeek请求队列管理
预填充阶段	TTFT(首Token生成时间)	KV缓存机制	**超过20并发时的延迟**
编码阶段	单Token生成耗时	自回归解码	Transformer架构特性
总推理过程	Total Inference Time	端到端延迟统计	包含排队+生成全流程
性能评估	P99/P90分位值	负载测试方法论	多并发压力测试场景