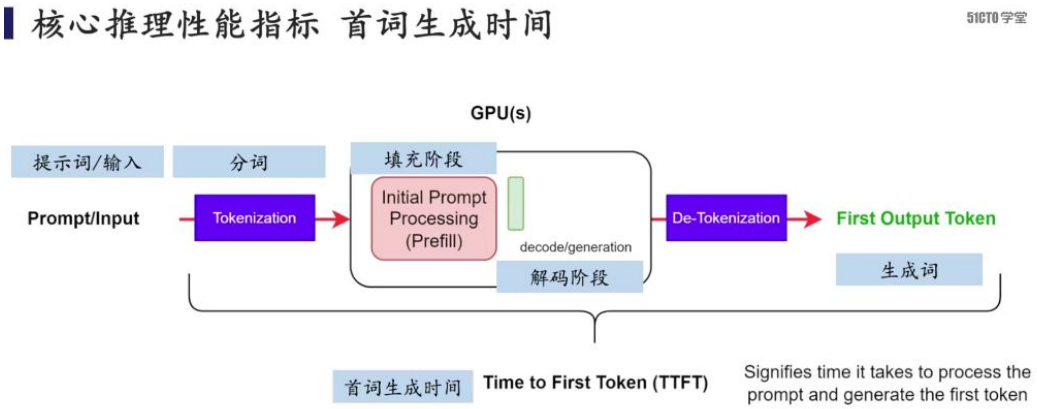
以下为AI生成的图文笔记的内容

一、首词生成时间 **00:00**



- TTFT 通常包括请求排队时间、预填充时间和网络延迟。提示时间越长，TTFT 就越大。
- 注意力机制需要整个输入序列来计算和创建所谓的 key-value (KV) 缓存，从该点开始迭代生成循环。
- 生产应用可能有多个请求正在进行中，因此一个请求的预填充阶段可能会与另一个请求的生成阶段重叠。

●

1. 提示词/输入分词填充阶段 00:18

- **输入来源**: 可能是用户提示词输入，也可能是系统预设指令的输入
- **分词机制**: 基于不同模型对token的索引(index)系统，将输入内容转换为模型可理解的向量表示，类似字典索引功能
- **填充阶段核心任务**: 通过Transformer架构计算生成第一个输出token。具体过程包括:
  - 通过k、q、v三个矩阵的计算
  - 经过softmax和多头注意力机制处理
  - 输出注意力权重参数用于生成首词
- **TTFT组成要素**:
  - 请求排队时间
  - 预填充时间
  - 网络延迟
  - 提示词越长，TTFT越大
- **KV缓存机制**: 输入序列会被缓存为key-value(KV)缓存，用于后续迭代生成循环。例如"今天是星期几"的token序列会被缓存用于后续decode阶段的词生成

2. 解码阶段 01:52

- **处理流程**:
  - 接收预填充阶段的输出
  - 进行反分词(De-Tokenization)处理
  - 组合生成最终的首词(First Output Token)
- **并行处理特性**: 在生产环境中，多个请求可能同时处理，导致一个请求的预填充阶段与另一个请求的生成阶段可能重叠
- **迭代生成原理**: 每个decode阶段生成的词都会依赖预填充阶段缓存的提示词内容，通过KV缓存实现持续迭代生成

二、知识小结

知识点	核心内容	技术要点	关键指标
大模型推理阶段划分	手持生成时间(TTFT)的组成要素	预填充阶段→解码阶段→分词重组	**排队时间/网络延迟**

分词处理机制	输入内容的tokenization过程	字典索引→向量映射	**模型认知方式**
注意力机制	KV缓存与序列生成关系	Transformer架构的QKV矩阵运算	**多头注意力权重**
并行请求处理	多用户请求的时序重叠	预填充与生成阶段并发	**系统吞吐量瓶颈**
生成迭代过程	首词生成(first output token)原理	解码阶段动态分词重组	**TTFT关键路径**