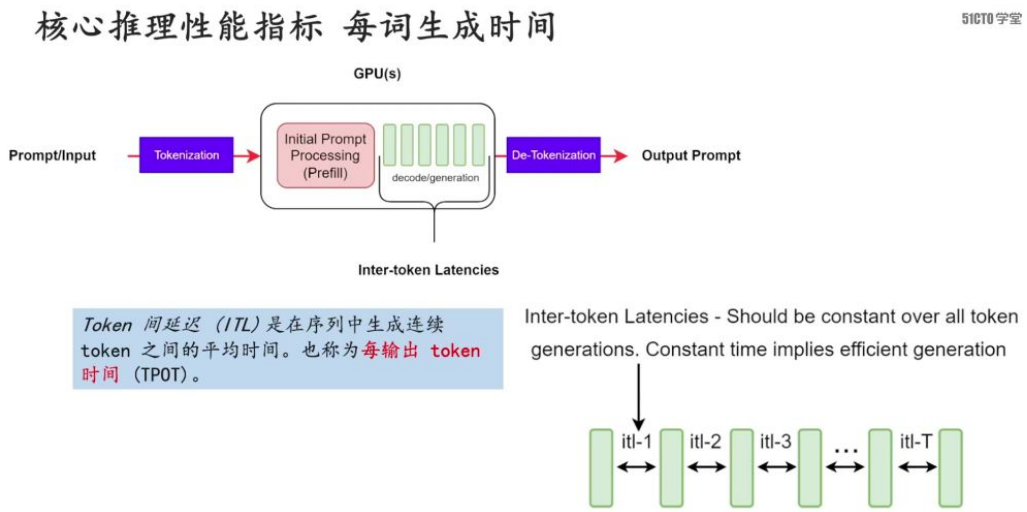
以下为AI生成的图文笔记的内容

## 一、每词生成时间 **00:06**

- **定义**：Token间延迟(ITL)是在序列中生成连续token之间的平均时间，也称为每输出token时间(TPOT)
- **计算阶段**：特指解码/生成阶段，不包括预填充阶段

1. 图解每词生成时间 00:14




- 
- **生成机制**：
  - 每个token生成时需与之前所有token序列进行QKV计算
  - 依赖KV缓存机制加速计算过程
  - 最终输出注意力权重参数（关键计算输出）

2. 每词生成时间的注意点 01:15

- **时间差异**：
  - 不同token生成时间存在差异
  - 序列越长，后续token生成时间越长（需计算更多历史token的K/V向量）
- **平均特性**：
  - ITL/TPOT是序列中所有token生成时间的平均值
  - 实际应用中需考虑序列长度对延迟的影响
- **核心矛盾**：
  - 生成质量要求更长的上下文窗口
  - 但上下文窗口增长会显著增加末端token的生成延迟

## 二、知识小结

| 主题 | 核心概念 | 关键指标 | 技术要点 | 性能特征 |
| --- | --- | --- | --- | --- |
| 生成式AI推理 | **核心推理性能指标** | 首持生成时间 | 填充阶段(prime/in)处理 | 初始生成延迟 |
| | **美持生成时间** | 每个token生成耗时 | decode阶段逐字生成 | **KV缓存计算** |
| | 注意力机制 | QKV权重参数计算 | 依赖前序token序列 | 动态计算复杂度 |

| | | | | |
|---|---|---|---|---|
| | 生成时间特性 | 平均token延迟 | **序列长度正相关** | 末token耗时最长 |
| | 性能评估标准 | 综合平均时间 | 全序列时间平均 | 基准测试指标 |