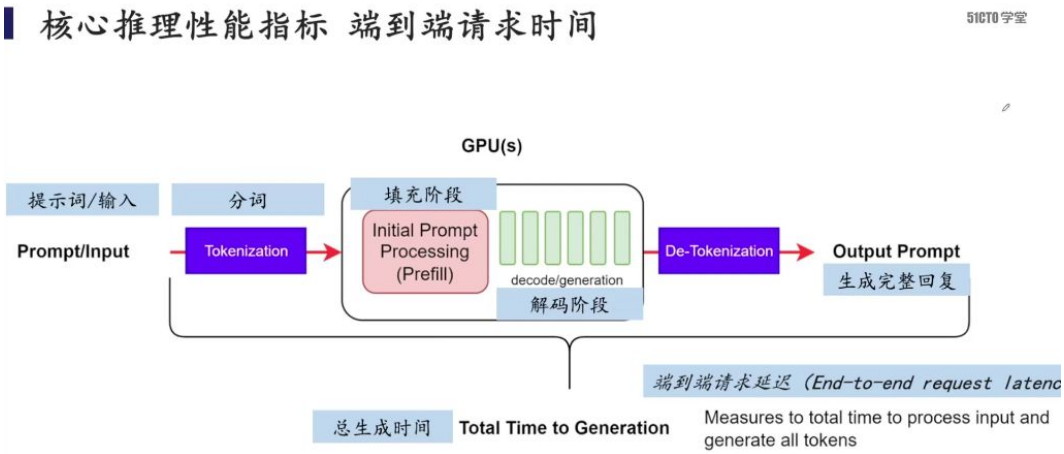
以下为AI生成的图文笔记的内容

一、端到端的请求时间 00:05

- **完整处理阶段**:　从提示词输入开始，经过分词、预填充阶段(Prefill)、解码/生成阶段(Decode/Generation)，直到输出完整回复的全过程时间
- **用户视角指标**:　用户从提交查询到接收完整响应所感知的总时间，是衡量大模型用户体验的核心商业指标
- **包含要素**:
  - 首次生成时间(TTFT)
  - 每次生成时间的总和(generation_time)
  - 排队等待时间
  - 网络传输延迟
  - 批处理等待时间

1. 端到端请求延迟公式 01:11



- *端到端请求延迟（e2e_latency）表示从提交查询到接收完整响应所需的时间，包括排队和批处理的时间以及网络延迟*

$$e2e_latency = TTFT + generation_time$$

- **基础公式**:$e2e_latency = TTFT + generation_time$
- **扩展要素**:
  - **推理模型特性**:　如GPT-5等需要深度思考的模型，还需包含任务规划、拆解、执行、反思的"思考时间"
  - **用户体验阈值**:
    - 首次响应时间影响用户对系统"正在工作"的感知
    - 总生成时间需控制在用户心理预期范围内
- **优化方向**:
  - 降低TTFT可使用户快速获得初步反馈
  - 减少generation_time总和能提升整体响应效率
  - 系统级优化需考虑并发处理、网络传输等全链路因素

二、知识小结

知识点	核心内容	易混淆点	难度系数
端到端请求时间	从输入提示词到完整输出的总耗时，含首次生成时间（TTFT）和每次生成时间（Generation Time）	与“手持/美持生成时间”概念区分	★★

首次生成时间（TTFT）	用户输入后首次出现文字/数字输出的延迟	不包含后续生成时间	★★
Generation Time	每次token生成的时间总和	需与排队、网络等时间区分	★★
端到端延迟公式	**TTFT + Generation Time**（严格场景需增加排队、网络等时间）	是否包含非计算耗时（如网络延迟）	★★★
用户体验指标	以TOC视角衡量，首次输出快慢影响用户感知	推理模型需额外考虑“思考时间”	★★
推理模型特殊性	如GPT-5需规划/拆解任务，增加思考时间	与通用生成模型的延迟标准差异	★★★★