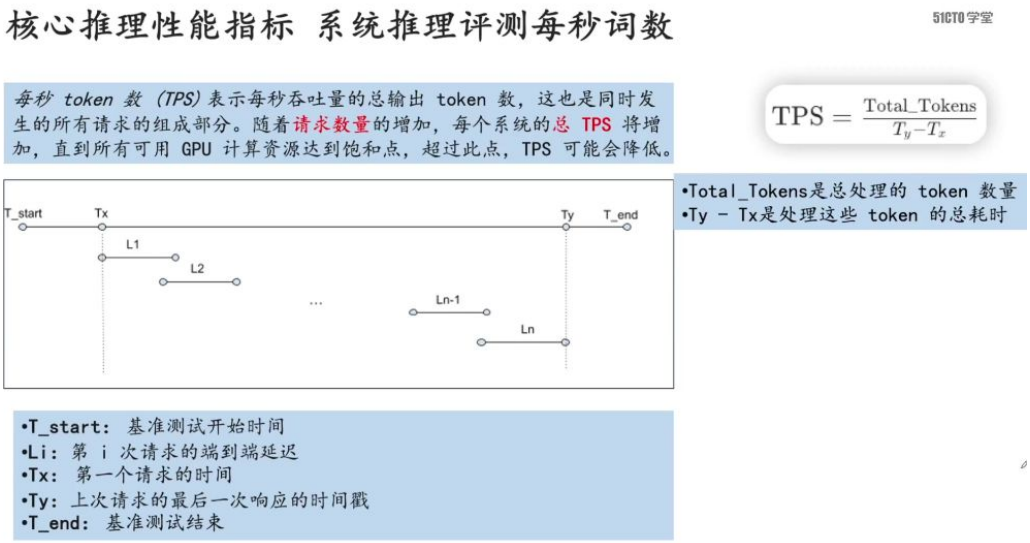
以下为AI生成的图文笔记的内容

一、系统吞吐量 00:23



-
- **定义**：每秒处理的token数(TPS)是衡量大模型推理系统性能的核心指标
- **计算公式**：$\text{TPS} = \frac{\text{Total Tokens}}{T_y - T_x}$
  - **Total Tokens**：测试期间处理的所有token总数
  - **Ty-Tx**：从第一个请求开始(tx)到最后一个请求结束(ty)的时间差

1. 系统性能分析 00:41

- **性能曲线**：
  - **上升阶段**：随着请求量增加，TPS线性增长
  - **饱和点**：当GPU计算资源达到极限时出现峰值
  - **下降阶段**：超过饱和点后TPS会降低
- **影响因素**：
  - **硬件层面**：内存→显存→流式多处理器的数据传输瓶颈
  - **软件层面**：KV缓存容量限制导致处理延迟增加

2. 测试参数说明 03:16

- **测试时间轴**：
  - **t_start**：基准测试开始时间
  - **t_end**：测试结束时间
- **请求特征**：
  - **L1-Ln**：模拟n个用户并发的请求流
  - **延迟组成**：首词生成时间+每词生成时间=端到端延迟
- **测试方法**：
  - 通过工具模拟多线程并发请求
  - 记录绝对时间差和总处理token数
- **关键记忆点**：
  - 系统吞吐量反映的是服务端处理能力，不同于用户感知的延迟
  - 饱和点的确定需要测试不同并发量下的TPS变化曲线
  - 当显存数据过多时，会出现"水桶效应"导致性能下降

二、知识小结

知识点	核心内容	考试重点/易混淆点	难度系数
大模型推理性能指标（用户角度）	首词生成时间、每词生成时间、端到端生成时间（用户体验维度）	区分**端到端时间**（首词+每词生成时间）与单一指标	★★
系统吞吐量（TPS）	**每秒处理的token数**，计算公式：总token数/(t_end - t_start)	**饱和点现象**：超过临界值后TPS下降（显存/KV缓存瓶颈）	★★★
性能测试方法	多线程并发请求模拟，记录L1-Ln端到端延迟时间	并行/串行请求对测试结果的影响	★★
系统瓶颈原理	显存-内存数据传输延迟、KV缓存压力导致性能衰减	**硬件层面**与**算法层面**的关联分析	★★★★