以下为AI生成的图文笔记的内容

## 一、根据业务指标确定指标 00:21

1. 业务水平目标设定

1）图表分析 01:51




- **SLO定义**：端到端延迟≤2秒（2000ms），适用于7B参数模型的AI客服LLM推理服务场景
- **测试条件**：假设输入tokens=200，输出tokens=500，使用单张A100显卡
- **关键参数**：
  - 横轴：端到端延迟（ms）
  - 纵轴：吞吐量（TPS）
  - 曲线特征点：标注不同并发数(N)下的延迟和吞吐量表现
- **性能拐点**：
  - N=1：延迟2187ms，TPS 620（低并发，资源未充分利用）
  - N=2：延迟1905ms，TPS 630（临界过渡阶段）
  - N=4：延迟1980ms，TPS 1210（最佳操作点）
  - N≥6：延迟均超过2000ms（过饱和状态）

2）业务场景设定举例 05:12

- **低延迟应用**：
  - **典型场景**：实时交互（如聊天机器人）
  - **优化重点**：限制并发请求数量，降低TTFT（首token生成时间）和TPOT（每token生成时间）
  - **实现方式**：选择最佳并发数（本案例中N=4），确保延迟≤2000ms
- **高吞吐量应用**：
  - **典型场景**：批处理任务（如报表生成）
  - **优化重点**：最大化系统处理能力，允许牺牲单请求延迟
  - **实现方式**：将并发请求拉满，追求高TPS（本案例中最高可达2410 TPS）
- **端到端延迟构成**：
  - 首token生成时间
  - 解码阶段各token生成时间总和
  - 网络传输时间
  - 排队等待时间

- **选择依据**：
  - 在满足SLO（≤2000ms）的前提下，选择吞吐量最大的操作点
  - 本案例最佳选择：N=4时延迟1980ms，TPS 1210

## 二、知识小结

| 知识点 | 核心内容 | 考试重点/易混淆点 | 难度系数 |
| --- | --- | --- | --- |
| **业务指标定义（SLO）** | 从业务角度定义性能指标（如客服机器人响应延迟≤2000ms），需结合用户输入（200词）和输出（500词）的测试条件 | **端到端延迟的组成**（首token生成+解码时间+网络/排队时间） | ★★ |
| **性能测试数据分析** | 并发量=4时满足SLO（延迟1980ms，吞吐量1210 tokens/s），超过则超标；**最佳并发量选择逻辑**（延迟达标且吞吐量最大化） | **并发量与吞吐量的权衡**（高并发可能突破延迟阈值） | ★★★ |
| **业务场景分类** | **低延迟应用**（如聊天：优先控制延迟） vs **高吞吐应用**（如报表生成：优先拉满TPS） | **SLO的差异化设计**（延迟敏感型 vs 吞吐敏感型） | ★★ |
| **可视化分析** | 通过坐标图展示延迟（横轴）与吞吐量（纵轴）关系，**红标线（2000ms）**划分达标区域 | **图表解读要点**（选择左上方最优数据点） | ★ |