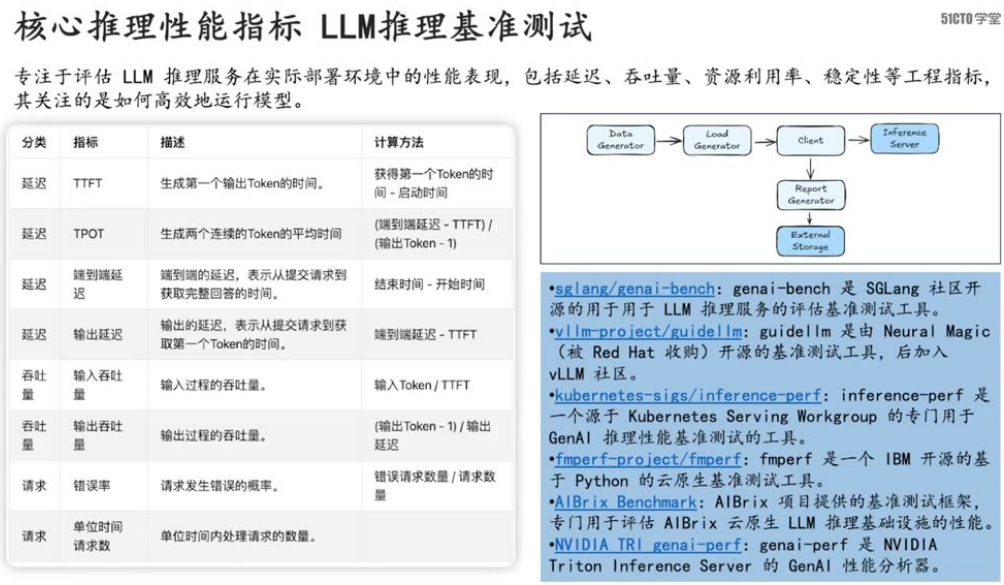
以下为AI生成的图文笔记的内容

一、核心推理性能指标 **00:00**

1. 推理基准测试 00:13

1）指标汇总 00:15



核心推理性能指标 LLM推理基准测试

51CTO学堂

专注于评估 LLM 推理服务在实际部署环境中的性能表现，包括延迟、吞吐量、资源利用率、稳定性等工程指标，其关注的是如何高效地运行模型。

分类	指标	描述	计算方法
延迟	TTFT	生成第一个输出Token的时间。	获得第一个Token的时间 - 启动时间
延迟	TPOT	生成两个连续的Token的平均时间	(端到端延迟 - TTFT) / (输出Token - 1)
延迟	端到端延迟	端到端的延迟，表示从提交请求到获取完整回答的时间。	结束时间 - 开始时间
延迟	输出延迟	输出的延迟，表示从提交请求到获取第一个Token的时间。	端到端延迟 - TTFT
吞吐量	输入吞吐量	输入过程的吞吐量。	输入Token / TTFT
吞吐量	输出吞吐量	输出过程的吞吐量。	(输出Token - 1) / 输出延迟
请求	错误率	请求发生错误的概率。	错误请求数量 / 请求数量
请求	单位时间请求数	单位时间内处理请求的数量。	

- sglang/genai-bench: genai-bench 是 SGLang 社区开源的用于用于 LLM 推理服务的评估基准测试工具。
- vllm-project/guidellm: guidellm 是由 Neural Magic（被 Red Hat 收购）开源的基准测试工具，后加入 vLLM 社区。
- kubernetes-sigs/inference-perf: inference-perf 是一个源于 Kubernetes Serving Workgroup 的专门用于 GenAI 推理性能基准测试的工具。
- fmperf-project/fmperf: fmperf 是一个 IBM 开源的基于 Python 的云原生基准测试工具。
- AIBrix Benchmark: AIBrix 项目提供的基准测试框架，专门用于评估 AIBrix 云原生 LLM 推理基础设施的性能。
- NVIDIA TRI genai-perf: genai-perf 是 NVIDIA Triton Inference Server 的 GenAI 性能分析器。

- **TTFT(首Token时间)**：用户输入提示词后生成第一个输出Token的时间，计算公式为：获得第一个Token的时间 - 启动时间
- **TPOT(每Token时间)**：　生成两个连续Token的平均时间，计算公式为：(端到端延迟 - $TTFT$) / (输出$Token$ - 1)
- **端到端延迟**: 从提交请求到获取完整回答的总时间，计算公式为：结束时间 - 开始时间
- **输出延迟**: 从提交请求到获取第一个Token的时间，计算公式为：端到端延迟 - TTFT
- **输入吞吐量**: 输入过程的处理效率，计算公式为：输入$Token$ / $TTFT$
- **输出吞吐量**: 输出过程的处理效率，计算公式为：(输出$Token$ - 1) / 输出延迟
- **错误率**: 请求发生错误的概率，计算公式为：错误请求数量 / 请求数量，对金融、政府等机密系统尤为重要
- **单位时间请求数**: 系统整体处理能力指标，反映单位时间内处理的请求数量

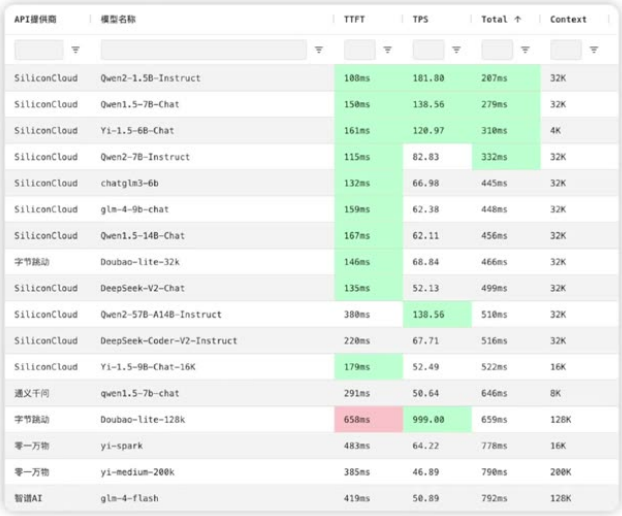
2）评测过程 02:21

- **测试数据生成**:
  - 使用工具生成测试数据
  - 定义请求长度(序列长度)：根据业务需求确定，问答系统通常2000-5000　token，上下文搜索系统可达几百K
  - 定义批次/并发数：模型单次处理的批量请求数(10/20/100等)
- **数据加载与处理**:
  - 加载过程中需进行格式转换和数据清理
- **客户端模拟**:
  - 使用工具生成客户端模拟多用户并发请求
  - 客户端向推理服务器发送Token请求
- **结果收集**:
  - 推理服务器返回output token和最终答案
  - 通过报表生成器产生性能指标报表
  - 导出并存储测试结果

3）评测工具 05:06

核心推理性能指标 平台参数

51CTO学堂



API提供商	模型名称	TTFT	TPS	Total ↑	Context
SiliconCloud	Qwen2-1.5B-Instruct	108ms	181.80	207ms	32K
SiliconCloud	Qwen1.5-7B-Chat	150ms	138.56	279ms	32K
SiliconCloud	Yi-1.5-6B-Chat	161ms	120.97	310ms	4K
SiliconCloud	Qwen2-7B-Instruct	115ms	82.83	332ms	32K
SiliconCloud	chatglm3-6b	132ms	66.98	445ms	32K
SiliconCloud	glm-4-9b-chat	159ms	62.38	448ms	32K
SiliconCloud	Qwen1.5-14B-Chat	167ms	62.11	456ms	32K
字节跳动	Doubao-lite-32k	146ms	68.84	466ms	32K
SiliconCloud	DeepSeek-V2-Chat	135ms	52.13	499ms	32K
SiliconCloud	Qwen2-57B-A14B-Instruct	380ms	138.56	510ms	32K
SiliconCloud	DeepSeek-Coder-V2-Instruct	220ms	67.71	516ms	32K
SiliconCloud	Yi-1.5-9B-Chat-16K	179ms	52.49	522ms	16K
通义千问	qwen1.5-7b-chat	291ms	50.64	646ms	8K
字节跳动	Doubao-lite-128k	658ms	999.00	659ms	128K
零一万物	yi-spark	483ms	64.22	778ms	16K
零一万物	yi-medium-200k	385ms	46.89	790ms	200K
智谱AI	glm-4-flash	419ms	50.89	792ms	128K

- **Generation AI Bench**: SGLong社区开源工具
- **vLLM Project的at LLM**: 原由NeuroMetric开源，后加入vLLM社区，擅长分布式推理和量化
- **KubeBlitz Science Inference Perform**: 基于KubeBlitz Serving Workgroup的测试工具
- **FM Prom**: IBM开源测试框架
- **IM Breaks Fix Benchmark**: 基准测试框架
- **平台性能参数示例**:
  - Qwen2-1.5B-Instruct: TTFT=108ms, TPS=181.80 token/s
  - Qwen1.5-7B-Chat: TTFT=150ms, 模型增大后性能下降明显
  - 模型参数与性能关系：14B模型TTFT升至167ms，吞吐量降低至62.11 token/s
  - 上下文长度差异：从4K(Qwen1.5-6B)到128K(Doubao-lite)不等

二、知识小结

知识点	核心内容	考试重点/易混淆点	难度系数
大语言模型性能指标	用户角度指标：首次生成时间（TTFT）、每词生成时间（TPOT）、端到端延迟；系统角度指标：吞吐量（输入/输出token总量）、错误率、单位时间请求数	**延迟指标计算关系**：输出延迟=端到端延迟-TTFT；吞吐量公式计算	★★★
测试数据生成	定义请求长度（token数）、批次/并发数；根据业务需求调整（如问答系统2000-5000token，上下文搜索可达数百K）	**关键参数影响**：模型承载上限、业务场景差异	★★
基准测试流程	1. 生成测试数据 → 2. 加载与清理数据 → 3. 客户端模拟请求 → 4. 推理服务器响应 → 5. 生成性能报表	**工具链依赖**：客户端模拟多用户并发请求	★★★★
开源测试工具	Generation AI Bench（SG Long）、vLLM Project的atLLM、KubeBlitz Science I	**工具特性对比**：vLLM专注分布式推	★★★

	Inference、FM Prom（IBM）、ImBreaks Fix Benchmark	理与量化能力	
厂商性能对比	**硅基流动Cloud示例**：TTFT=108ms、TPS=181token/s；**模型参数影响**：1.5B→7B→14B时延迟递增（167ms）、吞吐量递减	**关键变量**：并发数、上下文长度、模型精度	★★★★