一、LLM推理性能指标与评估 00:00

1. 推理指标全景图 00:16

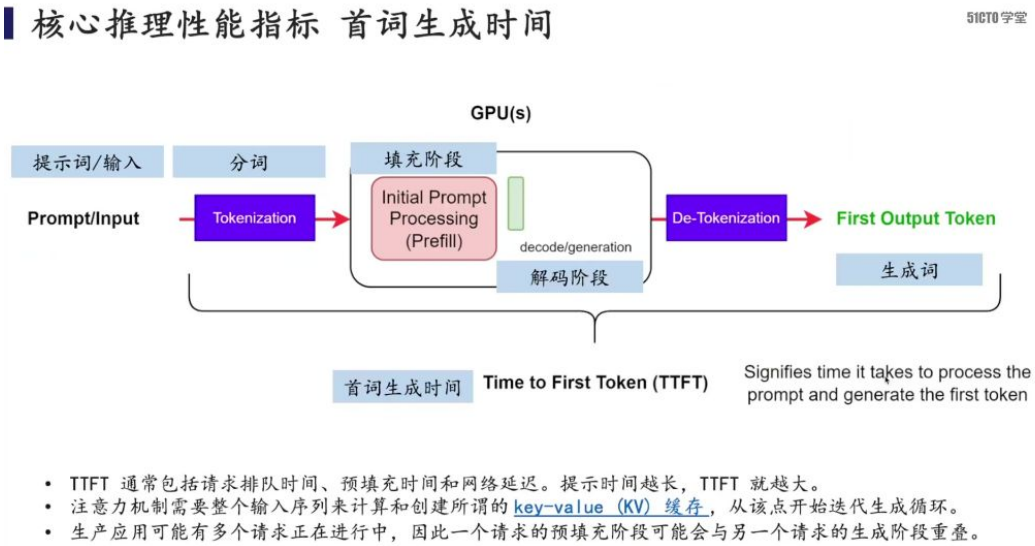


- **阶段划分**：从用户请求到最终结果需要经历填充阶段（Prefill）和解码阶段（Decoder）
- **时间构成**：包含请求排队时间、网络延迟时间以及各阶段的处理时间
- **关键指标关系**：端到端时间=首词生成时间+解码阶段每词耗时×生成词数

1）解码阶段 00:35

- **处理特征**：在解码阶段生成的每词耗时是一个平均值
- **延迟计算**：Token间延迟(ITL)即每输出token时间(TPOT)，理想情况下应为恒定值

2. 首词生成时间 00:55

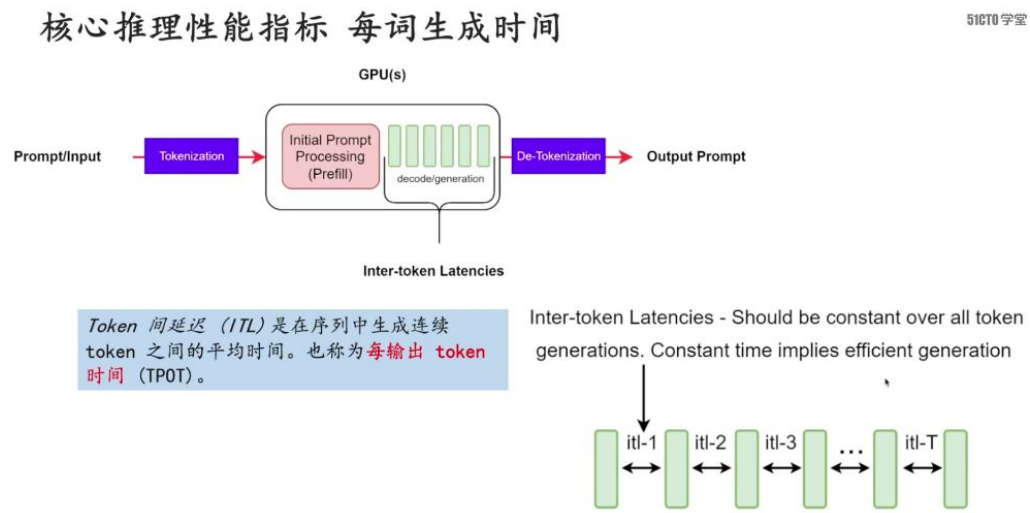


- **组成要素**：包含请求排队时间、预填充时间和网络延迟
- **影响因素**：提示时间越长，TTFT越大；KV缓存创建需要完整输入序列
- **并发特性**：多个请求时，一个请求的预填充阶段可能与另一个请求的生成阶段重叠

1）预填充阶段 01:12

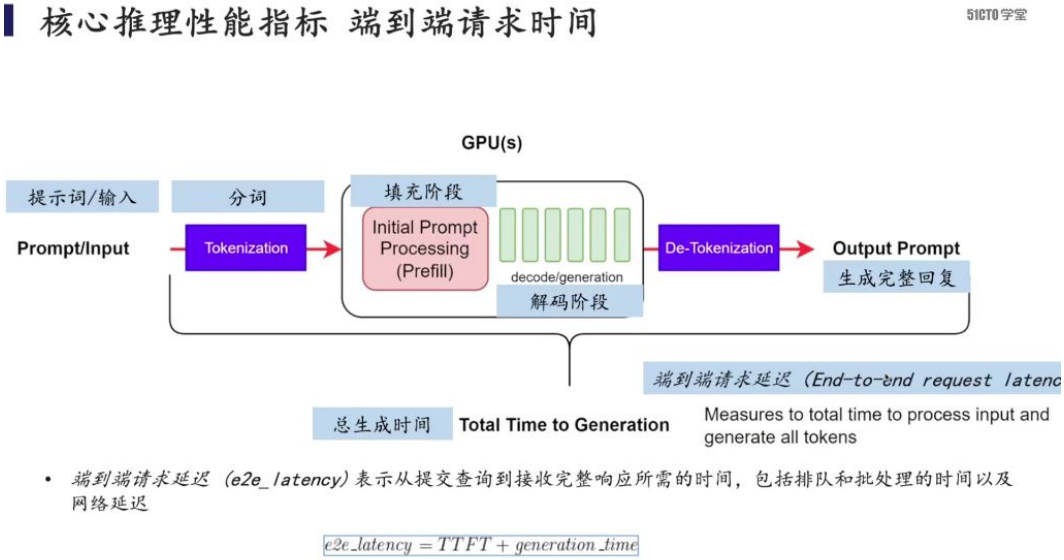
- **处理流程**：输入提示词后进行分词处理，生成首次输出token
- **关键机制**：注意力机制需要创建key-value(KV)缓存用于后续迭代生成

3. 每词生成时间 01:26



-
- **定义**：序列中生成连续token之间的平均时间，又称TPOT或Inter-token Latency(ITL)
- **性能特征**：恒定时间意味着高效的生成过程，计算公式为(端到端延迟 - $TTFT$) / (输出$Token$ - 1)

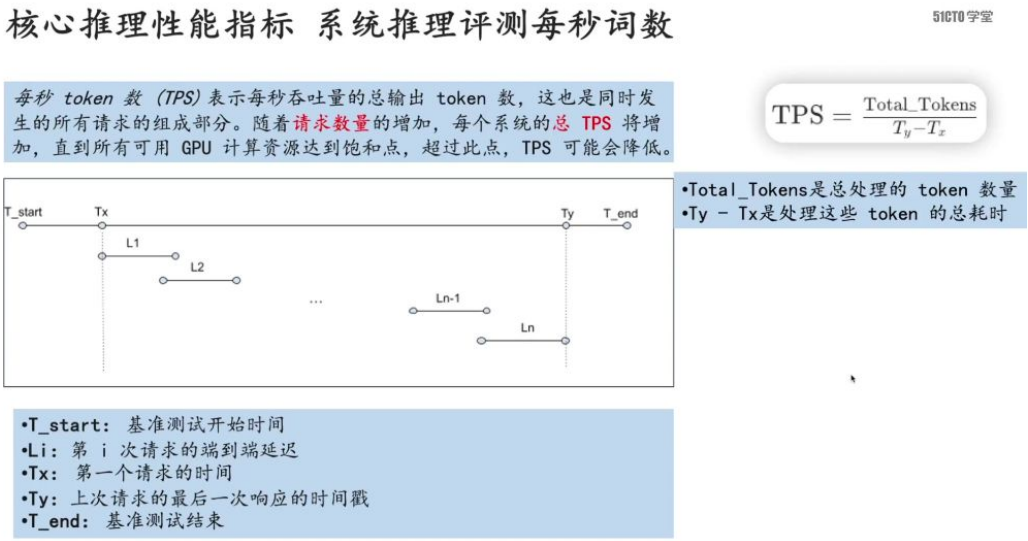
4. 端到端请求时间 01:35



-
- **计算公式**：$e2e_latency = TTFT + generation_time$
- **用户体验**：反映从提交查询到接收完整响应所需的总时间，直接影响用户满意度
- **包含要素**：除处理时间外还包括排队、批处理时间和网络延迟

5. 系统推理评测 02:03

1）每秒词数 02:13



-
- **计算公式**：$TPS = \frac{Total_Tokens}{T_y - T_x}$
- **性能曲线**：随着请求量增加TPS上升，达到GPU饱和点后可能下降
- **测试参数**：包含基准开始时间(T_start)、各请求延迟(Li)、首末响应时间戳(Tx,Ty)

6. 业务水平目标 02:58



并发度 (N)	横轴：端到端延迟 (ms)	纵轴：吞吐量 (TPS)	测试说明 (对应曲线阶段)	是否满足 SLO (≤2000ms)?
1	2187	320	低并发，未充分利用资源	❌ 延迟超限
2	1905	630	低并发向临界过渡	✅ 延迟达标
4	1980	1210	临界前阶段（最佳操作点）	✅ 延迟达标
6	2050	1750	临界阶段	❌ 延迟超限
8	2430	2120	过饱和初期	❌ 延迟超限
10	3120	2350	过饱和阶段	❌ 延迟超限
12	4050	2410	过饱和后期	❌ 延迟超限
14	4890	2380	严重过饱和	❌ 延迟超限

-
- **典型场景**：AI客服LLM服务(7B模型)要求端到端延迟≤2秒(2000ms)
- **最佳实践点**：并发量N=4时延迟1980ms，TPS1210，满足SLO要求

1）低延迟应用 03:14

- **应用场景**：实时交互如聊天机器人
- **优化方向**：限制并发请求数，最小化TTFT和TPOT

2）高吞吐量应用 03:24

- **应用场景**：批处理任务如报表生成
- **优化方向**：最大化系统处理能力，可牺牲单请求延迟换取高TPS

7. LLM推理基准测试 04:13



- **评估维度**：延迟、吞吐量、资源利用率、稳定性等工程指标
- **工具生态**：包括genai-bench(SGLang)、guidellm(vLLM)、inference-perf(K8s)等开源工具

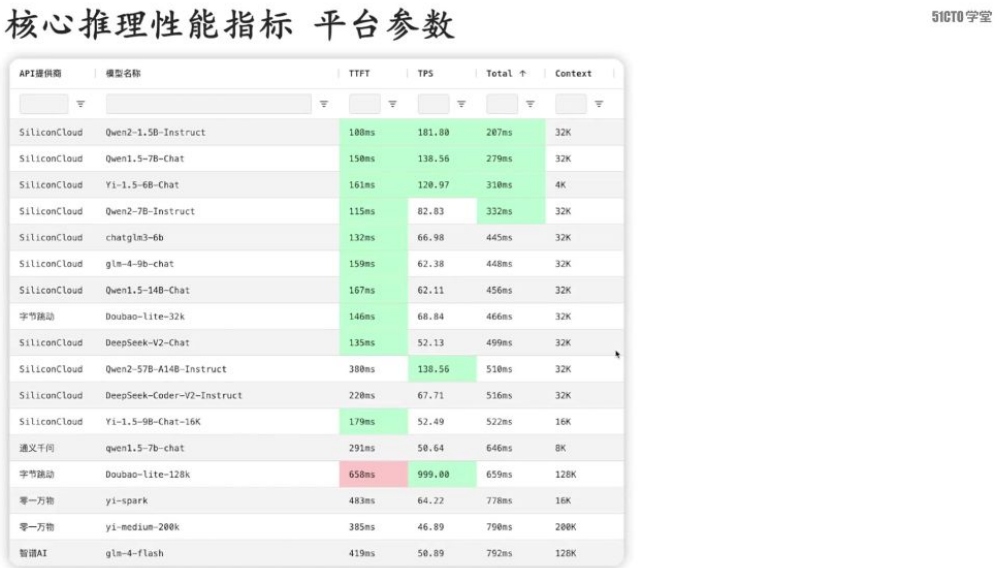
1）数据加载 04:19

- **测试流程**：从外部存储加载测试数据集到基准测试系统

2）请求处理 04:34

- **测试方法**：通过客户端模拟并发请求，生成性能报告

8. 平台参数对比 04:47



- **典型数据**：Qwen2-1.5B模型TTFT108ms，TPS181.8；DeepSeek-V2模型TTFT135ms，TPS52.13
- **上下文长度**：从4K(Qwen1.5-6B)到200K(yi-mcdiun-200k)不等

二、知识小结

知识点	核心内容	考试重点/易混淆点	难度系数
大语言模型推理性能指标全景图	从用户请求到结果经历的阶段（预填充阶段、解码	区分**首词生成时间**与**每词生成时间**的计算方式	★★

	阶段），包含请求队列时间、网络延迟等		
端到端时间（Total Time to Generation）	**首词时间 + 每词耗时 × token数**，反映用户对系统响应的满意度	易混淆：端到端时间是否包含网络延迟（文中明确包含）	★★★
系统吞吐量（TPS）	单位时间处理的token数（总token数/区间时间），受GPU饱和点限制	**高并发时TPS先升后降**，需关注业务场景的SLO定义	★★★★
业务水平目标（SLO）	实时聊天场景：低延迟（如TTFT <2秒）；批量生成场景：高TPS	**并发量=4时TPS=1210且延迟<2000ms**为理想值	★★★
大模型推理流程	数据加载→生成→调用开源工具→请求服务器→生成报表	关键参数：上下文长度、并发数	★★
API提供商选型	通过模型参数对比选择服务商（文中未展开具体参数）	需结合业务需求（如延迟、成本）综合评估	★★