以下为AI生成的图文笔记的内容

一、算法优化 00:14

1. 模型压缩策略 00:53

- **显存占用组成**:　大模型推理时显存主要加载两部分内容：模型参数（权重和偏置量）和KV Cache（推理过程中的重要缓存）
- **压缩策略分类**:
  - **训练中压缩**: 在模型训练过程中进行参数压缩
  - **微调中量化**: 在模型微调阶段进行参数量化
  - **后训练量化**:　　模型训练完成后进行参数量化（重点讲解，因对大多数企业更实用）
- **实现方式**: 通过降低参数精度实现压缩，如将FP16降为INT8

2. 模型量化概念 02:18

- **基本原理**: 将高精度参数转换为低精度参数的过程
- **精度转换示例**: 如从浮点16位(FP_{16})量化为整数8位(INT_8)
- **核心目标**: 在保持模型性能的前提下减少模型体积和计算资源需求

3. AWQ 02:27

- **全称**: Activation-aware Weight Quantization（激活感知权重量化）
- **类型**: 后训练量化方法
- **核心思想**:
  - 评估神经网络中权重的重要性
  - 对重要权重保持原精度
  - 对非重要权重进行降精度处理
- **优势**: 能有效平衡模型压缩率和精度损失

4. GPTQ量化 03:07

- **适用场景**: 生成式模型的后训练量化
- **核心机制**: 量化补偿机制
  - **问题**: 量化会导致模型准确率下降
  - **解决方案**: 在量化过程中引入补偿，使准确率保持在可接受水平
- **特点**: 在压缩率和模型性能间取得折中平衡

5. 模型剪枝 03:54

- **类比**: 类似树木修剪，去除无用枝条
- **操作对象**: 神经网络中的参数和连接
  - 输入层、隐藏层、输出层的参数
- **剪枝标准**:
  - 不重要参数（对输出影响小）
  - 冗余参数连接
- **效果**: 减少模型复杂度，提高推理效率

6. 模型蒸馏 04:31

- **类比**: 老师教学生（大模型指导小模型）
- **目的**:
  - 使模型能在资源受限平台运行
  - 减少模型体积和计算需求
- **实现方式**:
  - 将大模型的知识迁移到小模型
- **局限性**:
  - 存在性能损耗（学生无法完全达到老师水平）

- 需要权衡模型大小和性能保持

二、知识小结

知识点	核心内容	技术要点	实现难点
模型压缩策略	通过量化/剪枝/蒸馏降低参数量	精度转换(f16→int8)、参数重要性评估	**量化后准确率补偿机制**
KV Cache优化	推理过程中的关键缓存机制	显存占用优化、计算效率提升	大规模序列处理的动态内存管理
AWQ量化	激活感知权重量化	基于参数重要性的差异化压缩	**高重要性参数精度保持**
GPTQ量化	生成式模型后训练量化	误差补偿的折中量化策略	量化粒度与模型性能的平衡
模型剪枝	神经网络结构优化	参数连接重要性分析、冗余移除	**剪枝阈值动态调整**
知识蒸馏	大模型向小模型的知识迁移	教师-学生模型训练架构	**蒸馏过程中的信息损耗控制**
后训练量化	已训练模型的参数压缩	无需重新训练的部署优化	量化噪声对推理结果的影响