以下为AI生成的图文笔记的内容

一、模型压缩策略分类 00:00

1. 模型量化 00:22

- **核心思想**: 通过降低参数精度来减少显存占用和提高计算速度
- **实现方式**: 将高位参数(如fp_{16})转换为低位参数(如int_8)
- **优势**:
  - 降低数据传输成本：模型在GPU显存和运算单元间搬运时体积更小
  - 提升计算效率：低位运算比高位运算更快
  - 减少显存占用：参数占用空间更小

2. 量化感知训练 02:06

- **定义**: 在模型训练过程中加入伪量化算子
- **关键点**:
  - 训练时统计输入输出的数据范围
  - 适用于具有模型训练能力的组织
- **优势**: 能显著提升量化后模型的精度
- **技术细节**: 通过特殊设计的训练过程使模型适应低位表示

3. 量化感知微调 02:28

- **应用场景**: 对已微调的大语言模型进行量化
- **核心目标**: 确保模型在低位宽量化后仍保持性能
- **平衡点**: 在模型压缩和性能保持之间取得最佳平衡
- **典型用户**: 需要垂直领域定制化模型的企业

4. 训练后量化 03:02

- **特点**: 模型训练完成后对其参数进行量化
- **优势**:
  - 只需少量校准数据
  - 操作简单易用
  - 适合资源有限的场景
- **典型应用**: 直接对开源模型(如千问、deep seek)进行量化使用
- **补偿机制**: 可通过后续技术弥补可能的精度损失

5. 模型剪枝

- **定义**: 移除模型中不重要的结构来减小模型尺寸
- **操作对象**:
  - 不重要的参数
  - 不重要的参数连接
- **效果**:
  - 几乎不影响模型精度
  - 提升推理性能和效率
- **理论基础**: 神经网络中存在大量冗余参数

6. 知识蒸馏



- **核心概念**: 大模型(教师)指导小模型(学生)学习
- **过程比喻**: 类似海水蒸发提取盐分的过程
- **关键优势**:
  - 能在模型压缩后恢复和提升小模型准确性
  - 保留核心知识"干货"
- **应用场景**: 常与剪枝/量化技术配合使用

二、知识小结

知识点	核心内容	技术实现	应用场景
模型量化	通过降低参数精度减少显存占用	FP16→INT8二进制转换	资源受限的推理环境
量化类型	训练感知/微调量化/训练后量化	参数位宽动态调整	大厂模型优化/企业垂直领域适配
模型剪枝	删除非关键参数及连接	神经网络层重要性分析	提升推理效率
知识蒸馏	大模型指导小模型训练	师生模型协同优化	模型轻量化部署
显存优化	降低参数搬运成本	GPU显存-SM处理器调度	高并发推理场景