以下为AI生成的图文笔记的内容

一、激活感知权重量化 00:05

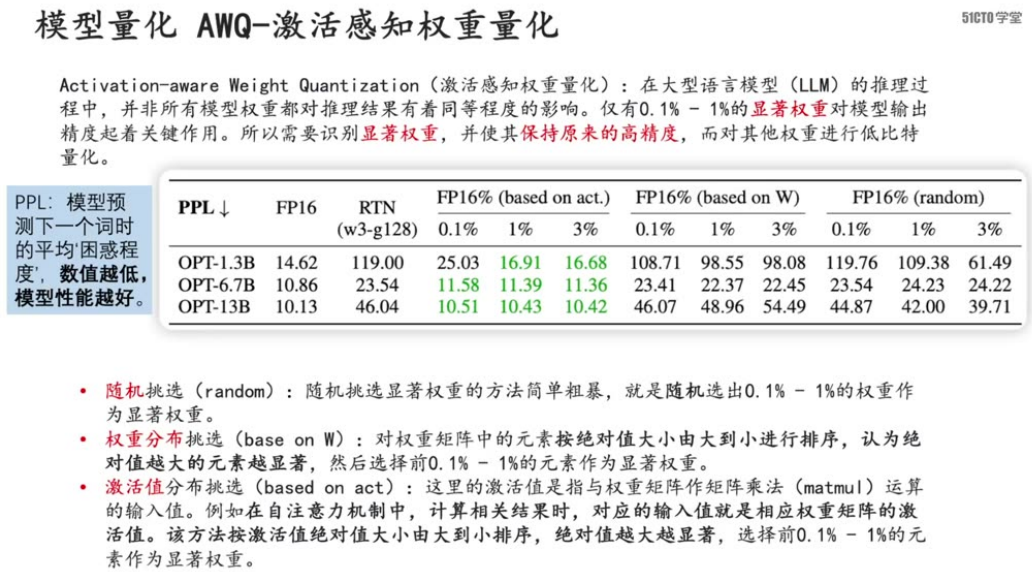
- **核心思想**：在LLM推理过程中，仅0.1%-1%的显著权重对输出精度起关键作用，通过识别并保留这些权重的高精度，其他权重可进行低比特量化
- **量化优势**：相比全局量化，能在保持模型精度的同时显著减小模型尺寸
- **关键指标PPL**：困惑度(Perplexity)衡量模型预测下一个词的平均困惑程度，数值越低表示模型性能越好

1. 实验方式 01:21

1）显著权重识别方法

- **随机选择(random)**：简单随机选取0.1%-1%权重作为显著权重
- **权重分布(based on W)**：按权重绝对值大小排序，选取前0.1%-1%的权重
- **激活值分布(based on act)**：通过矩阵乘法运算的输入激活值绝对值排序，选取前0.1%-1%权重（AWq采用方法）

2）实验对比



- **测试模型**：OPT-1.3B/6.7B/13B三个规模
- **基准精度**：FP16全精度模型
- **对比维度**：三种显著权重选择方法在0.1%/1%/3%保留比例下的PPL表现

2. PPL实验结果分析 02:40

- **随机选择结果**：
  - OPT-1.3B：PPL高达119.00(1%)和98.55(3%)
  - 所有模型PPL均显著高于基准FP16（14.62/10.86/10.13）
- **权重分布结果**：
  - OPT-6.7B：PPL改善至11.36(1%)，但仍高于基准10.86
  - 大模型(13B)在3%保留时PPL恶化至54.49
- **激活感知结果**：
  - OPT-1.3B：最佳PPL 16.68(1%)，接近FP16基准14.62
  - OPT-13B：PPL稳定在10.42(1%)，几乎与基准10.13持平
  - 唯一在0.1%保留比例下仍保持合理PPL的方法（25.03 vs 119.00/108.71）
- **结论验证**：激活感知方法通过注意力机制中的矩阵乘法运算识别关键权重，其PPL表现显著优于其他方法，证实了该方法的科学性

二、知识小结

知识点	核心内容	考试重点/易混淆点	难度系数
AWQ（激活感知权重量化）原理	通过识别显著权重（0.1%-1%）并优先保持其精度，实现模型尺寸压缩与精度平衡	显著权重的定义与识别方法（随机/绝对值/激活值分布）	★★★
显著权重识别实验对比	三种方法测试： 1. 随机选择权重（PPL值**100+/20+/40+**） 2. 按权重绝对值排序（PPL值较高） 3. **AWQ激活值分布法**（PPL值**<20**）	**激活值分布法**的科学性验证（注意力机制+矩阵乘法运算）	★★★★
评估指标（PPL）	困惑度指数：模型预测下一个词的平均困惑程度，**值越低精度越高**	PPL在量化效果评估中的核心作用	★★
实验模型与参数	测试模型：OPT-1.3B/6.7B/13B 基准精度：FP16 量化比例：0.1%/1%/3%权重	不同模型规模下的量化效果差异	★★★
AWQ技术优势	通过**激活值动态分析**显著权重，优于随机或静态绝对值方法	实际应用中需结合注意力机制计算	★★★★