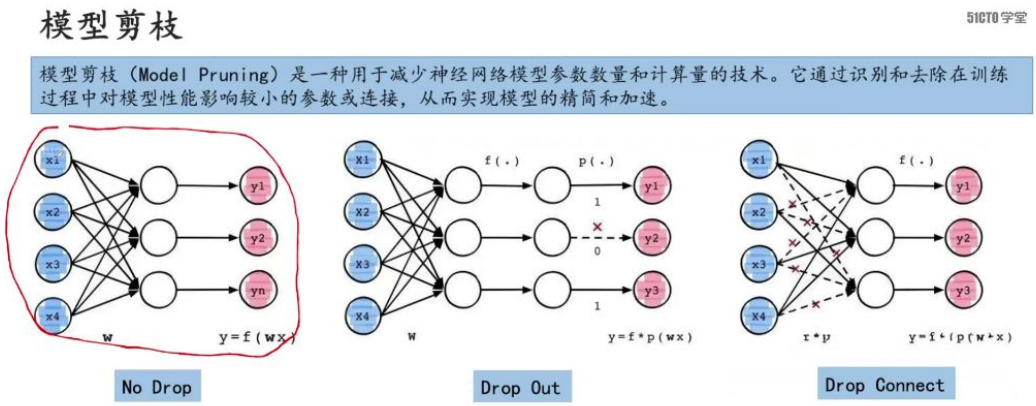
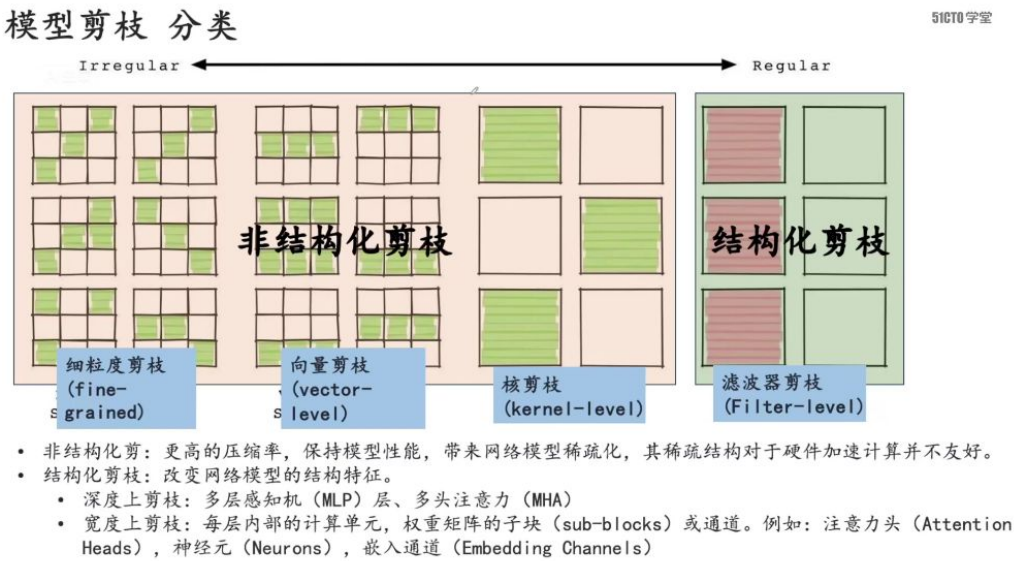
以下为AI生成的图文笔记的内容

一、模型剪枝 00:06



- **定义**：通过识别和去除对模型性能影响较小的参数或连接，减少神经网络参数数量和计算量的技术
- **实现方式**：
  - **Drop Out**：随机将神经元输出置零（神经元剪枝）
  - **Drop Connect**：随机将神经元间连接置零，使权重矩阵稀疏化
- **作用机制**：在神经网络中（含输入层、隐层、输出层），通过前向传递和反向传递识别不重要参数，将其删除或置零，从而减少显存占用和计算量

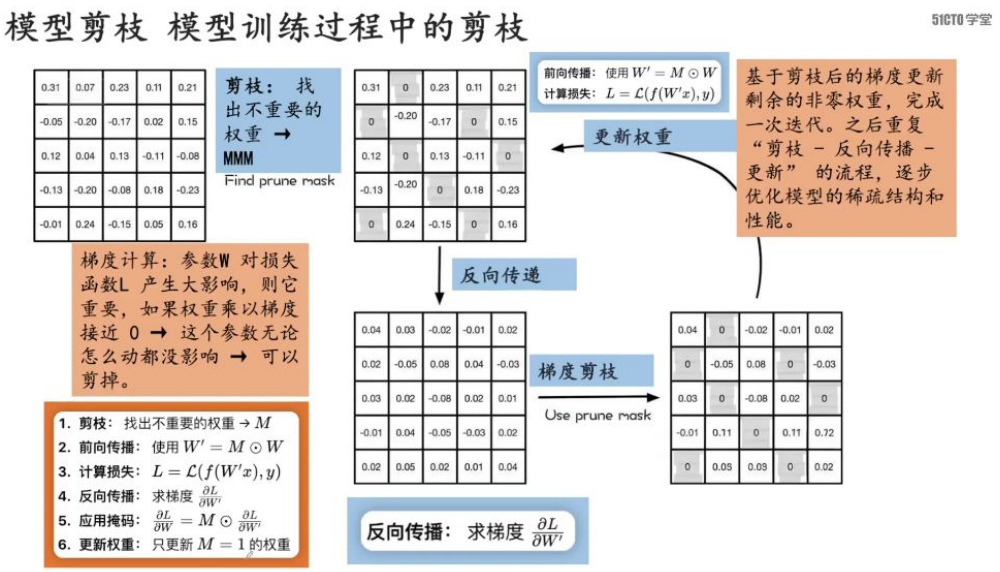
1. 模型剪枝分类 02:30



- **非结构化剪枝**：
  - **特点**：产生参数矩阵中的"空洞"，实现细粒度剪枝（向量/核级别）
  - **优势**：更高压缩率，能保持模型性能
  - **缺点**：导致网络稀疏化，对GPU等硬件加速计算不友好（需补全零值）
- **结构化剪枝**：

- **特点**：整块移除矩阵/向量（滤波器/注意力头级别）
- **分类**：
  - **深度剪枝**：移除整层（如MLP层、多头注意力层）
  - **宽度剪枝**：移除层内计算单元（如注意力头、神经元、嵌入通道）

2. 模型训练过程中的剪枝 04:25



- **核心原理**：通过梯度计算判断参数重要性（|权重 × 梯度| ≈ 0表示可剪枝）
- **六步迭代流程**：
  - **剪枝**：生成遮罩M标记不重要权重
  - **前向传播**：计算$W' = M \odot W$
  - **损失计算**：$L = L(f(W'x), y)$
  - **反向传播**：求梯度$\frac{\partial L}{\partial W'}$
  - **应用遮罩**：$\frac{\partial L}{\partial W} = M \odot \frac{\partial L}{\partial W'}$
  - **权重更新**：仅更新$M = 1$的权重
- **动态特性**：通过多次"剪枝-反向传播-更新"循环逐步优化稀疏结构
- **硬件影响**：训练中产生的非结构化稀疏会降低GPU计算效率，但有助于理解剪枝本质

二、知识小结

主题	核心内容	技术实现	关键特点
神经网络基础结构	输入层-隐层-输出层的前向/反向传递	参数矩阵运算与损失函数优化	**参数连接密集**
非结构化减值	随机将神经元输出置零	遮罩矩阵(Mask)应用	**产生参数稀疏性**
结构化减值	整层/整组参数移除	连接斩断(Job Collector)	**硬件运算友好**
训练过程减值	基于梯度的重要参数筛选	损失函数反向传播分析	**动态权重更新**
稀疏化影响	参数矩阵出现空洞	FP16/FP32精度混合运算	**GPU计算效率下降**
减值分类体系	非结构化vs结构化减值	深度减值vs广度减值	**压缩率-精度平衡**