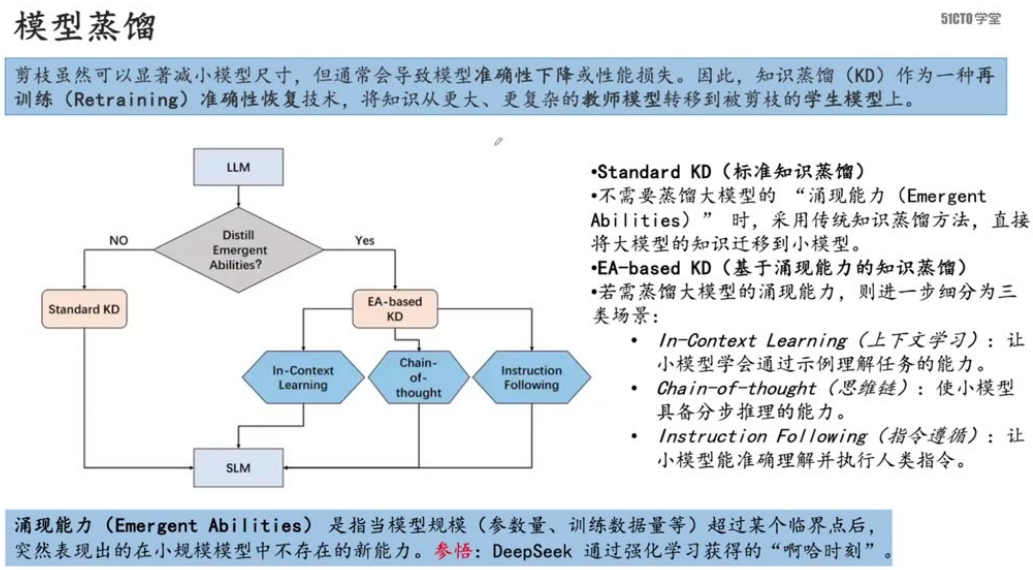
以下为AI生成的图文笔记的内容

一、模型蒸馏 00:00

1. 模型蒸馏定义 00:05



-
- **核心作用**：作为剪枝后的再训练技术，通过教师模型向学生模型传递知识来恢复模型准确性
- **技术本质**：属于模型压缩技术范畴，通过知识迁移实现"大教小"的学习过程

2. 标准知识蒸馏 00:19

- **基本流程**：教师模型直接输出知识，学生模型完全模仿教师输出
- **特点**：单向知识传输模式，类似"老师讲学生抄笔记"的被动学习
- **适用场景**：当不需要迁移涌现能力时采用，仅传递基础任务解决能力

3. 涌现能力定义 00:45

- **临界现象**：当模型参数量/数据量超过临界点后突然表现的新能力
- **典型表现**：如DeepSeek模型在强化学习中获得的"啊哈时刻"解题能力
- **产生机制**：通过大规模参数学习获得的步骤推理、指令理解等高级能力

4. 基于涌现能力的知识蒸馏 01:35

1）上下文学习蒸馏 01:52

- **教学方式**：通过示例对（如"上-下"、"小-大"）建立任务映射关系
- **训练特点**：依赖少量样本即可实现反义词识别等简单任务迁移
- **应用场景**：少样本学习、基础问答系统等需要快速适应的场景

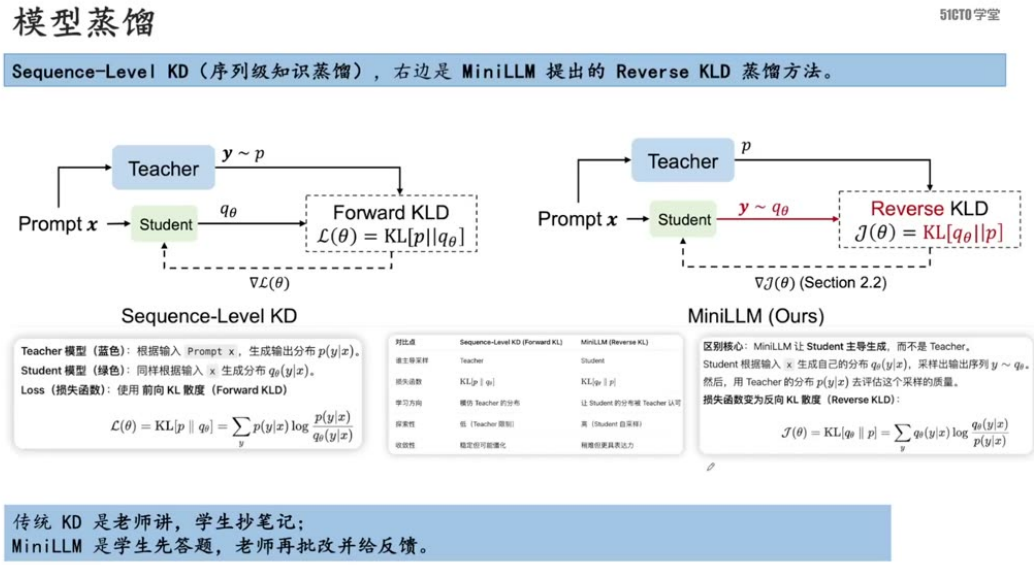
2）思维链蒸馏 02:18

- **核心要素**：同时提供题目、答案及完整解题步骤作为训练数据
- **优势**：解决小模型无法自主生成推理步骤的缺陷
- **典型应用**：数学证明、逻辑推理、代码生成等需要分步解决的复杂任务

3）指令遵循蒸馏 02:59

- **训练目标**：使模型准确理解并执行"生成小说大纲"等具体指令
- **实现方式**：通过大量指令-响应配对数据训练
- **应用领域**：对话系统、创意写作等需要精确响应人类指令的场景

5. 序列级知识蒸馏 03:30



-

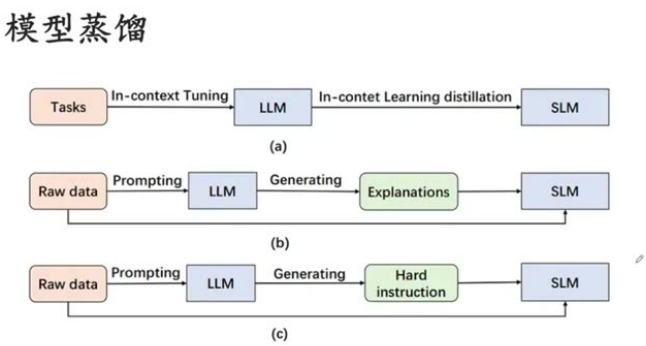
1）传统KD方法 03:44

- **流程特点**：教师生成输出分布p(y|x)，学生模仿生成$q_\theta(y|x)$
- **损失函数**：使用前向KL散度$KL[p||q_\theta]$计算分布差异
- **类比说明**：类似"老师示范解题，学生照抄标准答案"的教学模式

2）MiniLLM方法 04:35

- **创新点**：改为学生主导生成$q_\theta(y|x)$，教师仅评估质量
- **数学表达**：采用反向KL散度$KL[q_\theta||p]$作为损失函数
- **教学类比**：相当于"学生先自主答题，老师后批改反馈"的启发式教学
- **优势**：增强学生模型的探索性和表达能力，但训练难度更高

6. 蒸馏模式应用场景 05:59



模式	主要学习对象	目标	输出样式	典型应用
(a) In-context Learning Distillation	上下文学习能力	从上下文中泛化	示例 + 任务	少样本学习、问答
(b) Chain-of-Thought Distillation	推理步骤	学习推理链路	推理文本	数学、逻辑推理、代码生成
(c) Instruction Following Distillation	指令执行	模仿执行方式	指令响应	对话系统、写作生成

-

1）上下文学习应用 06:14

- **核心能力**：从少量示例中泛化任务规律的能力
- **典型场景**：客服系统中的话术学习、简单模式识别任务

2）思维链应用 06:51

- **关键突破**：使小模型获得原本只有大模型才具备的逐步推理能力
- **实现难点**：需要精确拆解大任务的中间步骤作为监督信号
- **应用实例**：数学应用题求解、程序算法设计等分步验证场景

3）指令遵循应用 08:20

- **训练重点**：强调对指令意图的准确理解而非简单模式匹配
- **典型表现**：能根据"生成悬疑风格小说"等具体指令调整输出
- **商业价值**：广泛应用于智能写作助手、个性化对话机器人等领域

二、知识小结

知识点	核心内容	考试重点/易混淆点	难度系数
模型蒸馏技术	基于模型压缩的技术，通过知识迁移实现小模型性能提升	区分标准蒸馏与涌现能力蒸馏	★★
涌现能力	模型参数超过临界点时表现的新能力（如参悟解题步骤）	理解涌现能力的触发条件（如DeepSeek Krone案例）	★★★
标准知识蒸馏	老师模型单向传授知识，学生模型模仿输出	**判断标准**：是否需学习涌现能力	★★
基于上下文的蒸馏	通过示例教学（如反义词训练）培养任务能力	依赖少量样本，重点在业务场景迁移	★★
思维链（Chain of Thought）	大模型提供解题步骤，小模型学习分布式推理	数学/代码类任务中步骤生成的难点	★★★★
指令遵循蒸馏	训练模型理解人类指令（如写作、客服）	指令的明确性与任务泛化性平衡	★★★
正向KL散度蒸馏	老师模型主导，学生比较输出并调整参数（抄笔记模式）	传统方法，适用于简单知识迁移	★★
反向KL散度蒸馏	学生主导生成，老师评估反馈（答题批改模式）	**高亮难点**：表达力要求更高，采样质量评估	★★★★
三类蒸馏应用场景	上下文学习→少样本任务；思维链→数学推理；指令遵循→对话/写作	区分每类技术的典型任务（如反义词vs代码生成）	★★★