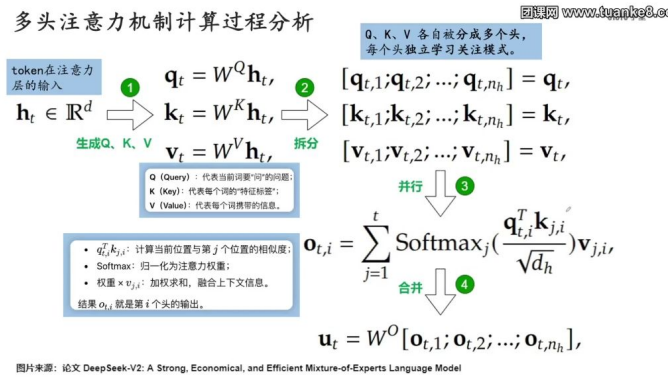
以下为AI生成的图文笔记的内容

一、多头注意力机制计算过程分析 00:00

1. token在注意力层的输入 00:36

- **输入处理**：token进入注意力层时，首先会进行嵌入处理，基于该嵌入生成Q(Query)、K(Key)、V(Value)三个矩阵
- **矩阵含义**：
  - Q：代表当前词要"问"的问题
  - K：代表每个词的"特征标签"
  - V：代表每个词携带的信息
- **计算公式**：
  - $\mathbf{q}_t = W^Q \mathbf{h}_t$
  - $\mathbf{k}_t = W^K \mathbf{h}_t$
  - $\mathbf{v}_t = W^V \mathbf{h}_t$
  - 其中$\mathbf{h}_t \in R^d$是输入向量

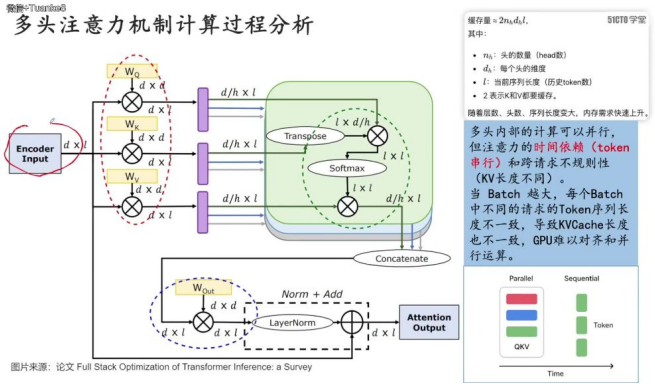
2. 拆分 01:08



图片来源：论文 DeepSeek-V2: A Strong, Economical, and Efficient Mixture-of-Experts Language Model

- **拆分过程**：生成的Q、K、V会被分成多个头(head)，每个头独立学习关注模式
- **数学表示**：
  - $\left[\mathbf{q}_{t,1};\mathbf{q}_{t,2};\ldots;\mathbf{q}_{t,n_h}\right] = \mathbf{q}_t$
  - $\left[\mathbf{k}_{t,1};\mathbf{k}_{t,2};\ldots;\mathbf{k}_{t,n_h}\right] = \mathbf{k}_t$
  - $\left[\mathbf{v}_{t,1};\mathbf{v}_{t,2};\ldots;\mathbf{v}_{t,n_h}\right] = \mathbf{v}_t$
- **缓存问题**：多头机制会导致KV缓存量增加，缓存量公式为$2n_h d_h l$，其中n_h是头数，d_h是每个头维度，l是序列长度

3. 并行 01:55



图片来源：论文 Full Stack Optimization of Transformer Inference: a Survey

- **并行特性**：不同头的计算可以并行执行，不是串行完成
- **计算过程**：

- 每个头独立计算相似度：$q_{t,i}^T k_{j,i}$
- 通过Softmax归一化为注意力权重
- 加权求和：$\mathbf{o}_{t,i} = \sum_{j=1}^{t} Softmax_j\left(\frac{\mathbf{q}_{t,i}^T \mathbf{k}_{j,i}}{\sqrt{d_h}}\right)\mathbf{v}_{j,i}$

- **合并输出**：所有头的输出合并为最终结果：$\mathbf{u}_t = W^O\left[\mathbf{o}_{t,1};\mathbf{o}_{t,2};...;\mathbf{o}_{t,n_h}\right]$
- **时间依赖**：虽然多头计算可以并行，但token处理仍是串行的，必须按顺序处理
- **性能瓶颈**：
  - 随着层数、头数、序列长度增加，内存需求快速上升
  - 不同请求的KV长度不一致导致GPU难以对齐和并行运算

二、知识小结

知识点	核心内容	技术要点	难点分析
多头注意力机制	并行计算QKV矩阵	分组/多查询优化	**缓存需求指数增长**
注意力计算流程	QK^T矩阵运算→缩放→Softmax→V加权	维度(dimension)归一化	**并行头与串行token的矛盾**
多头结构特性	每个头独立计算注意力输出	Q/K/V拆分到不同头	**硬件传输瓶颈**
Transformer架构限制	自回归生成模式	前序token向量依赖	**严格时序约束**
KV缓存问题	历史token向量存储	多头数量放大缓存压力	**内存带宽瓶颈**
计算并行性	多头间并行运算	注意力输出合并(concatenate)	**token级串行不可突破**