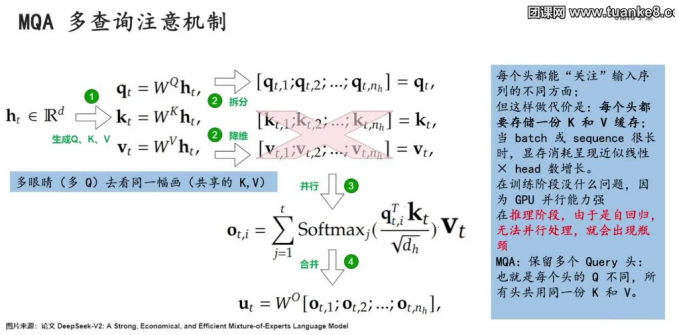
以下为AI生成的图文笔记的内容

一、多查询注意机制 00:00

1. 多查询注意力机制的基本概念 00:30



-
- **核心思想**：保留多个Query头（每个头的Q不同），但所有头共享同一份K和V缓存
- **类比解释**：如同用多只眼睛（多个Q）观察同一幅画（共享KV），实现并行处理Q与KV的计算
- **运算流程**：输入→生成Q / K / V矩阵→拆分多个Q但仅保留1组KV→并行计算→合并结果

2. 多查询注意力机制的运算逻辑 00:42

- **降维本质**：通过消除冗余KV缓存实现，具体表现为：
  - 生成QT_1,QT_2,...,QT_n多个查询矩阵
  - 仅保留单一K和V矩阵（如KTG / VTG）
- **并行处理**：n个Q头与同一组KV进行并行运算
- **结果合并**：将n个运算结果拼接后输出

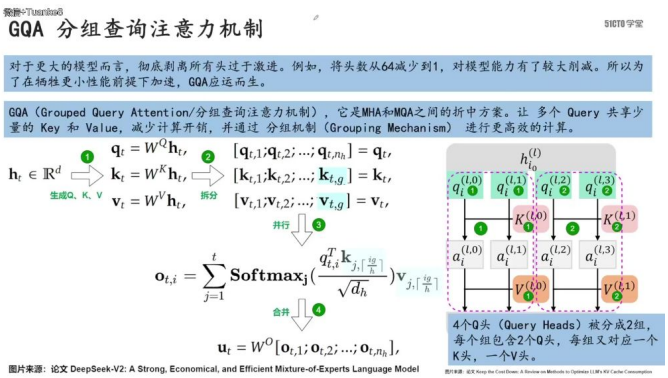
3. 多查询注意力机制的优势与问题 01:32

- **显存优化**：
  - 传统MHA：显存消耗随头数线性增长（×head数）
  - MQA：显存消耗恒定（仅1组KV）
- **推理瓶颈**：自回归过程无法并行处理，KV缓存成为主要瓶颈
- **精度代价**：由于KV信息大幅缩减（如64头→1头），会导致模型精度下降约1分（T5模型实验数据）

4. 多查询注意力机制的适用场景 02:30

- **大模型优先**：参数丰富的模型（如DeepSeek Krone）精度损失较小
- **小模型慎用**：参数较少的模型精度下降明显
- **典型取舍**：用精度下降换取推理速度提升（耗时从1.5s→0.5s）

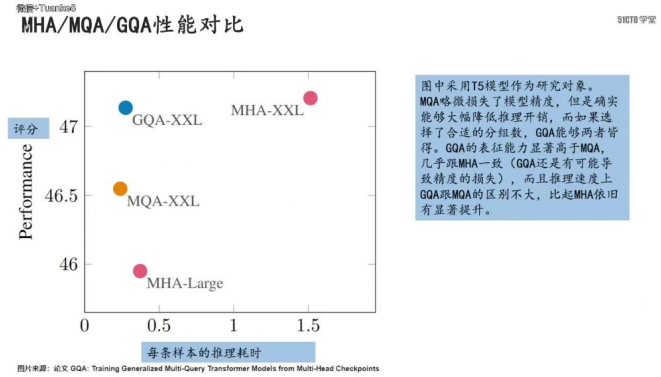
二、分组查询注意力机制 03:17



-

- **设计动机**：MQA过度削减头数（如64→1）损害模型能力，需折中方案
- **核心机制**：
  - 将Q头分组（如4头→2组）
  - 每组共享1组KV（如2组对应2组KV）
  - 运算公式：$\mathbf{o}_{t,i} = \sum_{j=1}^{t} Softmax_j\left(\frac{q_{t,i}^T \mathbf{k}_{j,\left\lfloor \frac{q}{h} \right\rfloor}}{\sqrt{d_h}}\right) v_{j_1\left\lfloor \frac{ig}{h} \right\rfloor}$
- **优势体现**：
  - 显存消耗减半（相比MHA）
  - 精度保持更好（相比MQA仅下降0.5分）
  - 推理耗时与MQA接近（约0.5s/样本）

三、MQA与GQA机制性能比较 05:47



图片来源：论文 GQA: Training Generalized Multi-Query Transformer Models from Multi-Head Checkpoints

- **评分对比**（T5模型）：
  - MHA-XXL：47分
  - GQA-XXL：46.5分
  - MQA-XXL：46分
- **耗时对比**：
  - MHA：1.5s/样本
  - GQA/MQA：0.5s/样本
- **选择策略**：
  - 精度敏感场景：选择GQA（接近MHA精度）
  - 速度优先场景：选择MQA（最大速度提升）
  - 平衡场景：通过分组数调节（如8头分4组）

四、知识小结

知识点	核心内容	考试重点/易混淆点	难度系数
多头注意力机制	介绍多头注意力计算机制的过程及问题分析，为后续多查询注意力（MQA）和分组查询注意力（GQA）做铺垫	多头注意力运算逻辑及问题点	★★★

多查询注意力（MQA）	仅生成多个Q矩阵，共享单个K、V矩阵，提升运算速度但降低精度，适合大模型	**KV缓存减少**（仅1份），精度下降风险	★★★★
分组查询注意力（GQA）	将K、V分组，每组对应多个Q，减少KV缓存但保持较好精度，适合中小模型	**KV缓存减半**，精度影响较小	★★★
MQA vs. GQA对比	**MQA**：推理速度最快（耗时<0.5秒），但精度损失明显（评分~~46）；~~ ~~**GQA**：平衡速度（耗时~~0.5秒）与精度（评分~47）	**横轴（耗时）** vs. **纵轴（精度评分）**	★★★★
适用场景选择	大模型优先用MQA（速度优先）；精度敏感场景用GQA；传统多头（MHA）耗时高（1.5秒）但精度最佳	**模型规模**与**精度要求**的权衡	★★★★