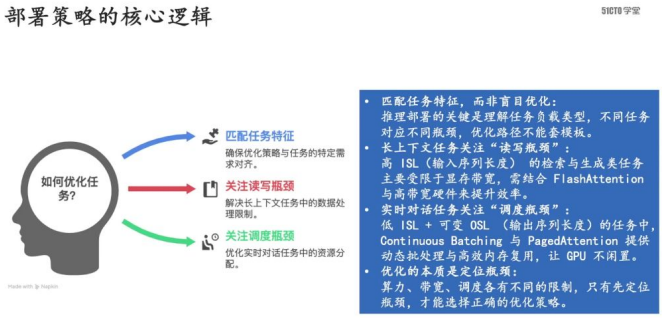
以下为AI生成的图文笔记的内容

一、推理部署实战指导与总结 00:01



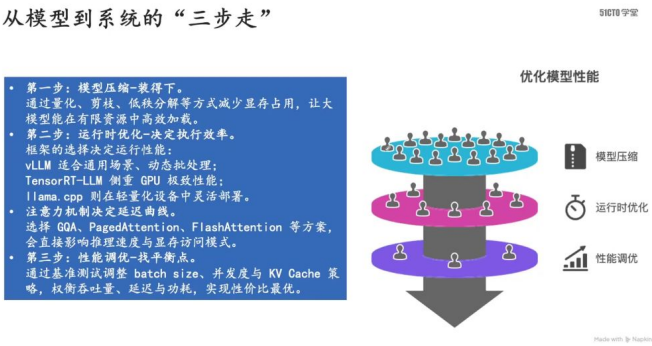
- **核心内容**：介绍大语言模型推理部署的实战指导，包括部署策略的核心逻辑、从模型到系统的三步走方法，以及技术发展趋势的展望。

1. 部署策略的核心逻辑 00:23



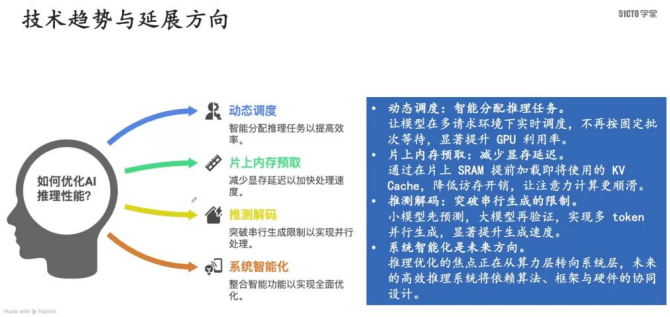
- **任务匹配原则**：优化策略必须与任务特征对齐，不同任务类型对应不同性能瓶颈，不能套用统一模板。例如长上下文任务关注读写瓶颈，实时对话任务关注调度瓶颈。
- **长上下文任务优化**：
  - **瓶颈特征**：高ISL(输入序列长度)的检索与生成类任务主要受限于显存带宽
  - **解决方案**：结合FlashAttention技术与高带宽硬件提升效率
  - **典型场景**：文章分析、内容润色等需要处理大段文本的任务
- **实时对话任务优化**：
  - **瓶颈特征**：低ISL+可变OSL(输出序列长度)
  - **解决方案**：采用Continuous Batching与PagedAttention实现动态批处理和高效内存复用
  - **典型场景**：聊天机器人等需要流式输出的应用
- **优化本质**：准确定位算力、带宽或调度等具体瓶颈，才能选择正确的优化策略。通用技术包括模型量化、KVCache优化等。

2. 从模型到系统的三步走 02:45



-
- **第一步：模型压缩**
  - **目标**：解决"装得下"问题，减少显存占用
  - **技术手段**：量化(如INT8/FP16)、剪枝、低秩分解(如LoRA)
  - **适用性**：所有部署场景的通用基础优化
- **第二步：运行时优化**
  - **目标**：提升执行效率，根据场景选择最优方案
  - **框架选择**：
    - vLLM：通用场景，擅长动态批处理
    - TensorRT-LLM：追求GPU极致性能
    - Llama.cpp：轻量化设备部署
  - **注意力优化**：采用GQA、PagedAttention、FlashAttention等技术直接影响推理速度和显存访问模式
- **第三步：性能调优**
  - **目标**：找到吞吐量、延迟与功耗的最佳平衡点
  - **调优方法**：通过基准测试调整$batch\ size$、并发度和$KV\ Cache$策略
  - **关键指标**：每秒token数、首次生成时间等业务相关参数

3. 技术趋势与延展方向 04:31



-
- **动态调度技术**：
  - **创新点**：智能分配推理任务，突破固定批次限制
  - **效益**：显著提升GPU利用率，特别是流处理器(SP)资源
- **片上内存预取**：
  - **原理**：在SRAM提前加载$KV\ Cache$
  - **优势**：减少显存访问延迟，使注意力计算更高效
- **推测解码技术**：
  - **突破**：小模型预测+大模型验证的多token并行生成
  - **效果**：突破Transformer架构的串行生成限制
- **系统智能化方向**：
  - **趋势转变**：从算力层优化转向系统层优化

- **未来特征**：算法、框架与硬件的协同设计将成为高效推理系统的关键

二、知识小结

主题	核心内容	技术要点	优化方向
部署策略	任务匹配与瓶颈分析	长上下文任务需flash attention 实时对话需continue patching	显存带宽优化 GPU资源利用率
模型压缩	参数量化与低秩优化	LoRA适配器 4/8-bit量化	**通用性技术** 参数占用率降低
运行时优化	框架级性能提升	FlashAttention 动态批处理	场景化方案选择 TensorRT加速
性能调优	多维指标平衡	吞吐量/延迟 首次token时间	批量请求数调整 KV缓存策略
动态调度	GPU资源智能分配	显存预取策略 SRAM优先	**未来趋势** 运算单元利用率
并行解码	突破串行限制	多token并行 Transformer架构改进	算法突破方向 解码加速
系统智能化	软硬件协同设计	算法-架构-框架三位一体	推理焦点转移 端到端优化