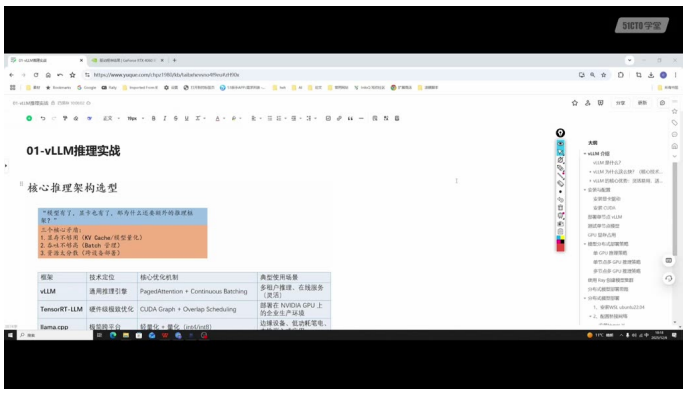
以下为AI生成的图文笔记的内容

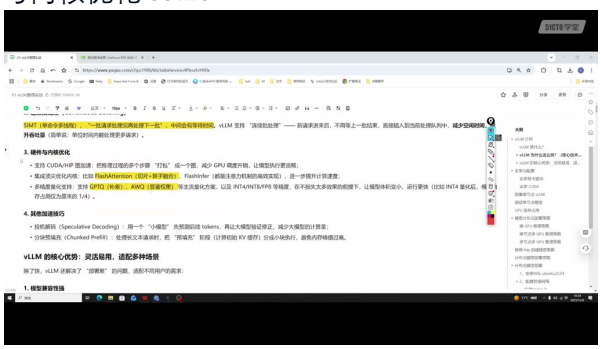
一、vLLM推理实战 00:23

1. 核心推理架构选型 00:38

1）vLLM介绍 02:23



-
- **定位**：快速应用的语言模型推理与服务工具，源自加州大学伯克利分校Sky Computing Lab
- **解决痛点**：
  - 速度慢（通过PagedAttention等技术优化）
  - 资源占用高（支持多精度量化）
  - 部署复杂（提供分布式部署方案）
- vLLM为什么这么快 04:02
  - 分页注意力机制 04:09
    - **实现原理**：采用类似操作系统内存管理的分页机制，通过page table建立逻辑内存与物理内存的映射关系
    - **优势**：
      - 解决KV Cache长度不一致导致的内存碎片问题
      - 使逻辑内存空间连续，显存利用率提升30%+
    - **技术来源**：灵感来自计算机内存分页管理
  - 硬件与内核优化 05:26



    -
    - **连续批处理**：
      - 突破传统SIMT（单指令多线程）必须等待批次完成的限制
      - 新请求实时插入处理队列，GPU计算单元利用率提升40%
    - **CUDA图加速**：
      - 将推理步骤打包成单一执行图，减少GPU调度开销
    - **优化内核**：
      - FlashAttention：采用切片（tiling）和算子融合技术
      - FlashInfer：高效注意力机制实现
    - **多精度量化**：

        - 支持GPTQ（补偿量化）和AWQ（显著权重放大）
        - INT4量化使模型显存占用降至1/4
    - 其他加速技巧 07:18
        - **投机解码**:
            - 小模型预测token→大模型验证修正，减少30%大模型计算量
        - **分块预填充**:
            - 长文本处理时将KV Cache初始化分块执行，避免内存峰值
        - **部署优势**:
            - 单节点支持RTX 4060等消费级显卡
            - 多节点可通过Ray集群扩展

二、知识小结

知识点	核心内容	技术亮点	应用场景
推理优化理论	Page Attention原理/KV Cache机制	内存分页管理技术	大模型推理加速
VL LM架构	开源推理框架	连续批处理/动态插入	多租户在线服务
硬件优化	CUDA图加速	算子融合/切片技术	GPU资源高效利用
Flash Attention	显存优化算法	**显著权重放大**/差值补偿	长序列处理
量化技术	GPTQ量化方案	AWQ显著权重处理	低精度推理部署
投机解码	小模型预验证	Token预测加速	降低推理延迟
分布式部署	分块预填充技术	KV Cache碎片化处理	集群推理服务