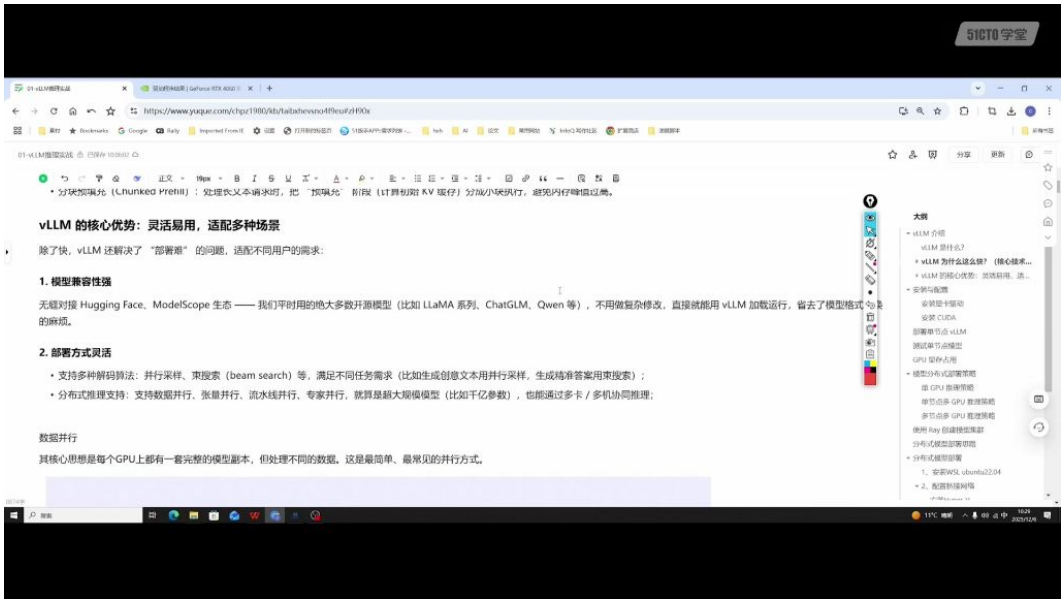
以下为AI生成的图文笔记的内容

一、vLLM的核心优势 00:03

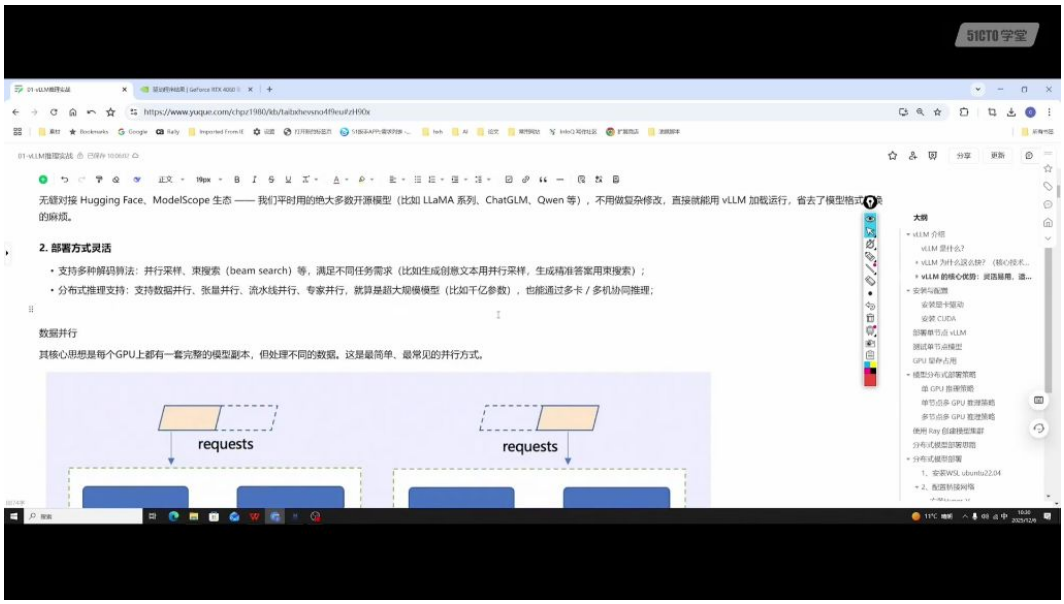
1. 模型兼容性强 00:22



- **生态对接**：无缝对接Hugging Face、ModelScope等开源平台，可直接加载LLaMA系列、ChatGLM、Qwen等主流开源模型
- **微调支持**：支持直接使用平台上的微调模型（如语言微调、指令微调模型），省去自行下载和转换的繁琐过程
- **API兼容**：自动适配不同平台的模型下载API，简化模型获取流程

2. 部署方式灵活 01:29

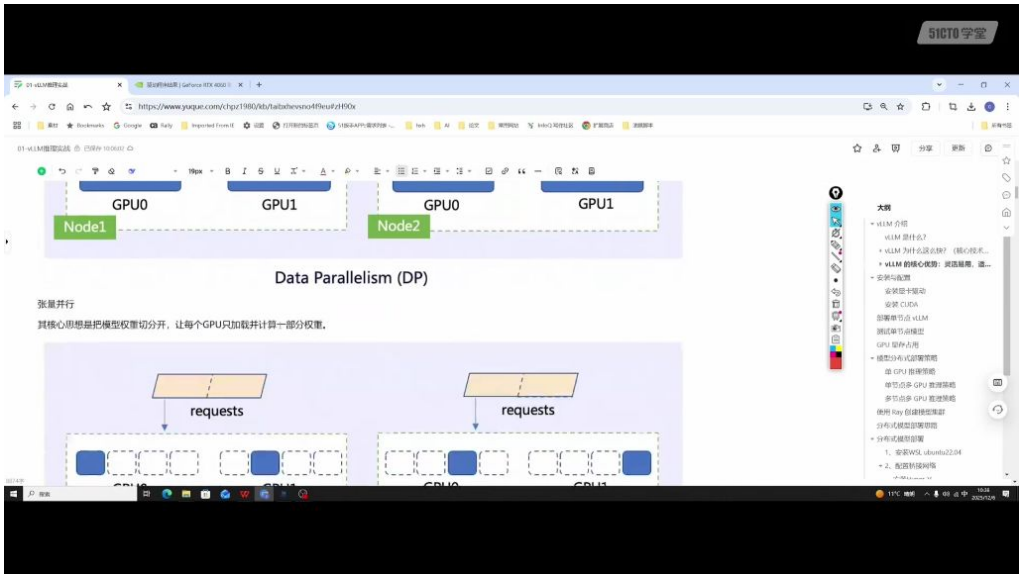
1）支持多种解码算法 01:33



- **并行采样**：适用于生成创意文本场景，可同时产生多个候选结果
- **束搜索(beam search)**：适用于需要精准答案的任务，通过保留最优候选序列提高输出质量

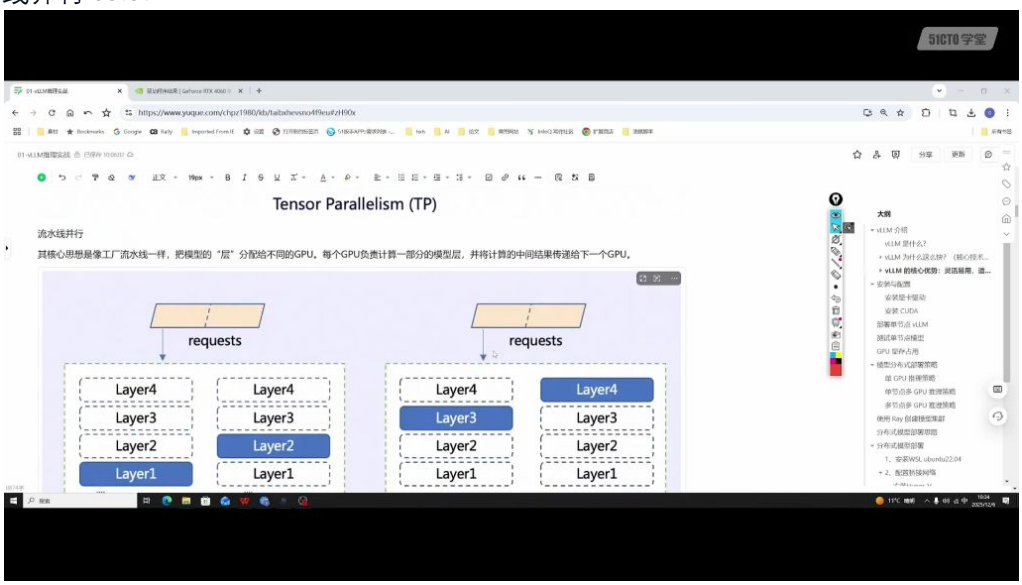
2）分布式推理支持 01:51

- 数据并行 02:42



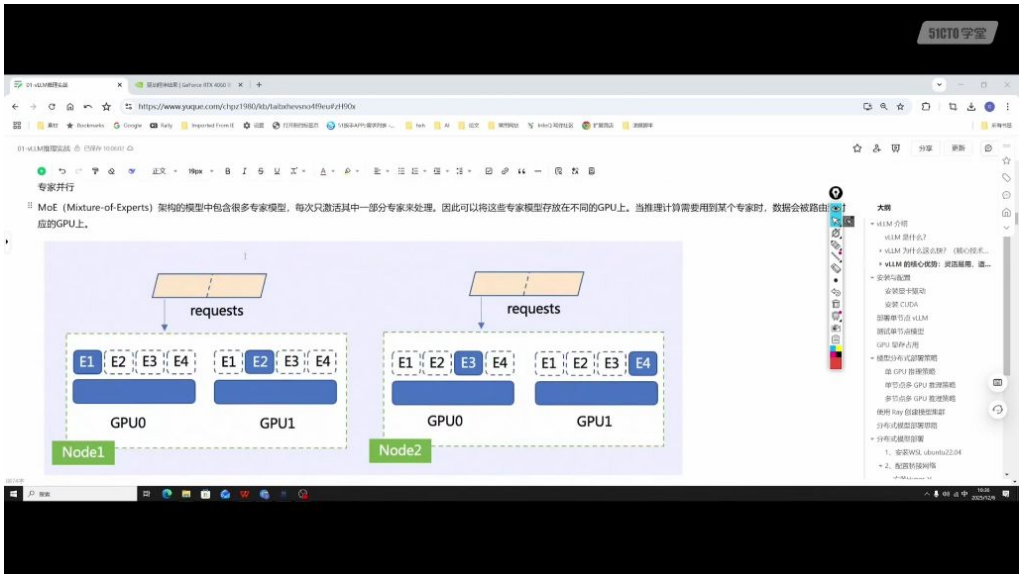
- **实现方式**：每个GPU保存完整模型副本，处理请求的不同数据分段
- **适用场景**：模型过大或请求量过高时，如千万级参数的模型部署
- **工作示例**：请求的前半部分由Node1的GPU0处理，后半部分由Node2的GPU1处理

- 张量并行 04:18
  - **权重分割**：将模型权重参数切分到不同GPU，如将W_{ij}矩阵分块存储
  - **计算优势**：多GPU并行计算提升吞吐量，运算后需合并结果
  - **典型应用**：适合参数规模达百亿级的大型模型推理
- 流水线并行 05:37



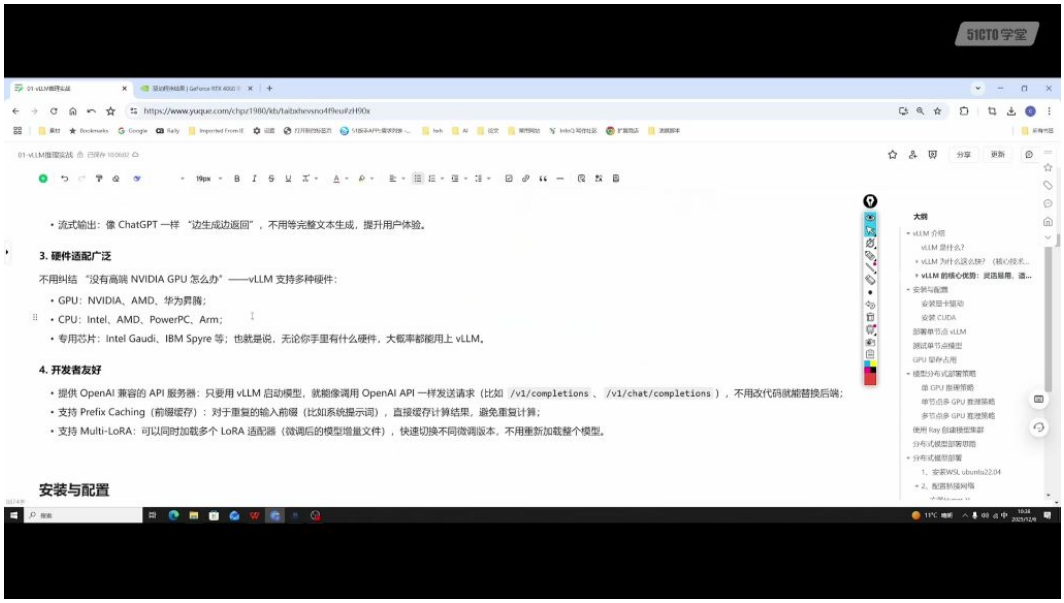
- **分层处理**：将神经网络不同层（如Layer1-4）分配到不同GPU
- **工作流程**：类似工厂流水线，各GPU处理指定层后传递中间结果
- **效率优化**：适用于32层/64层等深层网络模型的分布式推理

- 专家并行 06:48



- **MoE架构**：基于混合专家模型（如DeepSeek2），每个GPU存储不同专家模型
- **动态路由**：根据请求类型自动路由到对应专家（如翻译专家、医学专家）
- **资源利用**：仅激活相关专家，节省计算资源，支持超大规模模型部署

3. 硬件适配广泛 09:04



- **GPU支持**：兼容NVIDIA/AMD/华为昇腾等多种显卡
- **CPU推理**：支持Intel/AMD/PowerPC/Arm等处理器（适合边缘计算场景）
- **专用芯片**：适配Intel Gaudi、IBM Spyre等AI加速芯片
- **边缘部署**：可在无GPU环境下运行小模型（如0.5B参数模型）

4. 开发者友好 09:53

- **API兼容**：提供OpenAI风格接口（/v1/completions等），无需修改调用代码
- **前缀缓存**：对重复系统提示词缓存计算结果，避免重复推理开销
- **多LoRA支持**：可同时加载多个微调适配器，快速切换不同模型版本
- **加速技巧**：
  - 投机解码：用小模型预测结果后由大模型验证修正
  - 分块预填充：将长文本请求分块处理，避免内存峰值过高

二、知识小结

知识点	核心内容	技术优势/易混淆点	适用场景

VL LM核心优势	灵活易用，支持多业务场景	**运算效率高、部署兼容性强**	开源模型下载与微调
模型兼容性	无缝对接Hugging Face、ModelScope等平台	直接使用已上传的微调模型（如语言/指令微调）	开源模型生态整合
分布式推理	支持多节点/多GPU协同推理	**模型过大**或**请求量过高**时必需	超大规模语言模型部署
数据并行	每个GPU保存完整模型副本，处理请求分段数据	**请求内数据分段处理**	高并发请求场景
张量并行	模型权重切割分配至不同GPU	**参数分布式运算**，需结果合并	提升系统吞吐量
流水线并行	模型层拆分至不同GPU执行	**按层分配计算资源**	深度神经网络推理加速
专家并行	混合专家模型（如DeepSeek 2）按需路由	**专家动态激活**（如翻译/医学专家）	多领域任务协同
硬件兼容性	支持NVIDIA/AMD/华为GPU及CPU推理	**边缘计算可用**（小模型CPU推理）	无GPU环境部署
开发者友好性	兼容OpenAI API标准，支持前缀缓存	**降低SDK开发成本**	第三方应用集成