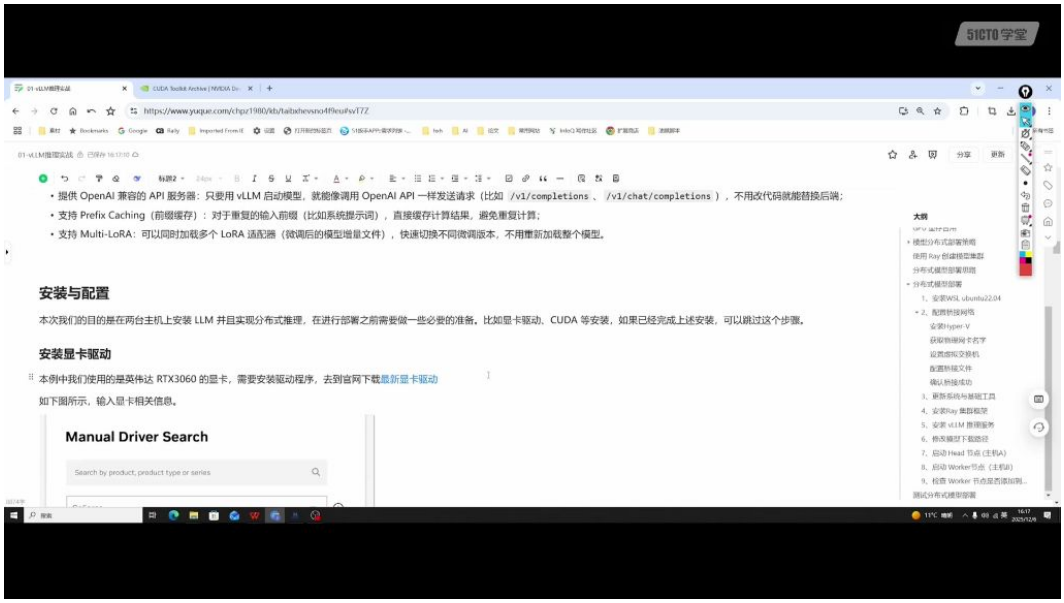
以下为AI生成的图文笔记的内容

一、vLLM介绍 00:00

1. vLLM的优势 00:05

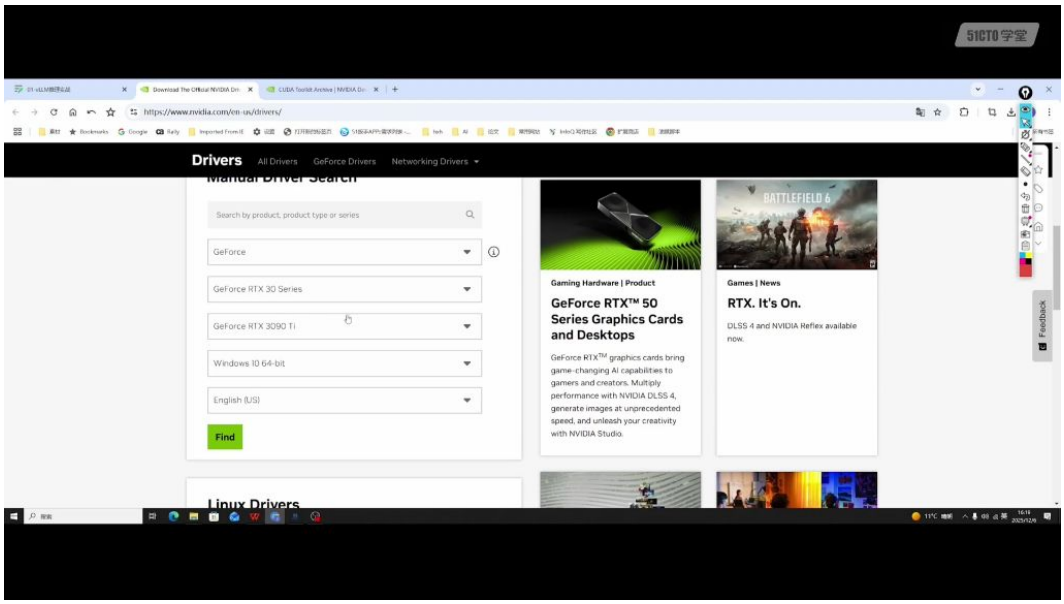


- **大模型推理优化**：天生为大语言模型设计，在分布式并行和算法优化量化方面表现优异
- **API兼容性**：提供OpenAI兼容的API服务器（如/v1/completions接口），无需修改代码即可替换后端
- **前缀缓存**：支持Prefix Caching技术，对重复输入前缀（如系统提示词）直接缓存计算结果
- **多适配器支持**：支持Multi-LoRA，可同时加载多个LoRA适配器（微调后的模型增量文件），快速切换不同微调版本

二、vLLM的安装与配置 00:20

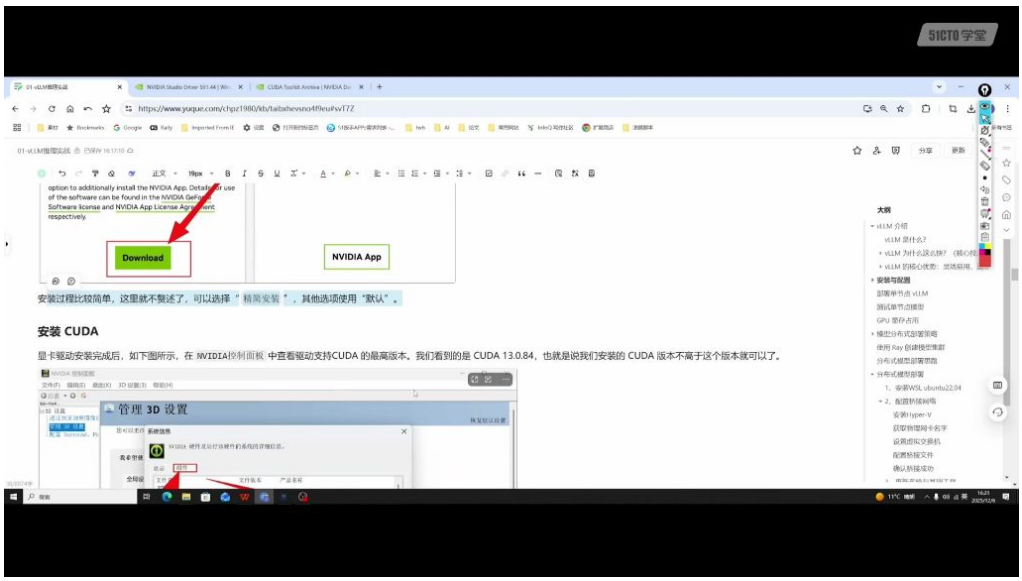
1. 准备工作 00:30

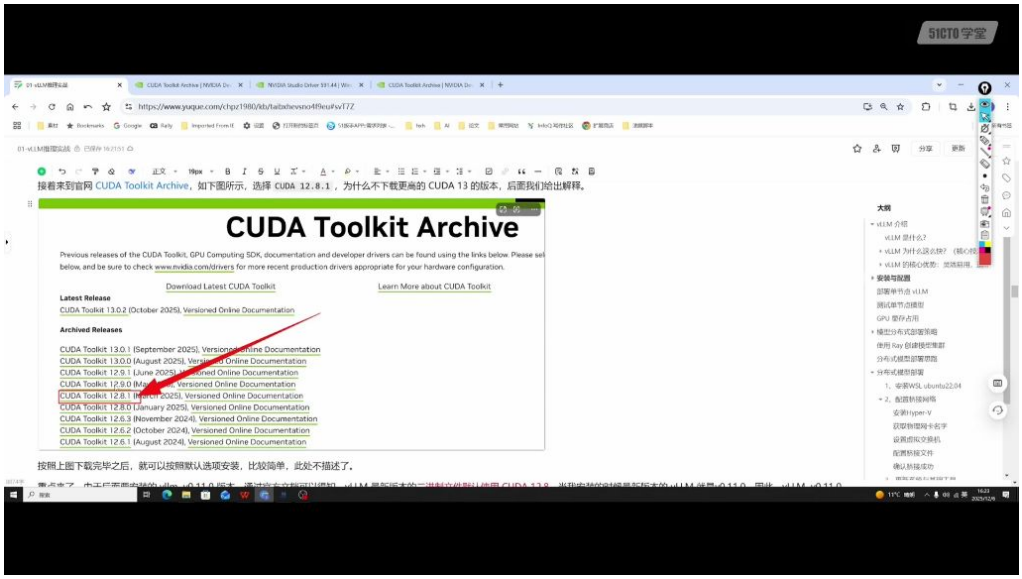
1）安装显卡驱动 00:33



- **硬件选择**：支持消费级显卡（如RTX3060/4060），建议2000元左右显卡用于测试
- **驱动类型**：
  - Game Ready驱动：面向游戏玩家
  - Studio驱动：面向开发者/工作室（推荐用于大模型训练）
- **安装步骤**：
  - 访问NVIDIA官网
  - 选择显卡系列（如RTX30系列）
  - 选择操作系统版本（Windows10/11）
  - 下载Studio驱动并选择"精简安装"

2）安装CUDA 03:30

- 查找支持的CUDA版本 03:32
  - 

  - **版本查询方法**：
    - 打开NVIDIA控制面板
    - 进入"管理3D设置"→"系统信息"→"组件"
    - 查看"NVCUDA64.DLL"对应的版本号（如12.9.76）
  - **安装原则**：安装的CUDA版本应等于或低于显卡驱动支持的版本
- CUDA Toolkit Archive 05:42
  - 

  - **版本选择**：推荐CUDA12.8.1（与vLLM v0.11.0默认兼容）

- **兼容性说明**：vLLM二进制文件默认使用CUDA12.8编译，若使用其他版本需手动安装适配组件
- **安装命令**：

```
#### 三、指定CUDA版本安装vLLM（示例为CUDA11.8）

export VLLM_VERSION=$(curl -s https://api.github.com/repos/vllm-project/vllm/releases/latest | jq -r .tag_name | sed 's/^v//')
export CUDA_VERSION=118
pip install https://github.com/vllm-project/vllm/releases/download/v${VLLM_VERSION}/vllm-${VLLM_VERSION}+cu${CUDA_VERSION}-cp38-abi3-manylinux1_x86_64.whl --extra-index-url https://download.pytorch.org/whl/cu${CUDA_VERSION}
```

1. 查看CUDA版本 08:26

- **验证命令**：在PowerShell中执行nvcc --version
- **输出示例**：

```
nvcc: NVIDIA (R) Cuda compiler driver
Built on Fri_Feb_21_20:42:46_Pacific_Standard_Time_2025
Cuda compilation tools, release 12.8, V12.8.93
```

- **版本确认**：确保安装版本与显卡驱动支持的版本一致

四、知识小结

知识点	核心内容	考试重点/易混淆点	难度系数
vLLM特性	天生为大语言模型推理设计，支持分布式并行、算法优化与量化	量化实现原理与性能提升关系	★★
显卡驱动安装	需选择NVIDIA Studio驱动（非Game Ready），支持消费级显卡（如RTX 3060/4060）	**驱动类型选择**（Studio vs. Game Ready）	★
CUDA版本匹配	需通过NVIDIA控制面板查询驱动支持的**最高CUDA版本**（如12.9.76），安装版本需≤该版本	版本兼容性验证方法（nvidia-smi与nvcc --version）	★★★
vLLM与CUDA依赖	vLLM v0.11.0默认集成CUDA 12.8二进制文件，若使用其他版本需手动配置	**CUDA 13.0等非默认版本的适配命令**	★★★★
部署方式	支持Docker容器与WSL分布式安装（后续讲解）	容器化部署与原生部署差异	★★★
硬件成本建议	推荐2000元级显卡（如RTX 3060）测试，高端卡（4090/5090）视经济能力选择	消费级与专业级显卡性能对比	★