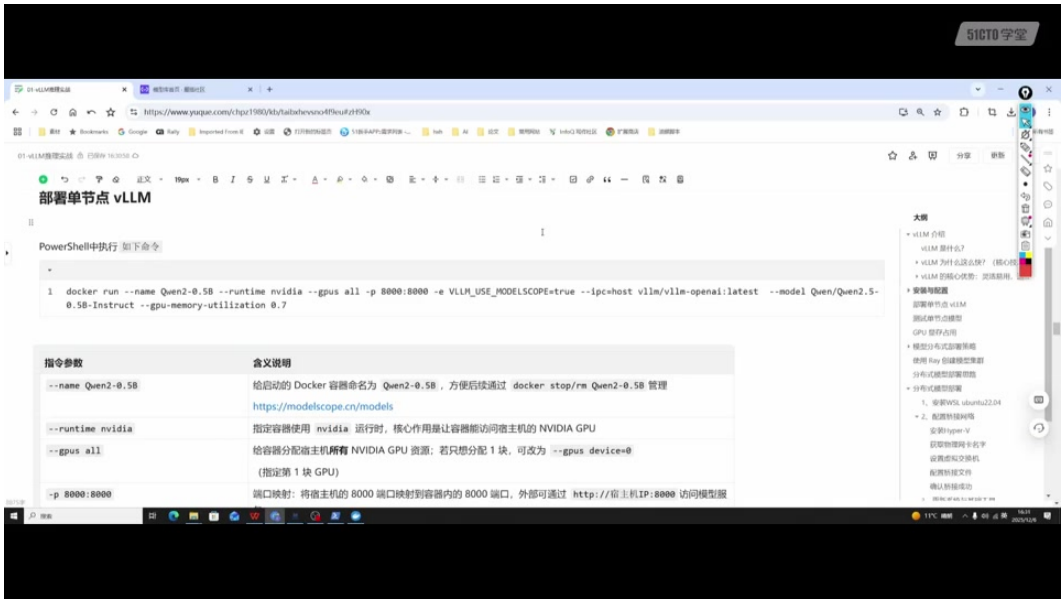
以下为AI生成的图文笔记的内容

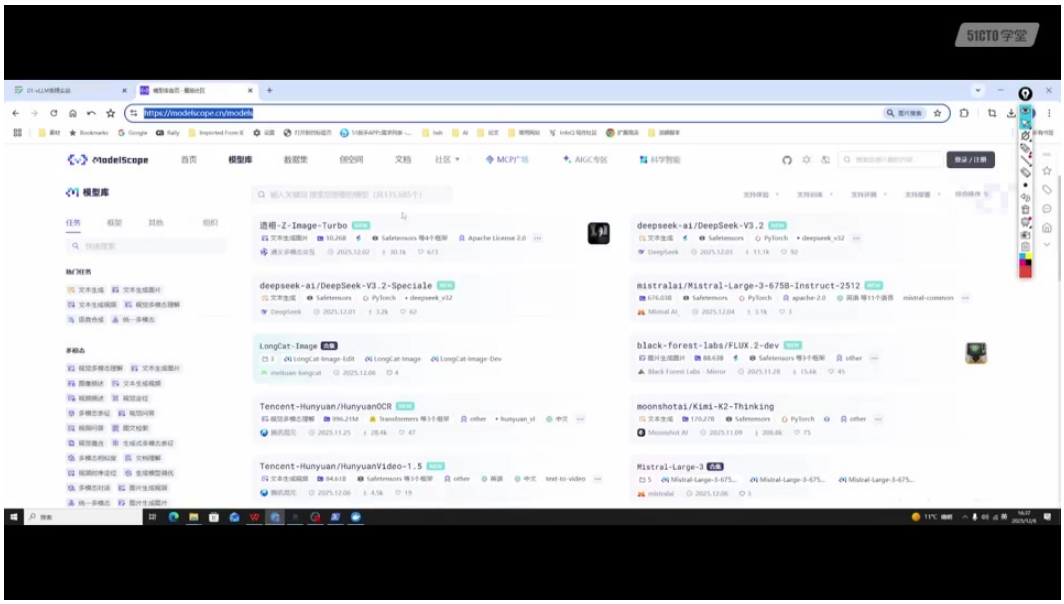
一、vLLM进行模型安装与部署 00:00

1. 命令教学 01:27



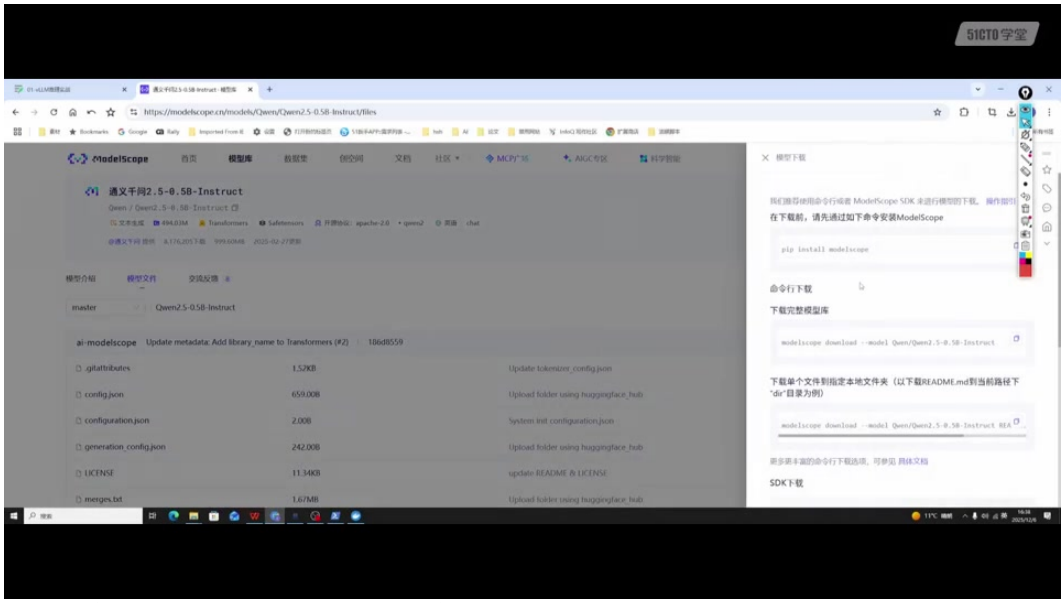
- **容器命名**：--name Qwen2-0.5B用于指定容器名称，方便后续通过docker stop/rm管理容器
- **GPU运行时**：--runtime nvidia让容器能访问宿主机NVIDIA GPU资源
- **GPU分配**：--gpus all分配所有GPU资源，若需指定单块GPU可改为--gpus device=0
- **端口映射**：-p 8000:8000将宿主机8000端口映射到容器内8000端口，外部通过http://宿主机IP:8000访问服务
- **模型源设置**：-e VLLM_USE_MODELSCOPE=true指定从魔搭社区自动下载模型
- **内存共享**：--ipc=host解决大模型运行时共享内存不足问题，避免OOM错误
- **镜像选择**：使用官方镜像vllm/vllm-openai:latest，已集成vLLM框架和OpenAI兼容接口
- **显存控制**：--gpu-memory-utilization 0.7限制GPU显存使用率为70%，预留30%防止溢出

2. 模型库 05:22



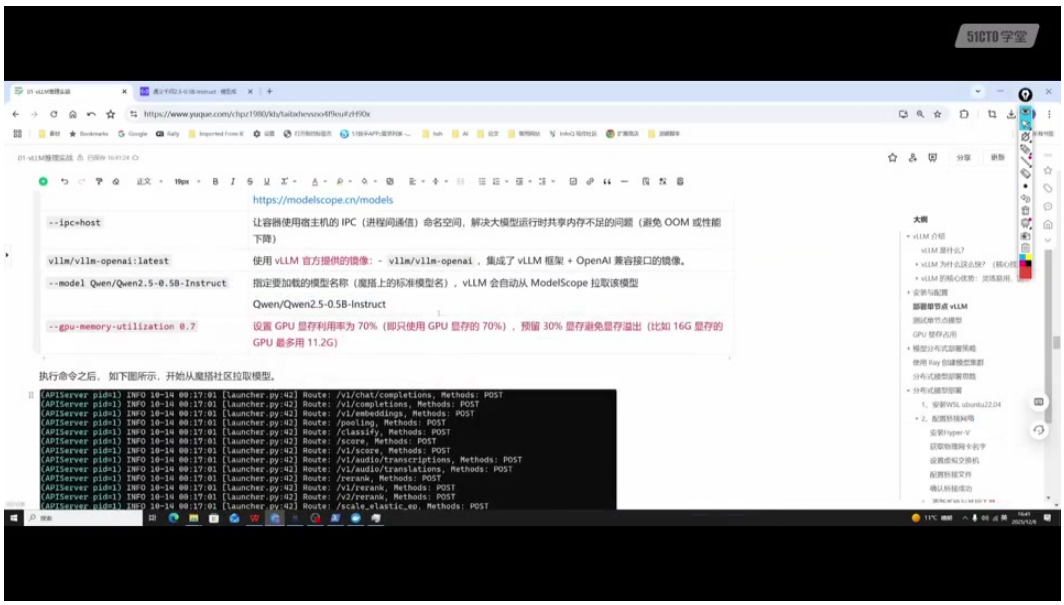
- **访问方式**：通过https://modelscope.cn/models访问开源模型库
- **模型搜索**：支持按关键字搜索（如"Qwen2"），可查看模型参数、训练方法和文件信息
- **模型特点**：通义千问2.5-0.5B-Instruct模型具有多语言支持（29种语言）、长文本生成（8K tokens）等特性
- **模型文件**：主要下载model.safetensors文件，大小约1GB

3. 模型下载 06:18



- **自动下载**：通过vLLM框架自动从指定社区拉取模型（推荐方式）
- **手动下载**：
  - 命令行：pip install modelscope后使用modelscope download命令
  - SDK方式：支持断点续传，示例代码：
  - Git方式：git clone https://www.modelscope.cn/Qwen/Qwen2.5-0.5B-Instruct

4. 执行命令 09:42



- **完整命令**：
- **执行过程**：
  - 下载约10GB的官方镜像
  - 自动拉取约1GB的模型文件

- 启动后可在Docker Desktop查看运行状态和日志
- **资源监控**：通过Docker Desktop可观察GPU显存占用情况（示例中使用RTX 4060显卡）
- **服务验证**：成功启动后可通过http://localhost:8000访问模型服务

二、知识小结

知识点	核心内容	技术要点/易混淆点	难度系数
Docker部署VL LM模型	使用Docker Desktop加载并运行千问2-0.5B模型镜像，通过容器化部署实现模型推理服务	**关键参数**：--runtime=nvidia（GPU资源映射）、-p 8000:8000（端口映射）、--ipc=host（共享内存优化）	★★★
模型下载与配置	从摩搭社区自动下载千问2-0.5B模型文件（约1GB），依赖VL LM官方镜像（约10GB）集成框架组件	**模型来源**：vllm_use_model_scope=true指定摩搭社区；**显存限制**：--gpu-memory-utilization=0.7（避免显存溢出）	★★
GPU资源分配	容器通过--gpus=all调用宿主机全部GPU（如RTX 4060），或指定单卡（--gpus=device=0）	**显存管理**：消费级显卡（8G/12G显存）需限制利用率，预留资源	★★★★
推理服务访问	容器内VL LM推理服务器通过8000端口暴露，宿主机通过localhost:8000调用	**端口冲突**：需确保宿主机8000端口未被占用	★★
模型版本选择	使用摩搭社区提供的Qwen2-0.5B-Instruct指令微调版本，适配OpenAI兼容接口	**镜像版本**：vllm/openai:latest确保框架兼容性	★★