以下为AI生成的大纲笔记的内容



一、vLLM推理实战 00:00

1.vUM介绍

1) vLLM是什么

- vLLM服务器安装:使用docker进行安装
- 模型下载:在vLLM服务器中下载模型
- 模型规格:加载的是instructor模型，规模为千万参数级别(2.5-0.5b)

2) vLLM测试单节点模型 00:16

- 安装与配置 00:26
  - pip install streamlit requests openai 00:32
    - 组件安装:pip install streamlit requests openai
    - 测试方法:通过streamlit作为UI界面测试模型
    - 调用方式:使用openAI的SDK调用模型能力
    - 安装验证:requirement already satisfied表示已安装
    - 核心组件:streamlit的web UI组件、网络请求组件、openAI SDK
    - 安装环境:可通过WINDOWS power share管理员权限安装
- 部署单节点vLLM 01:18
  - streamlit脚本 01:27
    - Streamlit UI设置：包括页面title、icon、侧边栏配置等基础界面元素
    - API配置参数：主机地址(localhost:8000)、API密钥(可选)、模型名称(千问2.5-0.5B instruct)
    - 模型参数设置：temperature(回答随机性)、max_tokens(最大生成token数)、对话重置按钮
    - 用户输入处理：使用st.chat_message显示用户消息，通过输入框获取问题
    - OpenAI API调用：创建client实例(base_url指向vLLM服务端)，配置流式请求参数(model/messages/temperature等)
    - 端口映射原理：本地8000端口通过Docker映射到容器内vLLM服务的8000端口
    - 流式响应处理：通过循环逐字接收响应，使用placeholder动态展示生成内容
    - 调试运行方法：在.py文件目录执行streamlit run命令启动Web UI界面

二、结束 06:26

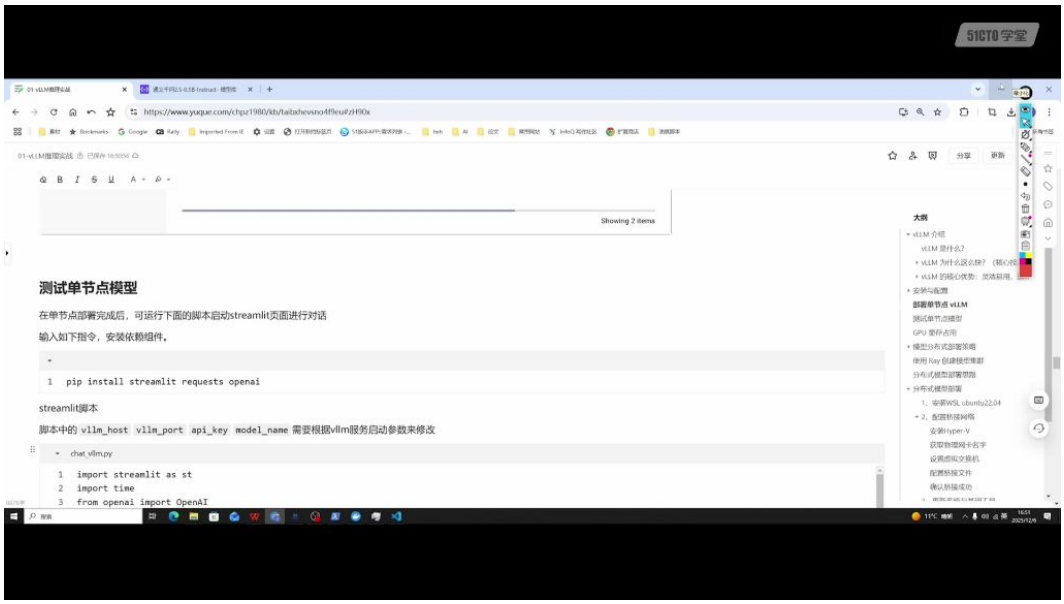
- 模型复制功能:通过复制按钮直接获取模型名称，避免手动设置错误。
- 参数设置:包括温度参数(如0.7)和最大token数等关键推理参数配置。
- 模型性能限制:0.5b规模模型仅能处理简单问题(如基础问答)。
- 端口映射机制:本地8080端口映射到容器内8000端口实现服务访问。
- 日志监控:通过容器日志可查看模型调用状态(200成功)、吞吐量(10.4 tokens/s)等实时指标。
- API调用流程:使用OpenAI SDK请求模型接口，通过端口映射获取推理结果。
- 性能指标解读:日志包含PID、prompt throughput(14 tokens/s)等关键性能参数。

以下为AI生成的图文笔记的内容

一、vLLM推理实战 00:00

1. vUM介绍

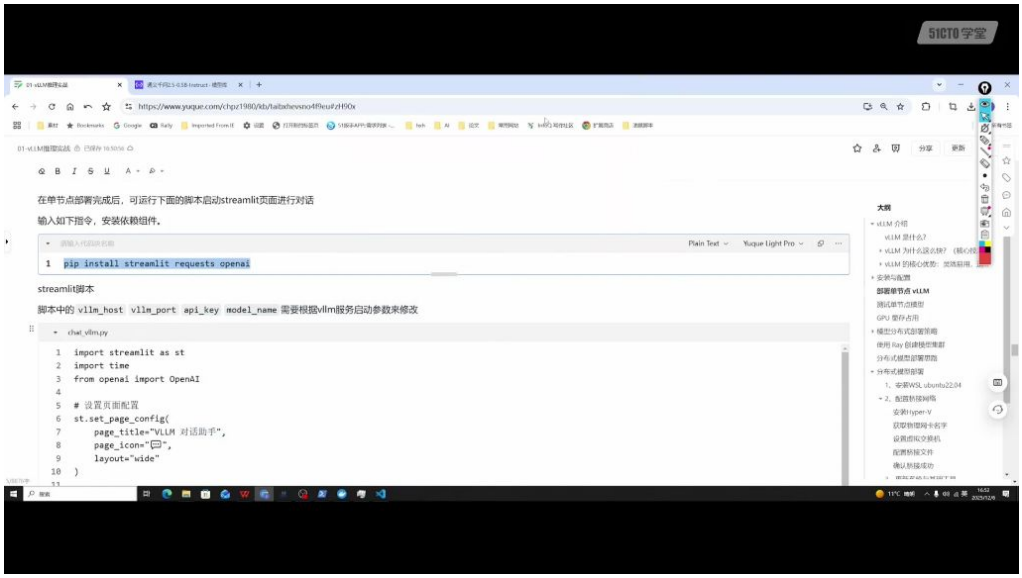
1）vLLM是什么



- **定义**: 一个高性能的大语言模型推理框架
- **特点**: 支持OpenAI兼容API，可用于部署和测试大语言模型
- **应用场景**: 主要用于单节点和分布式模型部署

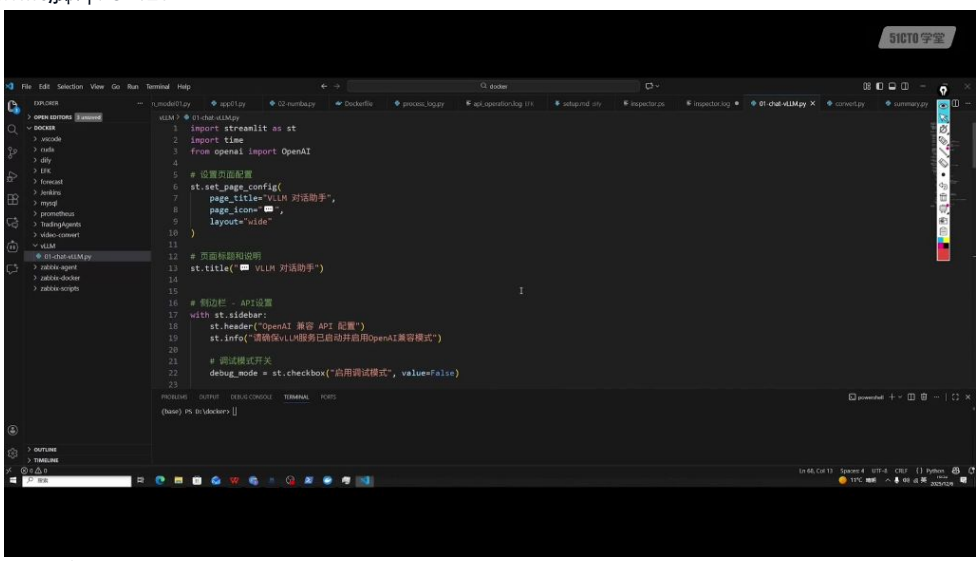
2）vLLM测试单节点模型 00:16

- 安装与配置 00:26

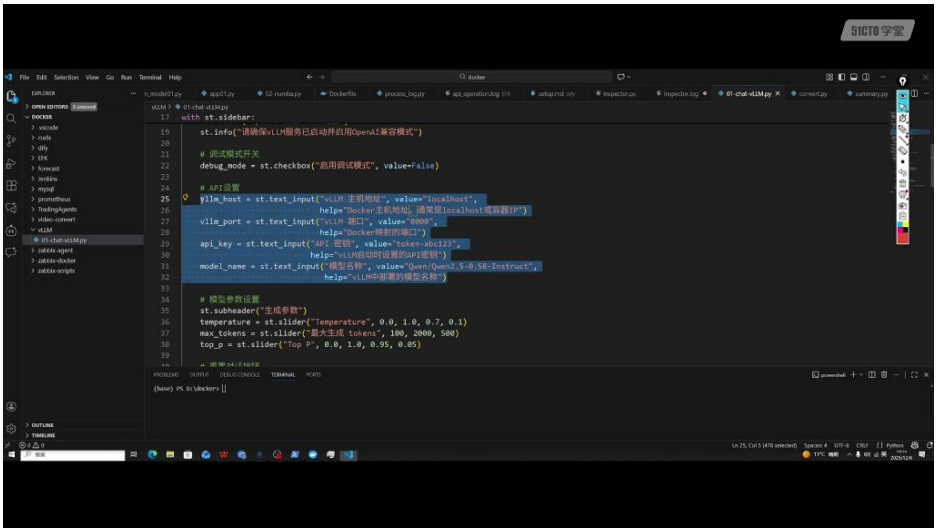


-
- **核心组件**:
  - **streamlit**: 用于构建Web UI界面
  - **requests**: 处理网络请求
  - **openai**: OpenAI SDK用于调用模型API
- **安装命令**: pip install streamlit requests openai
- **验证方法**: 出现"Requirement already satisfied"提示表示已安装

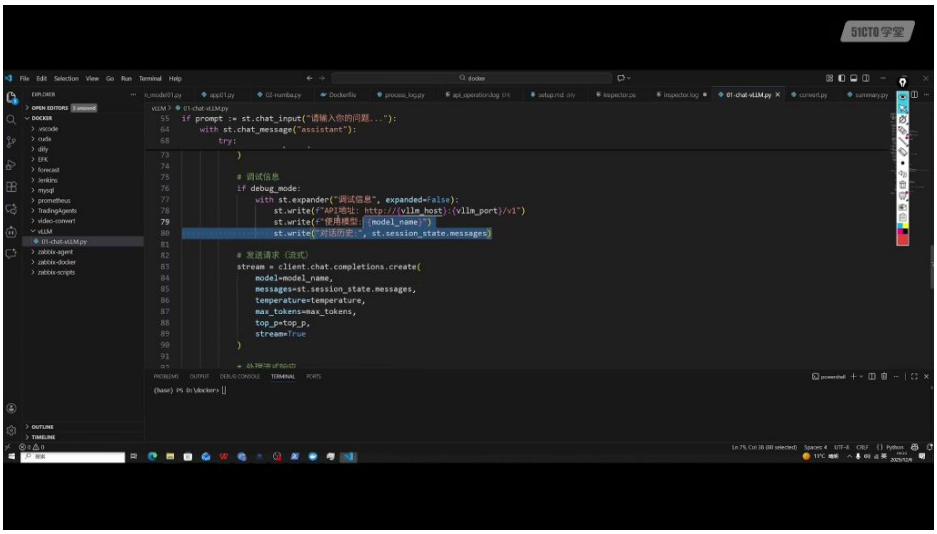
- 部署单节点vLLM 01:18
  - streamlit脚本 01:27



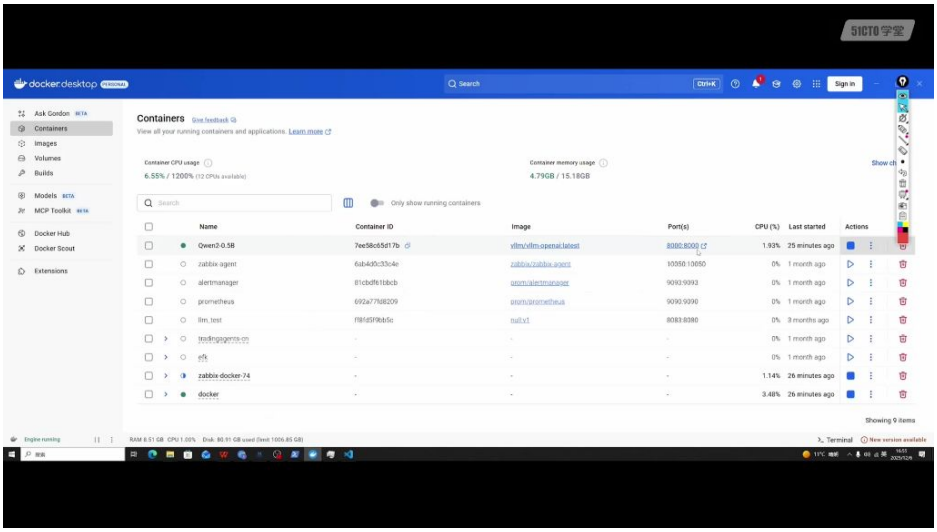
  -
  - **关键参数**:
    - **vllm_host**: 本地地址通常为"localhost"
    - **vllm_port**: 默认8000端口（需与Docker映射端口一致）
    - **api_key**: 可设置为空或任意值（如"token-abc123"）
    - **model_name**: 需与vLLM服务启动参数一致（如"Qwen/Qwen2.5-0.5B-Instruct"）



- **页面配置**:
  - 设置页面标题、图标和布局方式
  - 侧边栏包含API设置和模型参数调整
- **模型参数**:
  - **Temperature**: 控制生成文本的随机性（0.0-1.0）
  - **最大生成tokens**: 限制响应长度（100-2000）
  - **Top P**: 影响采样策略（0.0-1.0）

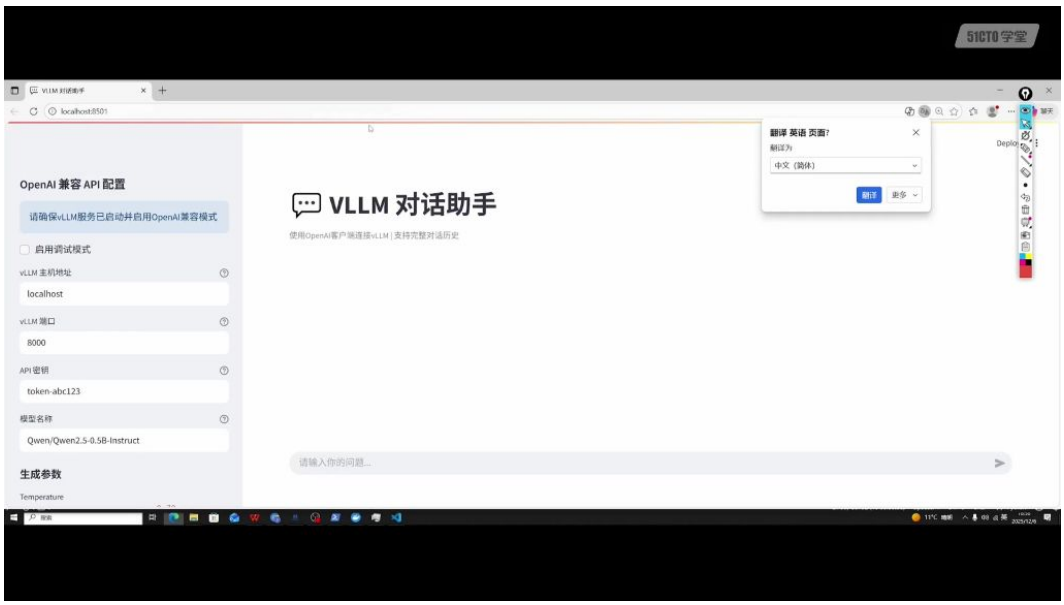


- **OpenAI客户端初始化**:
  - 使用base_url指向vLLM服务（格式: http://{vllm_host}:{vllm_port}/v1）
  - API密钥可留空或使用默认值
- **流式请求处理**:
  - 使用client.chat.completions.create方法
  - 设置stream=True实现逐字输出效果
  - 通过循环处理chunk.choices[0].delta.content获取响应内容



- **映射原理**: 本地8000端口映射到容器内vLLM服务的8000端口
- **验证方法**: 在Docker Desktop中查看容器端口绑定情况

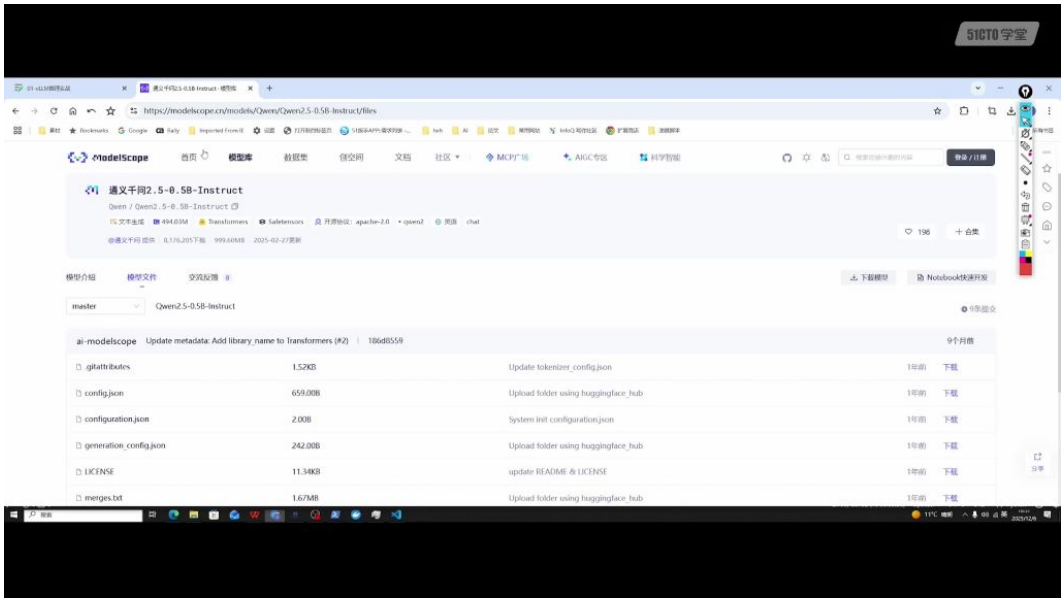
2. 模型测试与交互



- **启动方法**: 在脚本目录执行streamlit run 01-chat-vLLM.py
- **界面功能**:
  - 显示对话历史
  - 提供用户输入框
  - 支持参数实时调整
  - 包含重置对话按钮
- **调试信息**:
  - 可查看API地址和模型名称
  - 显示完整对话历史记录

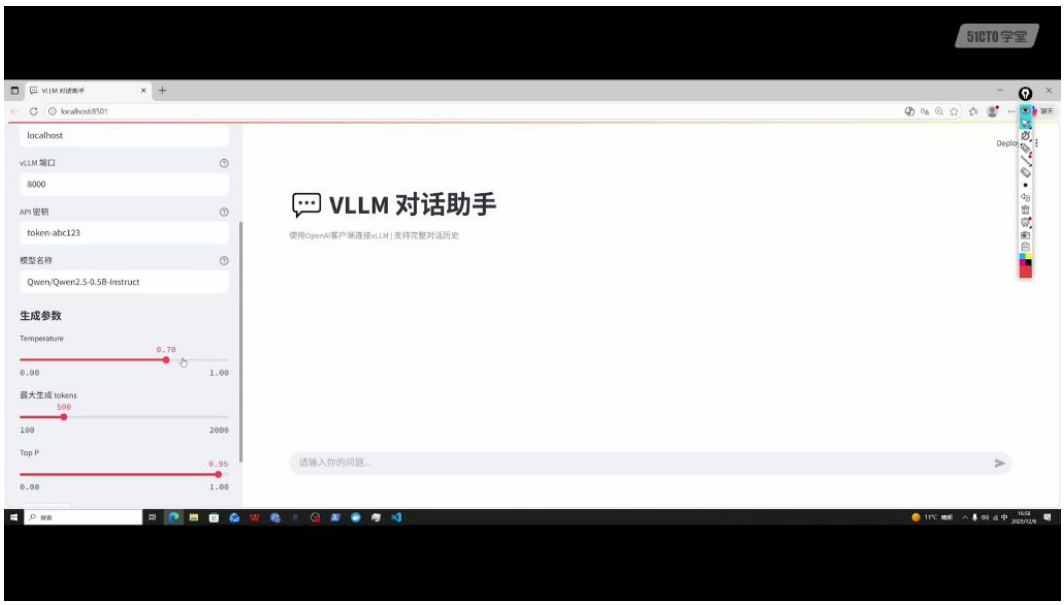
二、通义千问2.5-0.5B模型部署与调用 06:26

1. 模型基本信息



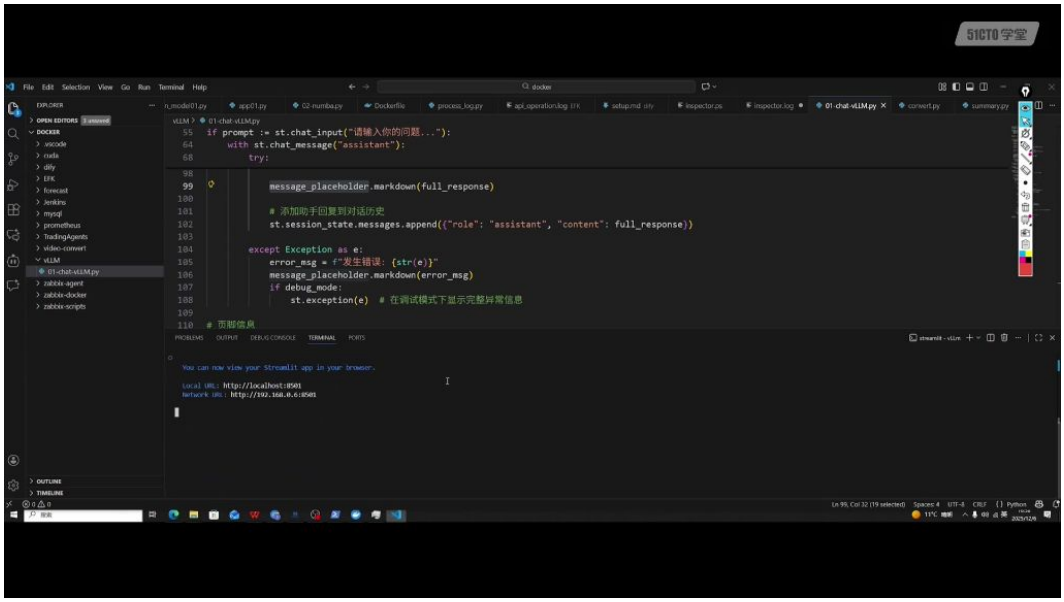
- **模型名称**: Qwen/Qwen2.5-0.5B-Instruct
- **模型类型**: 文本生成模型
- **框架支持**: Transformers, Safetensors
- **开源协议**: Apache-2.0
- **模型大小**: 49403MB
- **开发机构**: 阿里云通义千问团队

2. 模型部署配置



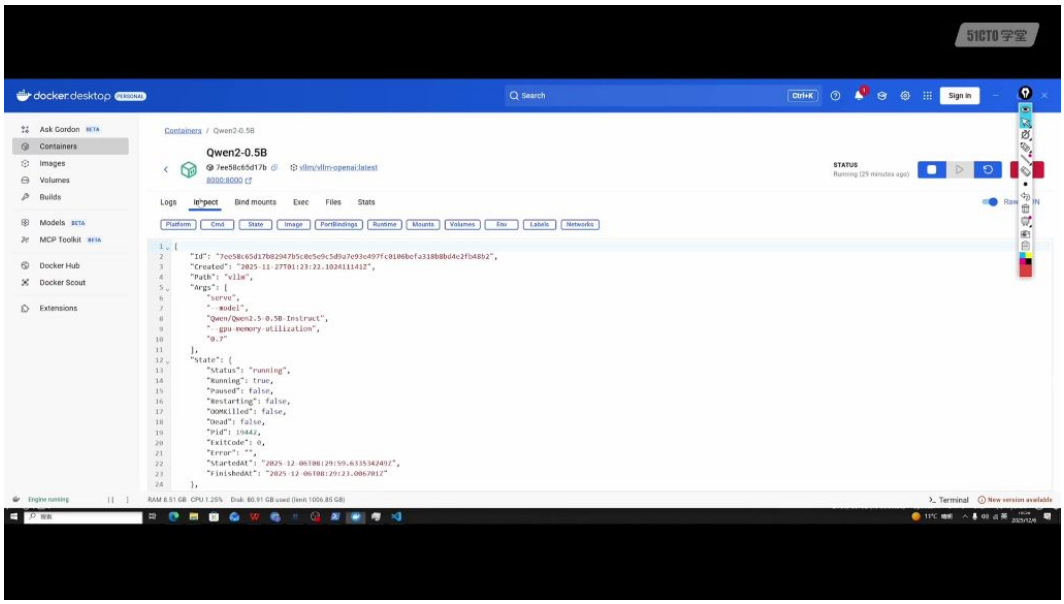
- **部署方式**: 使用vLLM框架部署
- **API连接**:
  - **端口**: 8000(容器内)/8501(映射)
  - **API密钥**: token-abc123
- **生成参数设置**:
  - **Temperature**: 0.7
  - **最大生成tokens**: 500
  - **Top P**: 0.95

3. 模型调用实践



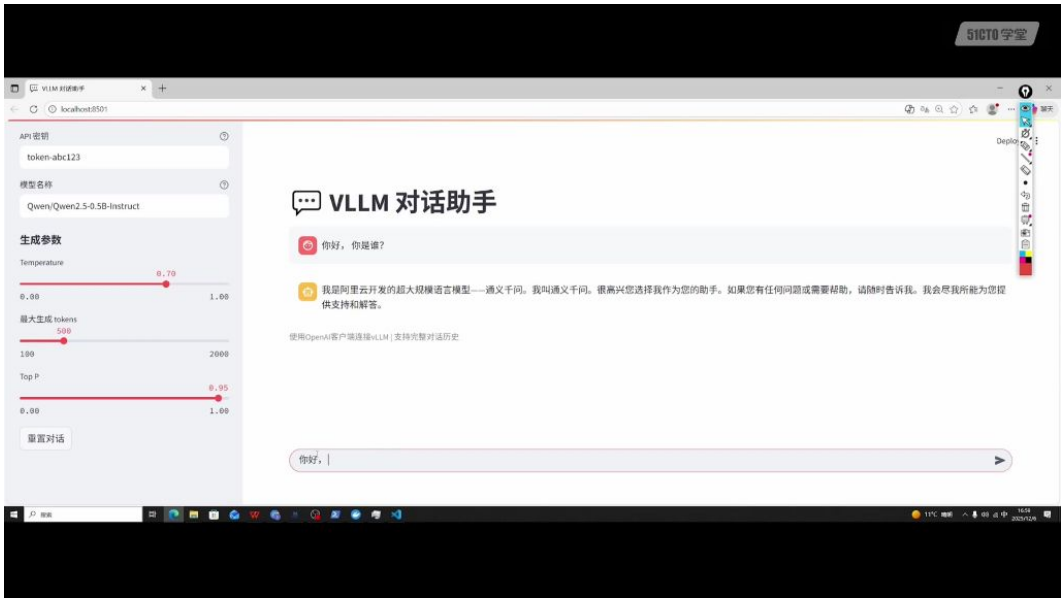
- **调用流程**:
  - 通过OpenAI客户端SDK连接vLLM服务
  - 支持完整对话历史记录功能
  - 错误处理机制包含调试模式异常显示
- **性能特点**:
  - 0.5B规模模型适合简单问答
  - 响应速度受参数配置影响

4. 容器运行监控



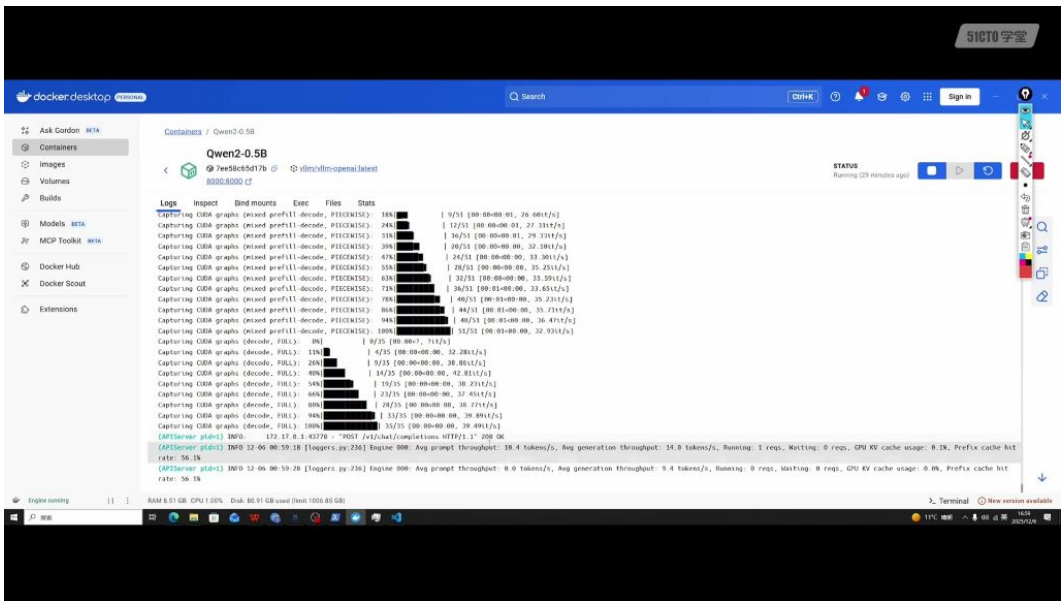
- **容器配置**:
  - 镜像: vllm-openai:latest
  - 运行时间: 25分钟
  - 资源占用: RAM 8.51GB, CPU 1.25%
- **启动参数**:
  - 模型路径: Qwen/Qwen2.5-0.5B-Instruct
  - GPU内存利用率设置

5. 模型交互示例



- **基础问答**:
  - **身份识别**: 模型正确识别自身为"阿里云开发的通义千问"
  - **响应格式**: 包含标准问候语和帮助提示
- **科学问答**:
  - **天空颜色解释**: 详细说明瑞利散射原理
  - **回答特点**: 包含大气成分、光波特性等多角度解释

6. 性能日志分析



- **关键指标**:
  - **吞吐量**: 平均提示处理10.4 tokens/s，生成14.8 tokens/s
  - **请求状态**: Running 1 reqs, Waiting 0 reqs
  - **缓存效率**: CPU缓存使用率8.1%，前缀缓存命中率56.1%
- **API调用**:
  - 成功响应HTTP 200状态码
  - 调用路径: /v1/chat/completions

三、知识小结

知识点	核心内容	技术要点/易混淆点	难度系数
Docker部署vLLM服务器	使用Docker安装vLLM服务器并加载千问2.5-0.5B Instruct模型	端口映射（本地8000↔容器8000）、模型名称需与摩搭社区一致	★★
Streamlit UI调用	通过Streamlit构建Web界面，集成OpenAI SDK调用模型API	base_url设置为localhost:8000，API密钥可留空	★★
OpenAI兼容API调用	使用chat.completions.create发起流式请求	参数包括model名称、messages缓存、temperature、max_tokens	★★★
模型性能监控	通过容器日志查看推理状态（如吞吐量、请求数）	average prompt throughput（10.4 tokens/s）、generation throughput（14 tokens/s）	★★
千问2.5-0.5B模型限制	适用于简单问答（如“天空为什么是蓝色的”），复杂任务能力有限	需严格匹配模型名称Qwen2.5-0.5B-Instruct	★★