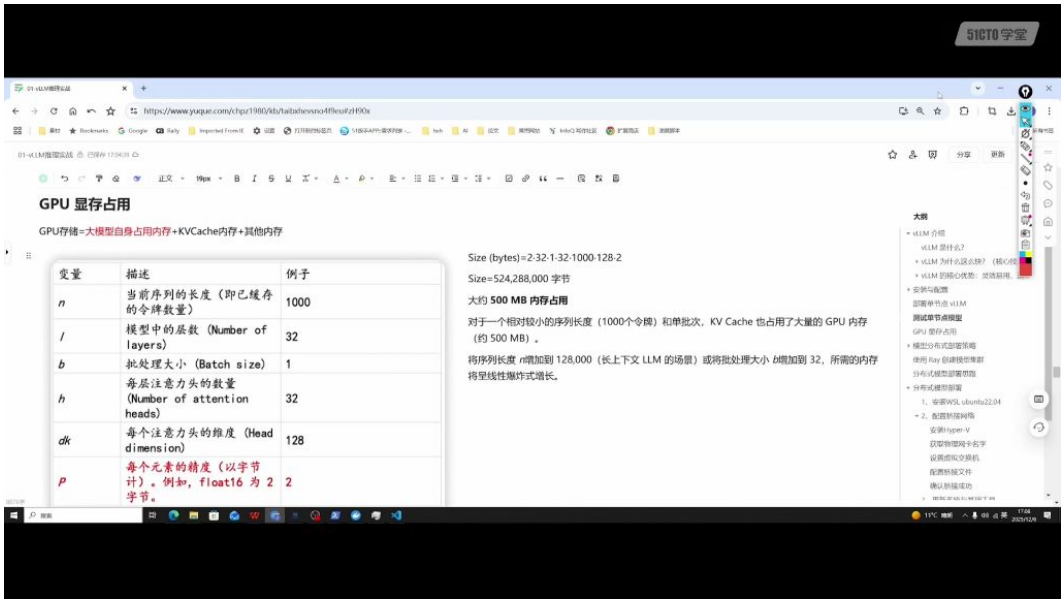
以下为AI生成的图文笔记的内容

一、vLLM介绍 00:00

1. GPU存储 00:56



- **计算公式**：GPU存储=大模型自身占用内存+KVCache内存+其他内存，具体计算公式为 $Size(bytes) = 2 \times 2 \times 1 \times 32 \times 1000 \times 128 \times 2$
- **关键参数**：
  - **序列长度**：当前已缓存的令牌数量，例如1000个令牌占用约500MB
  - **模型层数**：神经网络中的层数，示例中为32层
  - **批处理大小**：单次处理的请求批次数量
  - **注意力头**：每层注意力头的数量，示例为32个
  - **头维度**：每个注意力头的维度，示例为128
  - **精度**：每个元素的字节数，float16为2字节
- **内存增长规律**：当序列长度增加到128,000（长上下文场景）或批处理大小增加到32时，内存需求将呈线性爆炸式增长

2. 模型分布式部署策略 02:35

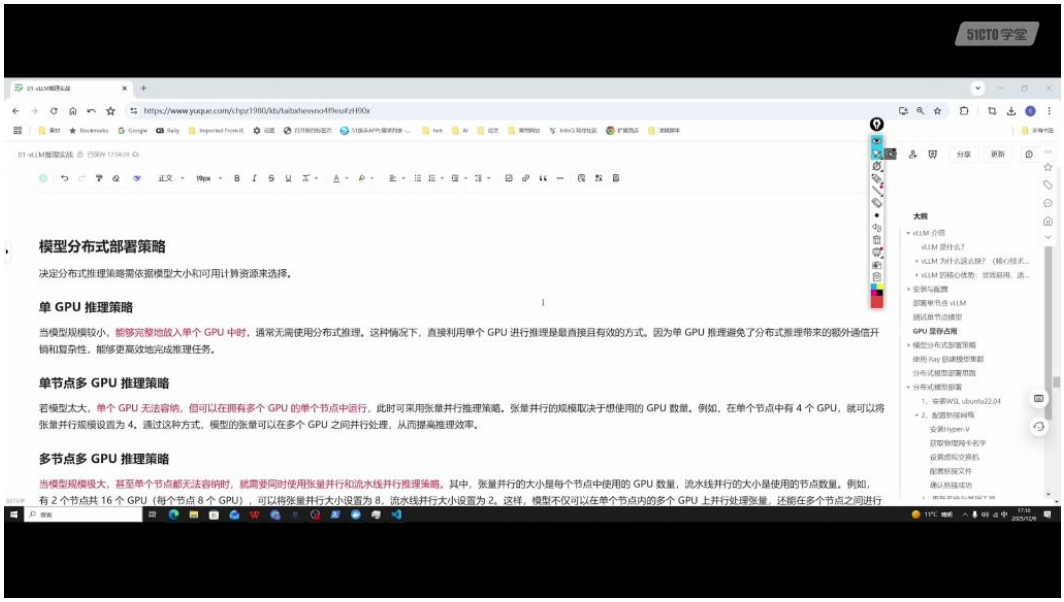
1）单GPU推理策略 02:38

- **适用场景**：模型规模较小，能完整放入单个GPU（如示例中的0.5B模型）
- **优势**：避免分布式通信开销，推理效率最高
- **实例**：使用8G显存的RTX 4060显卡可部署0.5B模型

2）单节点多GPU推理策略 03:30

- **适用场景**：模型超过单卡容量但可在单节点多GPU运行
- **技术方案**：采用张量并行策略，如4卡节点设置并行规模为4
- **特点**：模型张量在节点内多GPU间并行处理

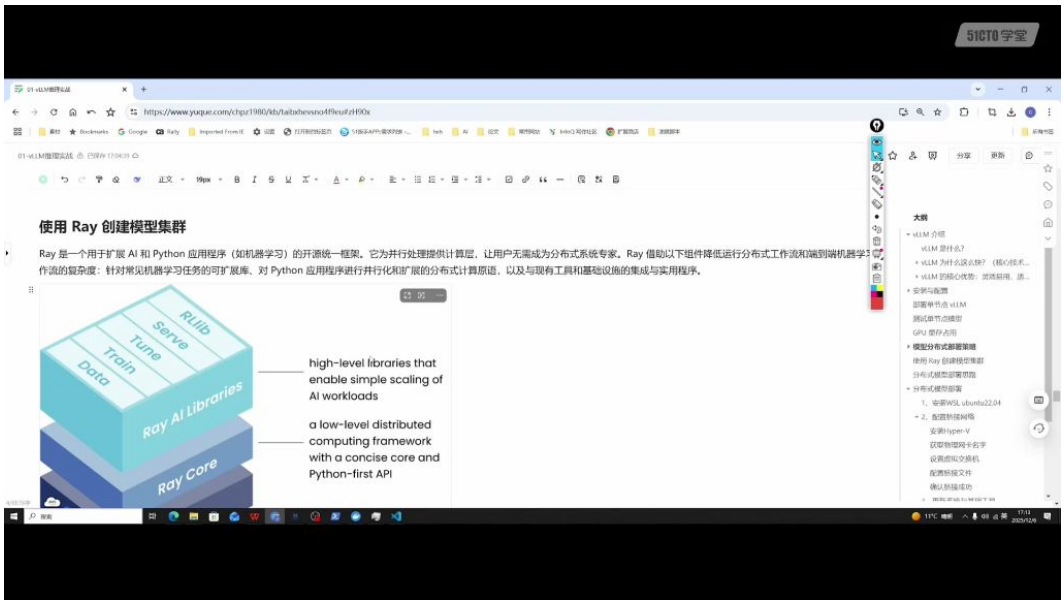
3）多节点多GPU推理策略 03:56



- **适用场景**：超大规模模型（如175B参数）
- **技术方案**：
  - **张量并行**：节点内GPU数量决定（如每节点8卡）
  - **流水线并行**：跨节点并行（如2节点16卡）
- **实例配置**：2节点16GPU（每节点8卡），张量并行8，流水线并行2

3. 使用Ray创建模型集群 05:09

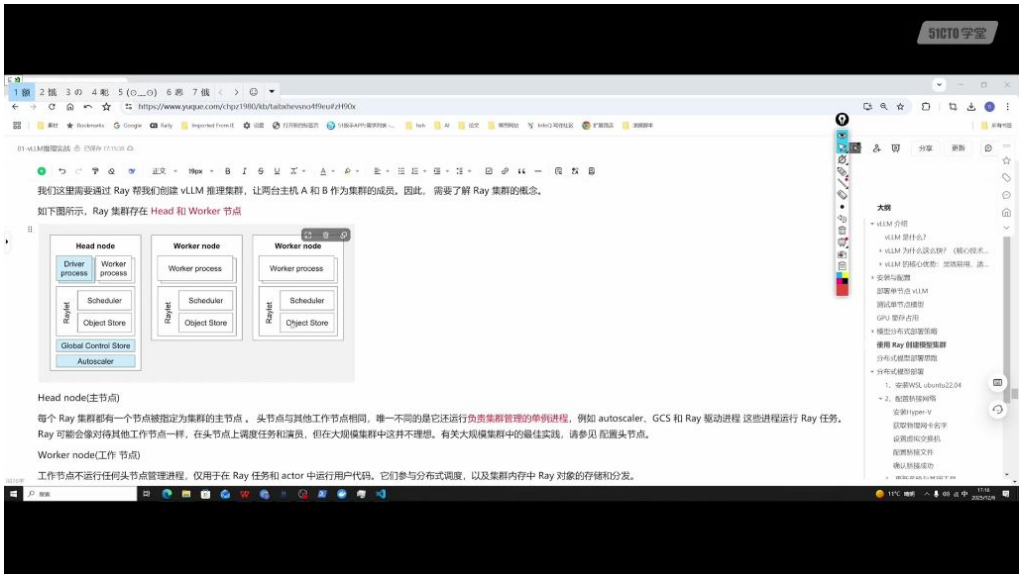
1）Ray的特点 05:49



- **核心能力**：
  - **并行处理**：提供计算层简化分布式工作流
  - **可扩展库**：支持机器学习任务扩展
  - **服务部署**：支持在线推理和微批处理
- **关键组件**：
  - **Tune**：超参数调优
  - **Serve**：可编程服务部署
  - **RLlib**：强化学习支持

2）Ray集群的概念 06:25

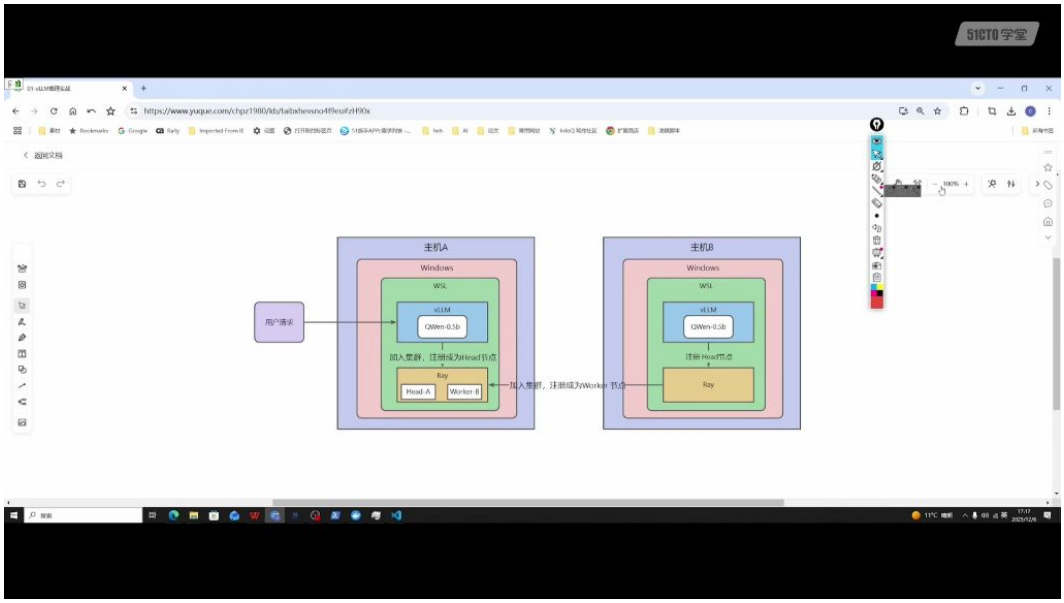
- Head node 08:31



-
- **管理功能**：
  - 运行autoscaler、GCS等单例进程
  - 全局控制存储和任务调度
  - 处理用户请求并协调工作节点
- **特点**：兼具计算和管理能力，但大规模集群中应避免过度负载

- Worker node 08:52
  - **核心职责**：
    - 执行具体分布式任务
    - 参与内存对象存储分发
    - 不运行管理进程
  - **工作模式**：接收head节点调度的推理任务并返回结果

3）分布式模型部署思路 09:03



-
- **硬件配置**：
  - 主机A（Head节点）：Windows+WSL Ubuntu 22.04
  - 主机B（Worker节点）：同配置
- **软件架构**：
  - 各节点运行vLLM服务加载0.5B模型
  - Head节点注册到Ray集群管理任务

- Worker节点加入集群执行推理
- **请求流程**：用户→Head节点→任务分发→Worker节点→结果聚合→用户

二、知识小结

知识点	核心内容	技术难点/关键点	应用场景
GPU显存占用因素	序列长度、模型层数、批处理大小、注意力头数量及维度、模型精度、KV缓存	**显存需求计算**：各参数乘积关系导致显存需求指数级增长	大模型推理场景
单GPU推理策略	模型完整加载到单张显卡（如演示中的8G显存RTX 4060运行0.5B模型）	**显存瓶颈**：模型参数量超过单卡容量时无法使用	小规模模型部署
单节点多GPU策略	单服务器多卡并行（如4张GPU卡通过参数/张量/层数并行）	**并行技术选择**：不同并行策略的通信开销差异	中等规模模型部署
多节点分布式部署	跨服务器集群协作（如2节点16卡部署175B模型）	**节点通信延迟**：网络带宽成为性能关键因素	超大规模模型生产环境
Ray集群架构	Head节点（任务调度/全局存储） + Worker节点（实际计算）的协同机制	**资源协调**：Head节点的自动扩缩容管理能力	分布式训练/推理框架
Windows-Linux混合部署	通过WSL虚拟化实现Windows主机运行Linux版vLLM服务	**性能损耗**：虚拟化层带来的额外开销	开发测试环境搭建
KV缓存优化	注意力机制中的键值缓存显存占用公式：(2×层数×头数×维度×序列长度×精度)	**量化技术**：FP16/INT8对显存占用的影响比例	长文本生成场景