以下为AI生成的图文笔记的内容

一、分布式部署vLLM思路 00:00

1. WSL解决方案 00:08

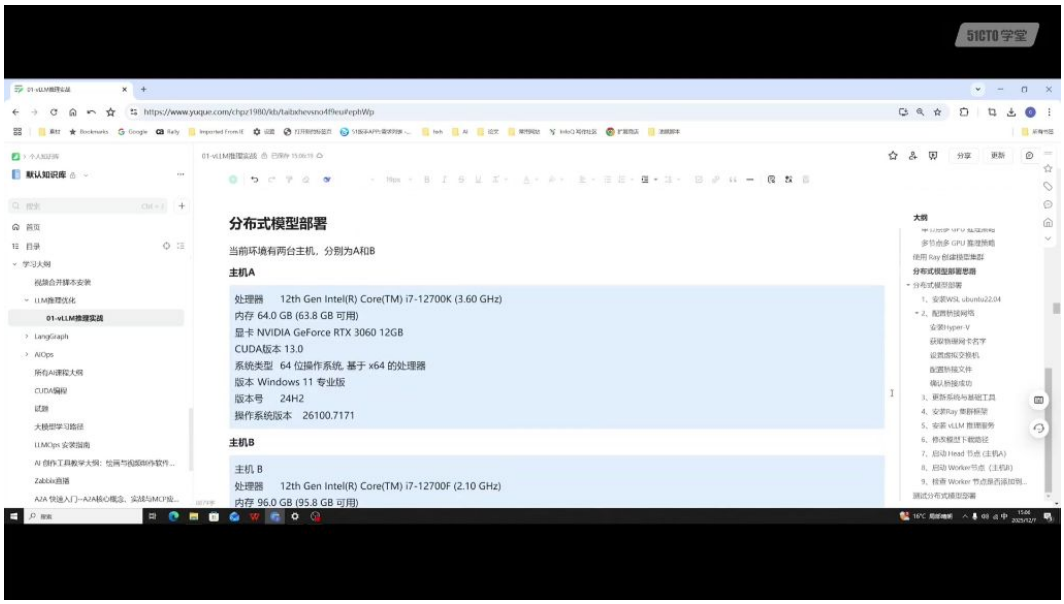
- **部署限制**：Windows主机天生不支持vLLM直接部署，需要通过WSL（Windows Subsystem for Linux）虚拟Linux环境
- **实现方式**：在主机A和B上分别安装WSL，创建Ubuntu 22.04虚拟机环境

2. Ray集群管理 00:20

- **管理架构**：采用Ray作为分布式节点集群管理器
- **节点分工**：
  - 主机A安装Head节点管理整个集群
  - 主机B安装Worker节点注册到集群
- **通信机制**：通过虚拟网络实现跨主机节点通信

二、硬件环境配置 01:02

1. 主机A配置 01:11



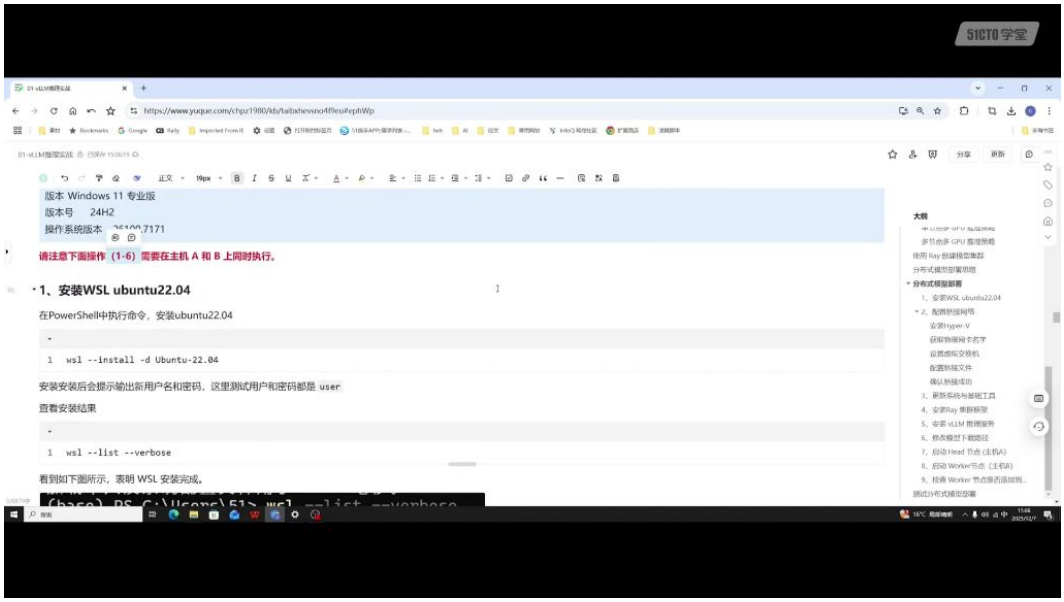
- **处理器**：12代i7-12700K(3.6GHz)
- **内存**：64GB可用
- **显卡**：RTX 3060 12GB
- **CUDA**：版本13.0
- **系统**：Windows 11专业版24H2

2. 主机B配置 01:23

- **处理器**：12代i7-12700F(2.1GHz)
- **内存**：96GB可用
- **显卡**：同主机A配置
- **生产环境对比**：实际生产通常配置4-8张显卡

三、WSL安装配置 01:57

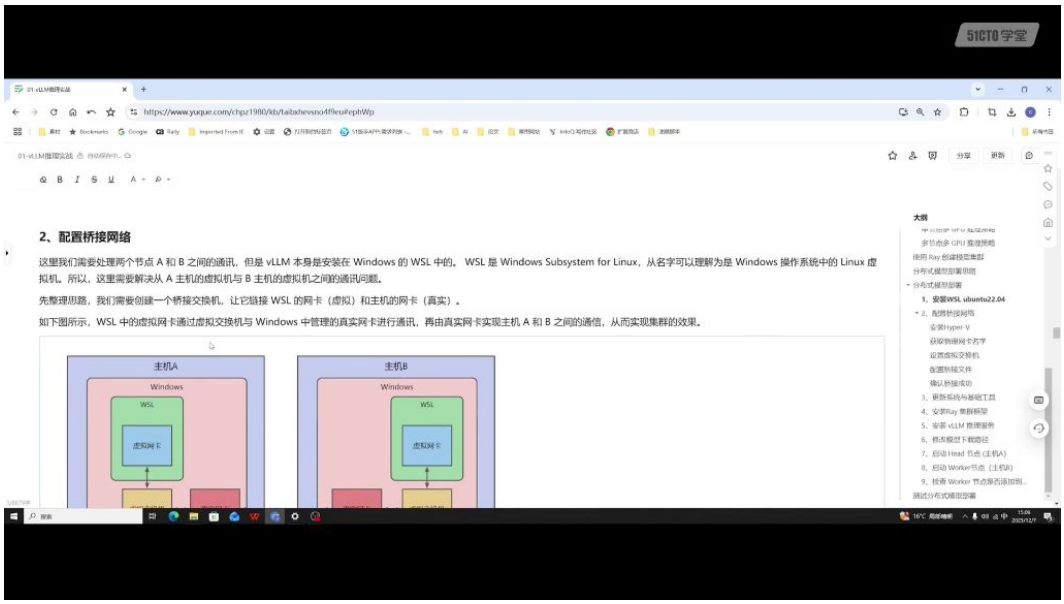
1. Ubuntu安装 02:01



- **安装命令**：wsl --install -d Ubuntu-22.04
- **账户设置**：测试用户名为user，密码同样设为user
- **验证安装**：wsl --list --verbose查看安装结果
- **进入系统**：wsl -d Ubuntu-22.04进入WSL环境

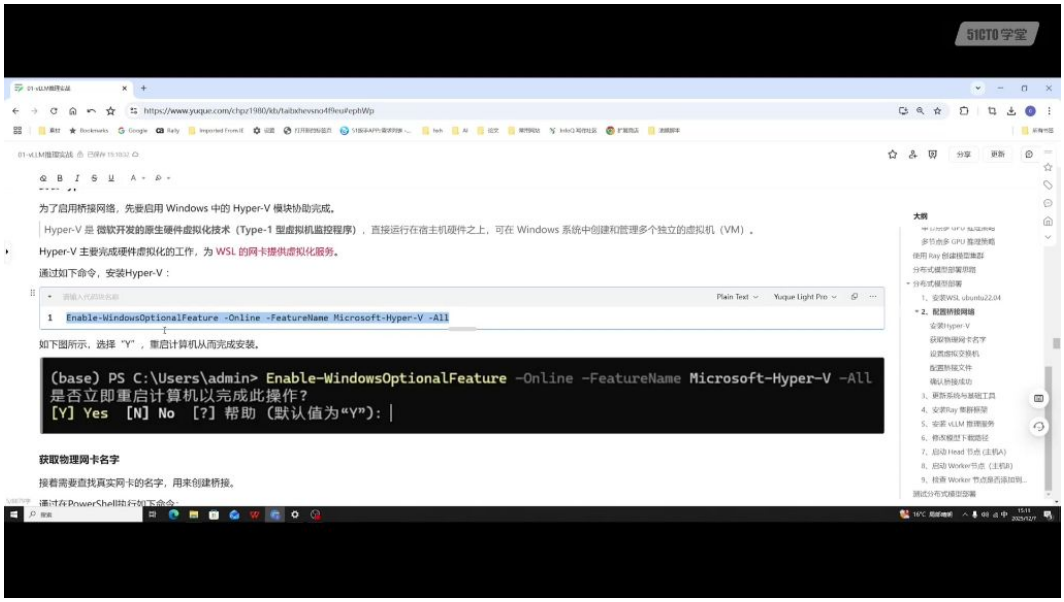
四、网络桥接配置 **02:55**

1. 桥接原理说明 03:54



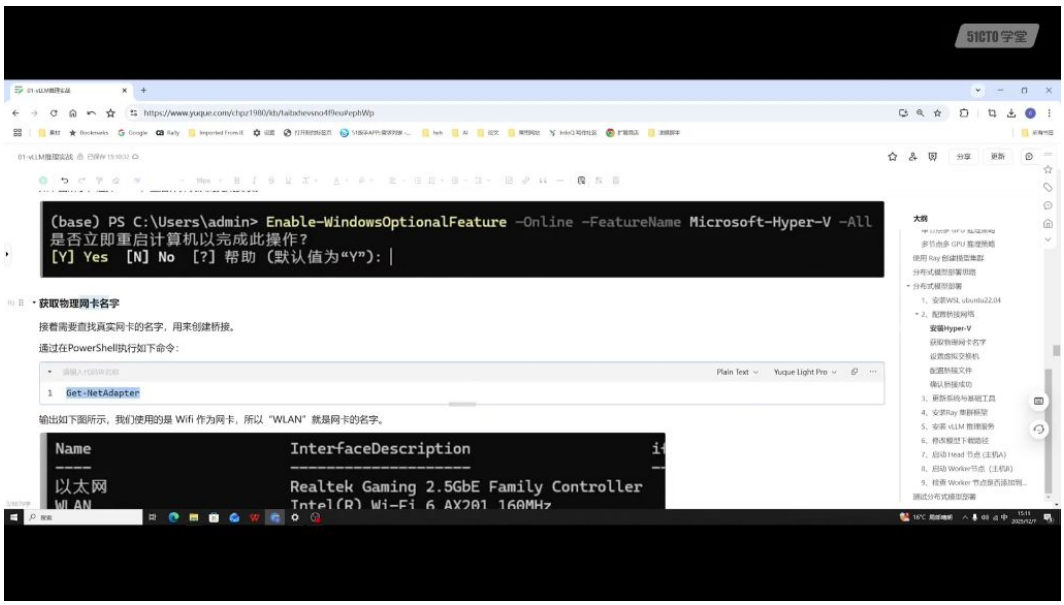
- **通信需求**：解决WSL虚拟机间的跨主机通信
- **实现方案**：
  - 虚拟网卡通过虚拟交换机桥接物理网卡
  - 主机A/B的物理网卡进行实际通信
- **特殊说明**：纯Linux系统可跳过此步骤

2. Hyper-V安装 05:31



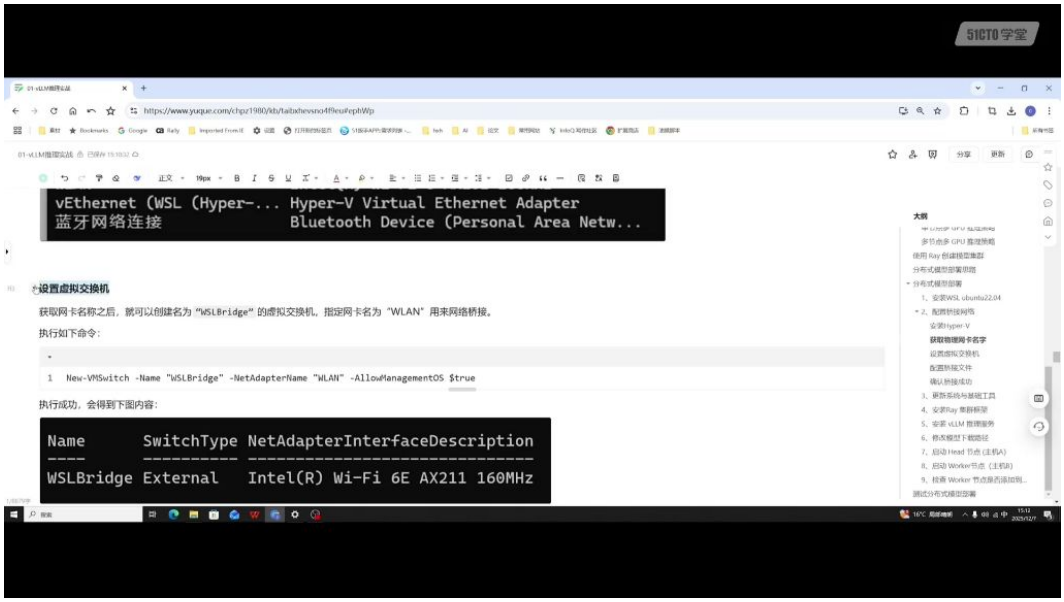
- **功能作用**：微软原生虚拟化技术，为WSL提供虚拟化服务
- **安装命令**：Enable-WindowsOptionalFeature -Online -FeatureName Microsoft-Hyper-V -All
- **注意事项**：执行后需重启计算机生效

3. 物理网卡识别 06:09



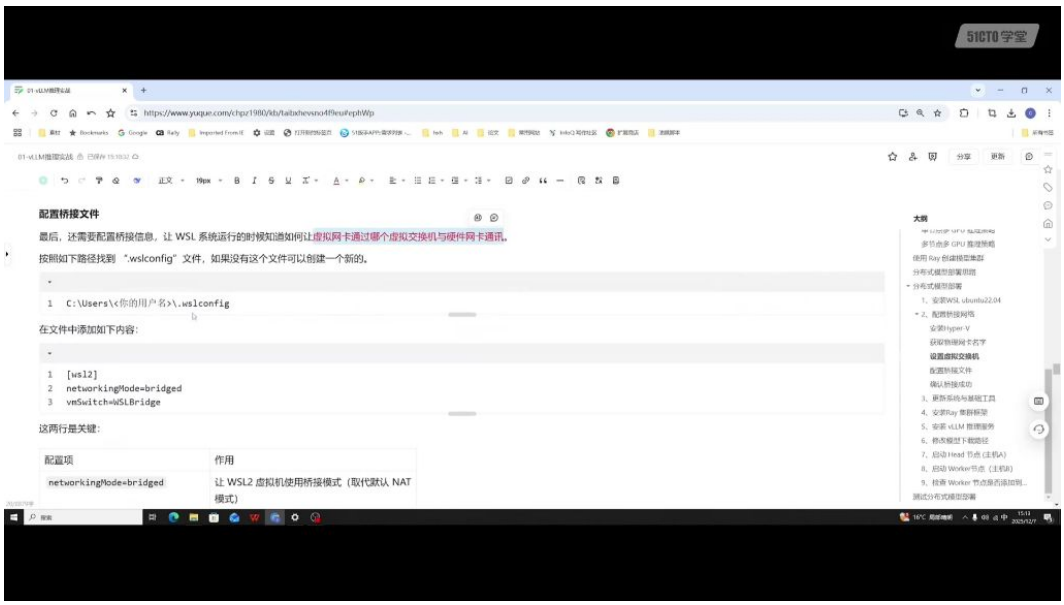
- **识别命令**：Get-NetAdapter
- **关键信息**：记录使用的网卡名称（如WLAN）
- **后续用途**：创建虚拟交换机时需指定网卡名

4. 虚拟交换机创建 06:45



- **创建命令**：New-VMSwitch -Name "WSLBridge" -NetAdapterName "WLAN" -AllowManagementOS$true
- **命名规范**：建议使用WSLBridge等有意义的名称
- **验证成功**：命令返回包含网卡信息的交换机配置

5. 桥接文件配置 07:20



- **文件路径**：C:\Users\<用户名>\.wslconfig
- **关键配置**：
- **配置说明**：
  - bridged模式替代默认NAT
  - 必须与创建的虚拟交换机名称一致

6. 桥接验证 08:44

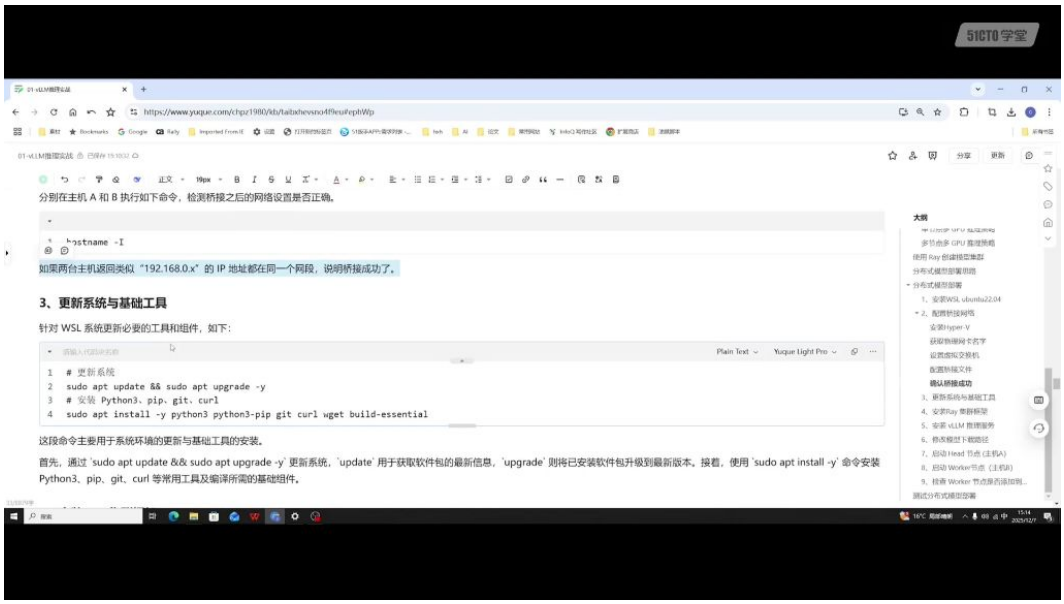
- **验证步骤**：
  - 关闭所有WSL实例：wsl --shutdown
  - 重新启动WSL系统
  - 执行hostname -I查看IP
- **成功标志**：两台主机IP处于同一网段（如192.168.0.x）

五、系统环境准备 09:13

1. 系统更新 09:17

- **更新命令**：sudo apt update && sudo apt upgrade -y
- **功能说明**：
  - update：获取软件包的最新信息
  - upgrade：将已安装软件包升级到最新版本
- **注意事项**：建议在安装新工具前先执行系统更新，确保环境兼容性

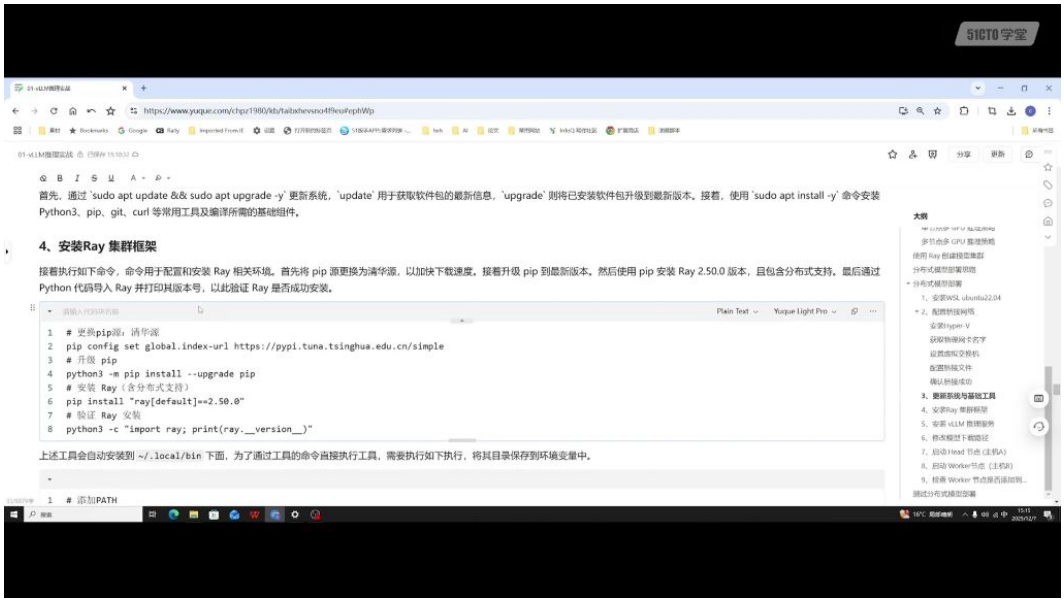
2. 基础工具安装 09:41



- **安装命令**：sudo apt install -y python3 python3-pip git curl wget build-essential
- **工具清单**：
  - Python3及pip包管理工具
  - git版本控制工具
  - curl/wget网络请求工具
  - build-essential编译工具链
- **安装建议**：可直接复制粘贴命令批量安装，这些是后续操作的基础依赖

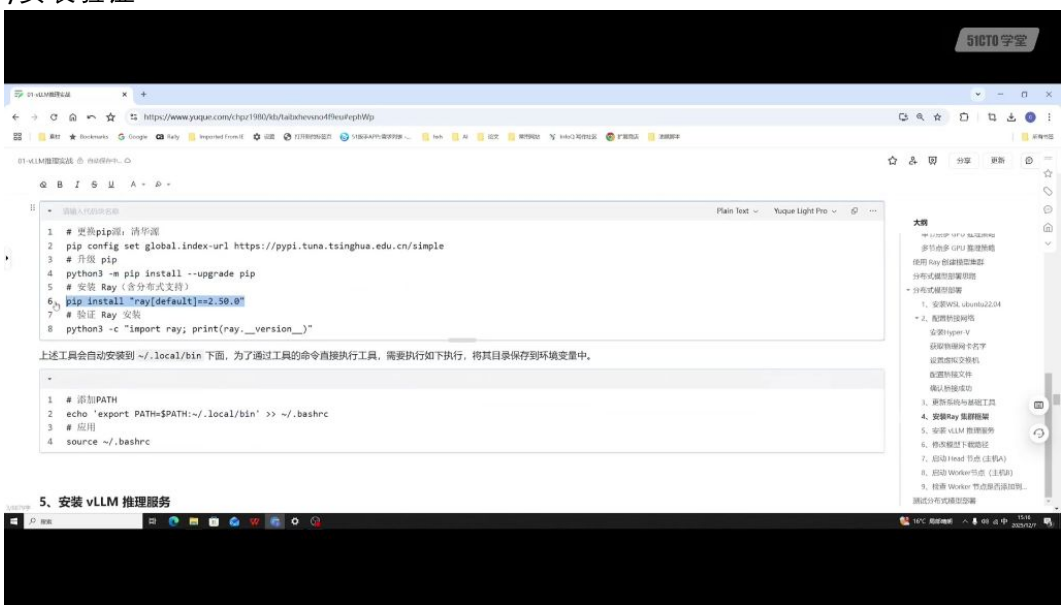
六、Ray集群安装 09:50

1. 清华源配置 10:01



-
- **源配置**：
- **pip升级**：python3 -m pip install --upgrade pip
- **安装建议**：使用清华源可显著提升国内下载速度，若使用VPN可不配置

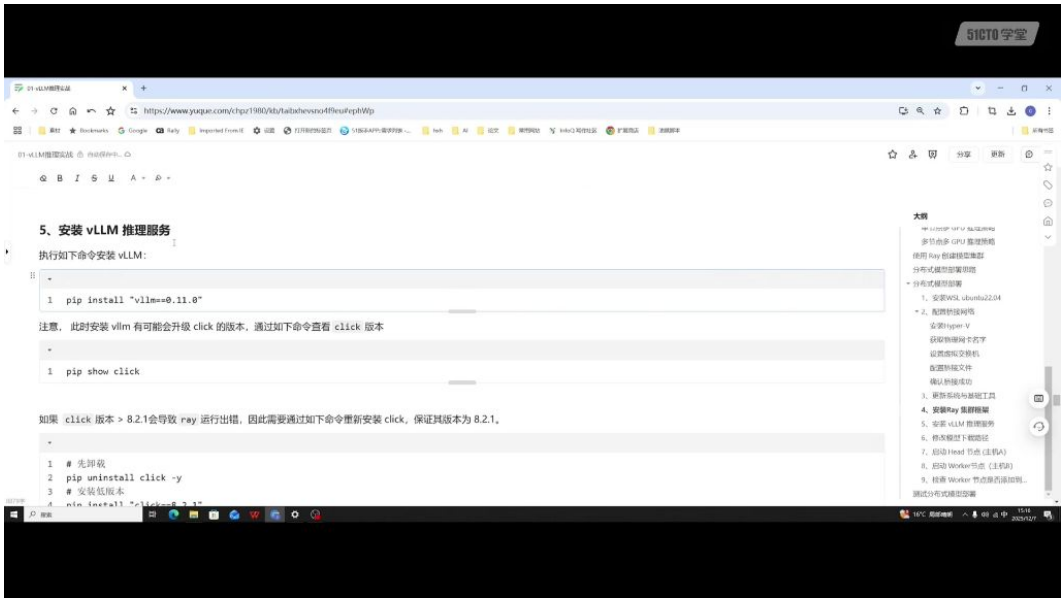
2. Ray安装验证 10:20



-
- **安装命令**：pip install "ray[default]==2.50.0"
- **版本验证**：
- **环境变量配置**：
- **路径说明**：Ray默认安装到~/.local/bin目录
- **配置技巧**：添加环境变量后可全局调用ray命令，否则需使用完整路径

七、vLLM服务安装 11:15

1. vLLM安装 11:18



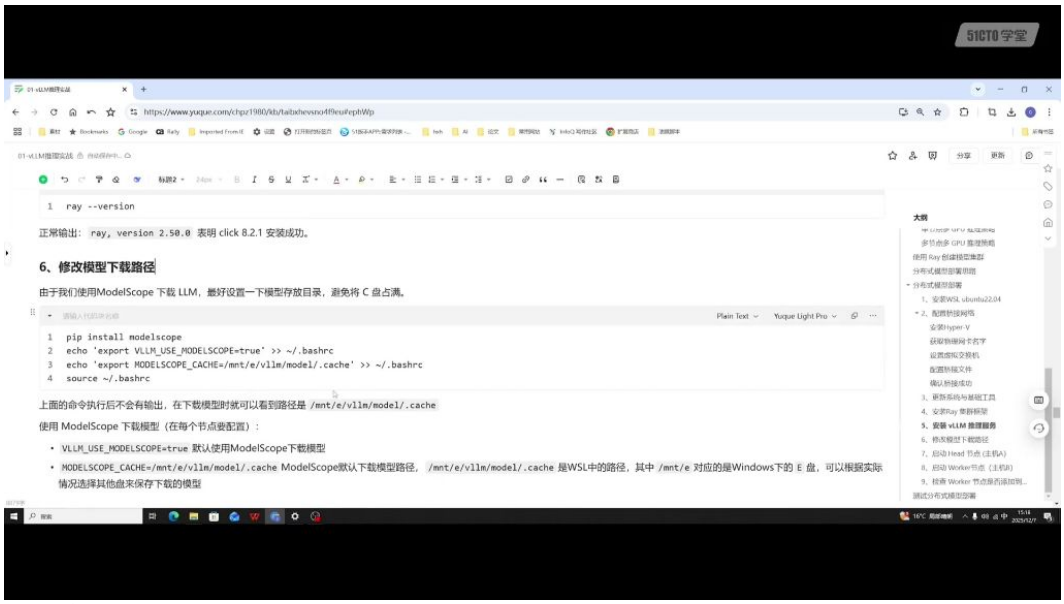
- **安装命令**: pip install vllm==0.1.10
- **版本选择**: 0.1.10版本是目前最稳定的最新版本
- **安装方式**: 推荐直接pip安装而非docker容器方式

2. 依赖冲突解决 11:43

- **关键依赖**: click包版本必须为8.2.1
- **冲突表现**: click版本>8.2.1会导致ray运行出错
- **解决方法**:
  - 检查版本：pip show click
  - 卸载高版本：pip uninstall click -y
  - 安装指定版本：pip install click==8.2.1
- **验证方法**: 执行ray --version显示2.5.0即表示成功

八、模型下载配置 **12:49**

1. 下载路径设置 12:57



- **工具安装**: pip install modelscope
- **环境变量配置**:
  - export VLLM_USE_MODESCOPE=true

- export MODELSCOPE_CACHE=/mnt/e/vllm/model/.cache

- **路径说明**:
  - /mnt/e/对应Windows的E盘
  - 可替换为其他有空间的盘符（如D/F盘）
- **生效命令**: source ~/.bashrc

2. 目录映射说明 13:45

- **WSL规则**: 所有目录都在/mnt/下映射
  - /mnt/c/映射Windows C盘
  - /mnt/d/映射Windows D盘
- **空间管理**: 避免下载到系统盘导致空间占满
- **模型来源**: 使用摩搭社区(ModelScope)下载LLM模型

九、知识小结

知识点	核心内容	关键步骤/配置	注意事项
分布式部署vLLM架构	通过WSL虚拟Linux环境部署vLLM，使用Rain构建跨主机集群	主机A（Handler节点）、主机B（Worker节点）	Windows原生不支持vLLM，需依赖WSL
WSL安装与配置	使用Ubuntu 22.04版本，通过PowerShell命令安装	wsl --install -d Ubuntu-22.04	需设置用户名/密码（示例：user/user）
网络桥接原理	虚拟交换机桥接WSL虚拟网卡与物理网卡	1. 启用Hyper-V 2. 创建虚拟交换机（New-VMSwitch） 3. 修改.wslconfig文件	需确保两台主机在同一网段（hostname -I验证）
Rain集群框架安装	开源分布式推理框架，版本2.5.0	1. 配置清华PyPI源 2. pip install rain==2.5.0.0	**Click包版本冲突**：需锁定为8.2.1
vLLM推理服务器安装	通过pip安装vLLM 0.1.1.0版本	pip install vllm==0.1.1.0	依赖项冲突需手动降级Click包
模型下载配置	从摩搭社区下载模型，指定缓存目录	1. 安装摩搭SDK 2. 设置环境变量 export VLLM_CACHE_DIR	避免占用系统盘空间（示例：E:/vlm_model/.cache）
硬件配置示例	主机A: i7/64GB/RTX3060 12G 主机B: i7/96GB/RTX3060 12G	生产环境建议多显卡（4/8张）	演示环境仅需单显卡