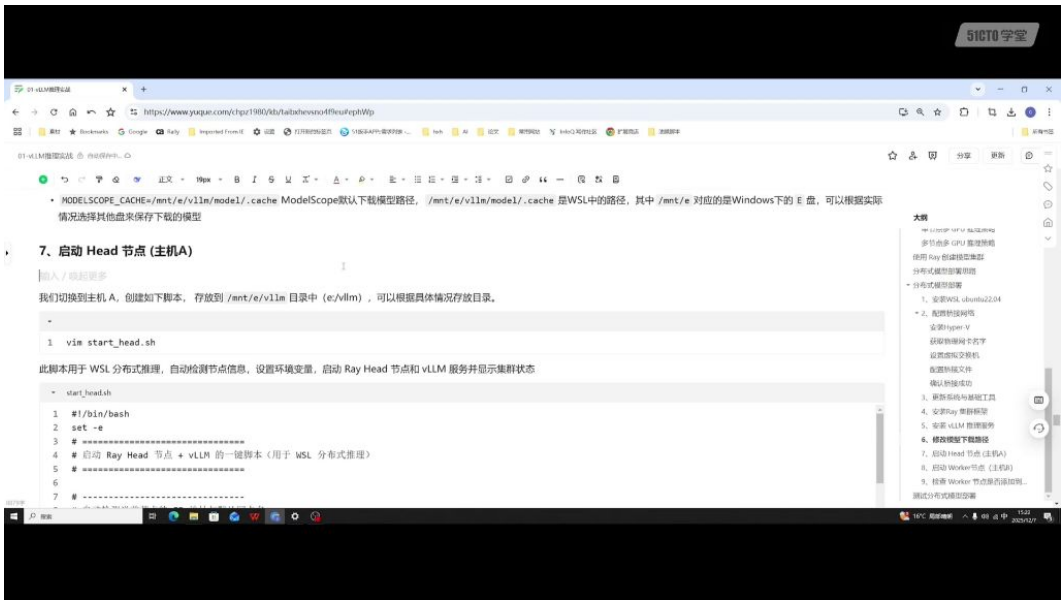
以下为AI生成的图文笔记的内容

一、分布式模型部署 **00:00**

1. 安装WSL ubuntu22.04 00:02

- **环境准备**：需要在主机A和主机B上同时安装WSL Ubuntu22.04系统作为基础运行环境
- **路径说明**：默认模型下载路径为/mnt/e/v11m/model/，其中/mnt/e对应Windows的E盘，可根据实际情况修改存储位置

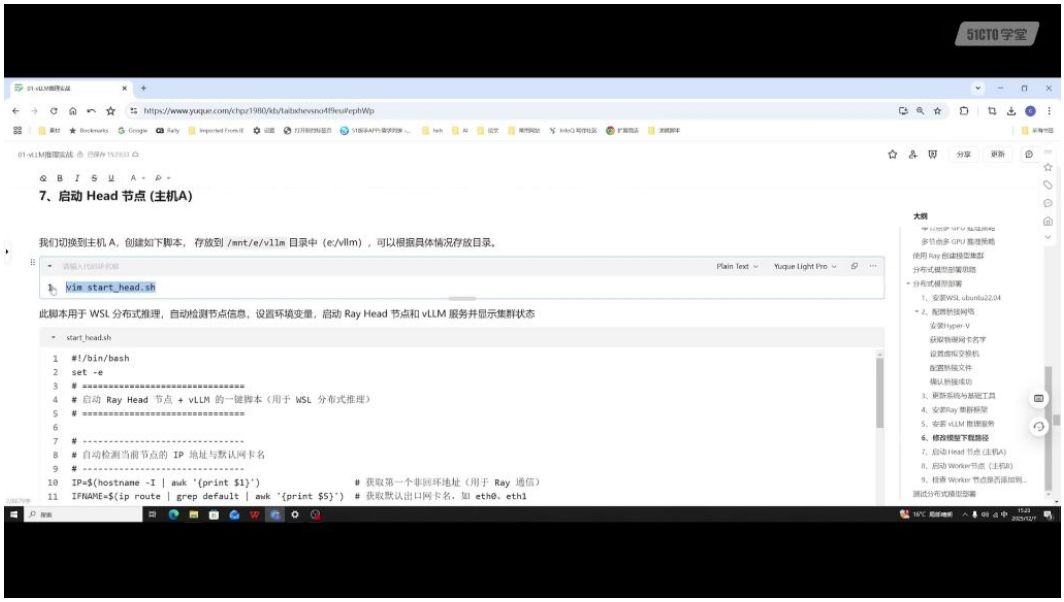
2. 配置桥接网络 00:17

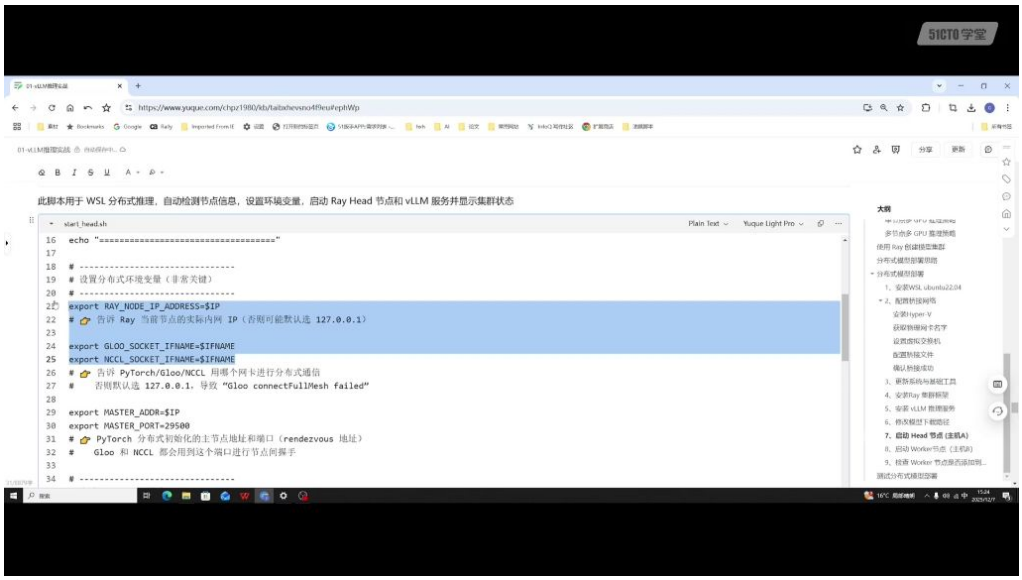


- **关键步骤**：
  - 安装Hyper-V虚拟化平台
  - 获取物理网卡名称
  - 设置虚拟交换机
  - 配置桥接文件
  - 确认桥接成功
- **通信原理**：主机A(Head节点)与主机B(Worker节点)需要通过桥接网络互相通信，Head节点负责接收用户请求并分发任务

3. 启动Head节点 00:46

1）脚本配置 00:58

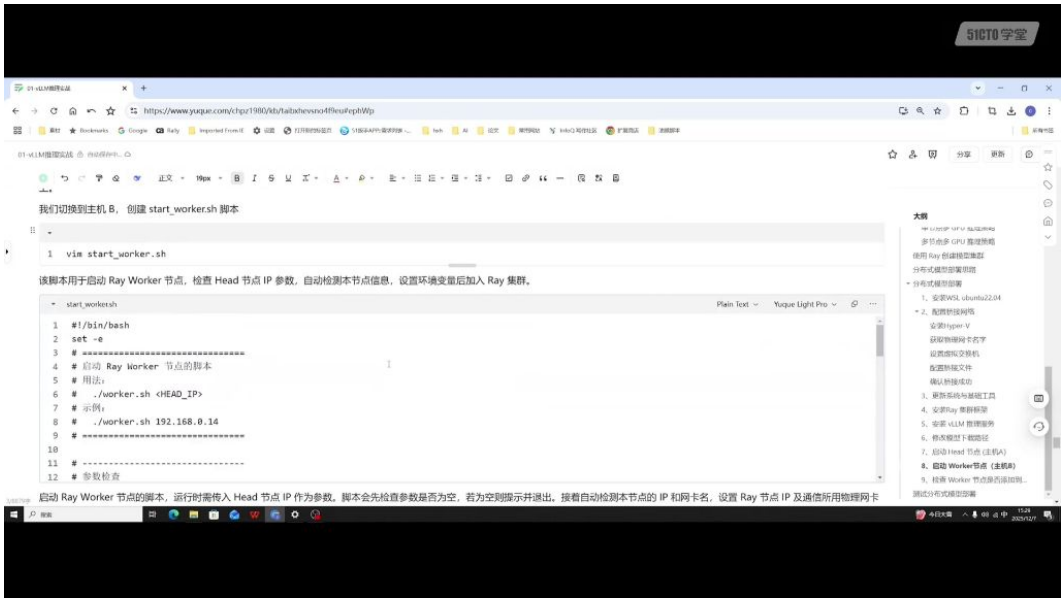


- **核心功能**：
  - 自动检测节点IP和网卡名
  - 设置分布式环境变量
  - 启动Ray Head节点和vLLM服务
  - 显示集群状态
- **关键参数**：
  - RAY_NODE_IP_ADDRESS：指定节点实际内网IP
  - GLOO_SOCKET_IFNAME/NCCL_SOCKET_IFNAME：指定分布式通信网卡
  - MASTER_ADDR/MASTER_PORT：PyTorch分布式初始化参数（默认端口29508）
  - 

- **启动流程**：
  - 强制停止旧Ray进程
  - 启动Ray Head节点（指定IP和端口6379）
  - 启动vLLM服务（绑定IP和端口8000）
  - 使用Ray分布式调度（--distributed-executor-backend ray）
  - 启用两节点流水线并行（--pipeline-parallel-size 2）

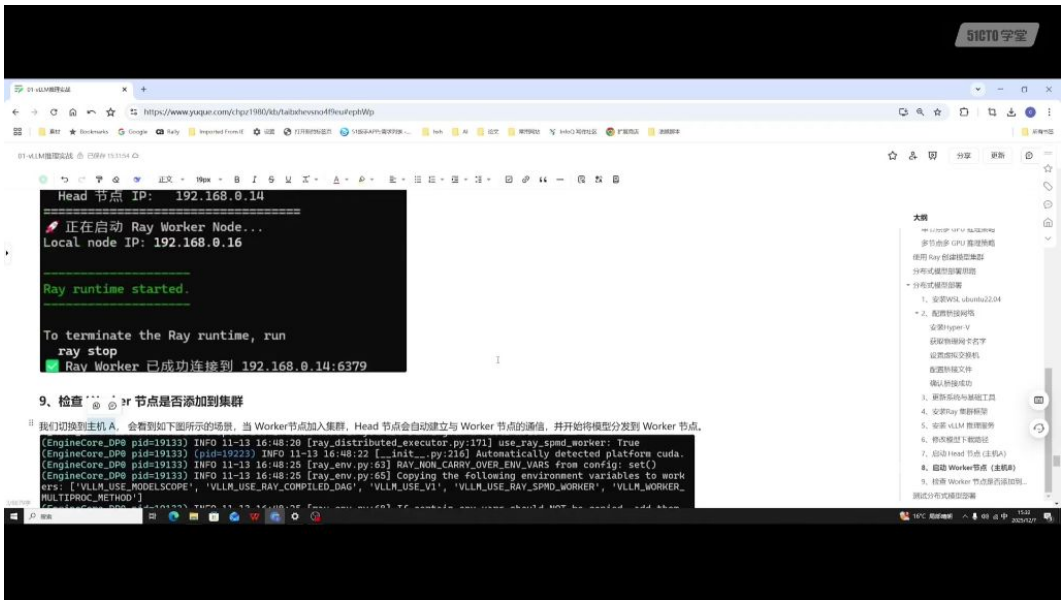
4. 启动Worker节点 06:10

1）脚本配置



- **执行方式**：需传入Head节点IP作为参数（如./start_worker.sh 192.168.0.14）
- **核心功能**：
  - 检查Head节点IP参数
  - 自动获取本机IP和网卡名
  - 设置环境变量
  - 加入Ray集群
- **连接验证**：成功连接后会显示"Ray Worker已成功连接到[Head_IP]:6379"的提示

5. 内容总结 09:04



- **部署阶段**：
  - 步骤1-6：在主机A和B上同步执行（基础环境准备）
  - 步骤7-9：分别在Head和Worker节点执行（集群启动）
- **脚本区别**：
  - Head节点脚本：自主启动服务并等待Worker连接
  - Worker节点脚本：需指定Head节点IP进行连接
- **扩展性**：可通过在多个Worker节点执行相同脚本实现集群扩展

二、知识小结

知识点	核心内容	关键配置/参数	难点/易错点
分布式推理集群架构	主机A（Handle节点）负责请求分发与结果汇总，主机B（Worker节点）执行具体推理任务	- Handle节点IP：192.168.0.14 - Worker节点IP：192.168.0.16 - 通信端口：6379（Rain）、8000（VLM服务）	**网络桥接**需确保双向通信；Worker节点需主动连接Handle节点
Rain集群部署	通过脚本启动分布式调度服务： - Handle节点：start_hand.sh - Worker节点：start_worker.sh	- Handle脚本参数：--node-ip-address、--port=6379 - Worker脚本参数：--address=<Handle_IP>:6379	**端口冲突**需检查；Worker节点需严格匹配Handle的IP和端口
VLM服务配置	模型服务部署与分布式并行推理	- 模型名称：从摩哒社区获取 - 服务端口：8000 - 并行参数：distributed_execution_backend=rain	**模型名称**需与社区一致；**端口暴露**需与Docker配置对齐
脚本关键逻辑	- Handle脚本：获取IP、网卡名称，启动Rain服务并等待Worker加入 - Worker脚本：连接Handle节点并注册	- 环境变量：IP、IF_NAME - 仪表盘配置：dashboard_host（可选）	**环境变量**未设置会导致启动失败；Worker需手动输入Handle IP
集群状态验证	Handle节点日志显示Worker连接成功	- 成功标志：rank is connected - 预期输出：application start complete	**超时问题**：Worker未加入时Handle会持续等待
推理服务测试	使用原单机代码测试分布式集群，仅需修改IP为Handle节点地址	- 测试IP：192.168.0.14:8000	**代码兼容性**：单机代码可直接复用，无需调整逻辑